

B3 B 系列

cellranger count 實戰 與 web_summary 判讀

跑完 count 只是開始——能判斷「這批資料能不能用」才是本事。

約 40 分鐘 | 前置: B2 | 資料: PBMC 1k FASTQ

兩份 web_summary，一份健康一份災難

樣本 A • web_summary.html

Estimated Number of Cells	1,187
Mean Reads per Cell	54,102
Median Genes per Cell	2,412
Valid Barcodes	97.6%
Mapped to Transcriptome (確信比對)	62.3%

警告：0 則

樣本 B • web_summary.html

Estimated Number of Cells	9,315
Mean Reads per Cell	6,890
Median Genes per Cell	342
Valid Barcodes	71.2%
Mapped to Transcriptome (確信比對)	28.4%

警告：4 則

你能在 30 秒內指出哪一份不能用、為什麼嗎？

同一種實驗、同一條流程——差別全寫在這一頁報告裡

本集的起點

web_summary 是這批資料的體檢報告。
看不懂它，下游做得再漂亮都是白工。

矩陣一旦出了問題， Seurat 不會幫你發現——它只會忠實地分析垃圾。

這一集你會學到


- 1 逐參數看懂 cellranger count 指令，用 PBMC 1k 實跑一次
- 2 逐區判讀 web_summary：十個關鍵指標、knee plot 形狀學、警告訊息
- 3 分清 outs/ 裡每個檔案是什麼、誰要用它——尤其 filtered 與 raw

01

count 到底在做什麼

寫指令之前，先知道按下 Enter 之後發生的四件事

一個指令，四件事




一個指令跑完四件事——但每一件品質，都要靠 `web_summary` 回頭驗收

比對、校正與去重、cell calling、產出——`web_summary` 就是這四件事的驗收單

cell calling：從 knee plot 開始

barcode rank plot (膝蓋圖)



第一步：高 UMI 直接收

以預期細胞數推一條硬閾值，
陡崖以上的 barcode 先判為細胞

第二步：低 UMI 救回

拿 ambient 平台估出「空滴長相」，
profile 明顯不像空滴的低 UMI
barcode 也救回來 (EmptyDrops 式檢定)

低 RNA 含量的細胞 (如 T 細胞)
不會只因為 UMI 少就被丟掉

模擬資料

EmptyDrops 式兩步：高 UMI 直接收，低 UMI 跟「空滴長相」比過才收 (Lun et al. 2019)

本集核心觀念

**跑指令的是電腦，
判讀報告的是你。**

count 幾乎不會失敗——它只會安靜地產出一份「跑完了但不能用」的結果。判讀是唯一的防線。

02

指令解剖

八行指令，每一行都知道為什麼

完整的一次 count

```
cellranger count \  
  --id= pbm c1k_count \  
  --transcriptome= refdata-gex-GRCh38-2020-A \  
  --fastqs= fastq/pbm c_1k_v3_fastqs \  
  --sample= pbm c_1k_v3 \  
  --create-bam = true \  
  --localcores= 8 \  
  --localmem = 64
```

就這八行。接下來一行一行拆

每個參數在做什麼

`cellranger count \`

`--id=pbmc1k_count`

→ 輸出資料夾名，自己取；重跑要換名或刪舊資料夾

`--transcriptome=refdata-gex-GRCh38-2020-A`

→ B2 下載的參考資料夾（基因組 + GTF）

`--fastqs=fastq/pbmc_1k_v3_fastqs`

→ FASTQ 所在資料夾，不是單一檔案

`--sample=pbmc_1k_v3`

→ FASTQ 檔名的樣本前綴，必須一字不差

`--create-bam=true`

→ v8 起必填：要不要產 BAM（大檔，見 4-4）


`--localcores=8 --localmem=64`

→ 用幾核心、幾 GB 記憶體；不設就吃滿整台機器

藍色照抄即可；金色是最常出錯的兩個；紅色關係到整台機器

--sample 對的是 FASTQ 檔名

FASTQ 檔名的固定結構



對不上 (如 `--sample=pbmc1k`) → 「No input FASTQs were found」，直接停在起跑線

- FASTQ 檔名結構固定：樣本名 _S1_L001_R1_001.fastq.gz
- `--sample` 只對「樣本名」那一段，必須一字不差
- 多個樣本放同資料夾時，它就是挑檔案的依據

對不上會怎樣？跑給你看

```
# [踩雷示範] 樣本名打成 pbm c1k (漏了底線與版本)
cellranger count --id= trap_run \
  --transcriptome= refdata-gex-GRCh38-2020-A \
  --fastqs= fastq/pbm c_1k_v3_fastqs \
  --sample= pbm c1k --create-bam = true
```

error: No input FASTQs were found for the
requested parameters.

(檢查三件事： --fastqs 路徑、 --sample 拼字、檔名前綴)

好消息：這種錯 30 秒內就報，不會浪費你兩小時

資源與 `--expect-cells`：何時要管

```
# 資源：不設限，它就吃滿整台機器——共用伺服器上是公害
--localcores=8      # 給幾顆核心
--localmem=64        # 給幾 GB 記憶體；人類參考建議  $\geq 64$ 

# 預期細胞數：預設自動估，多數情況「不要給」
--expect-cells=5000 # 只在 cellcalling 明顯判錯、
                   # knee plot 又亂時，用上機數救回
```

`--expect-cells` 是矯正工具，不是必填欄位——先跑預設，看報告再說

4-1 小結：下指令前的三個確認

路徑兩條



--transcriptome 指向 B2 的參考、--fastqs 指向資料夾

前綴一致



--sample 與 FASTQ 檔名前綴一字不差

資源設限



localcores / localmem 明確給定，別吃滿機器

03

按下 Enter 之後

看懂螢幕上刷過的東西，等待才不焦慮

執行中的畫面長這樣

```
$ cellranger count --id=pbm c1k_count ...  
Marian Runtime - v4.0.13  
Serving UI at http://localhost:3600 ...  
Running preflight checks (please wait)...  
2026-08-18 09:12:03 [runtime] (run:local) ID .pbm c1k_count...  
# (接下來是幾百行 stage 訊息，一個 stage 一段，放著跑就好)
```

```
Waiting 6 seconds for UI to do final refresh.  
Pipestance completed successfully!
```

你要看的是最後一行：completed successfully 出現，才有 outs/

時間都花在哪

一次 count 的時間都花在哪（比例為示意）



行情：PBMC 1k 在 8 核 64 GB 上約 1-2 小時；記憶體低於 32 GB 時 STAR 連參考都載不進去

STAR 比對佔大頭；跑不動的備案：官方提供現成輸出可直接下載（附錄 C）

4-2 小結：等待的一兩個小時做什麼

別盯進度



中途卡住極少見；報錯幾乎都在前 5 分鐘

寫記錄



上機細胞數、樣本狀態記下來，等一下判讀要用

別砍程序




要中斷就 Ctrl-C 讓它收尾，砍半可能留殘檔

04

web_summary 逐區判讀

本集重頭戲：一頁報告、一套固定的看法

先認地圖：四個區、固定順序



① 先看警告

紅色 ERROR 出現，這批資料先當嫌疑犯

② 再看三個 hero 數字

細胞數對不對得上上機預期

③ knee plot 看形狀

陡崖清楚嗎？ambient 平台乾淨嗎？

④ Mapping 與 saturation

比對去哪了、定序深度夠不夠

示意圖

警告 → 三個 hero 數字 → knee plot → Mapping 與 saturation。每一份都照這個順序

三個 hero 數字

Estimated Number of Cells

1,187

cell calling 判定的細胞數

健康：接近上機預期的回收數
(上機 1,600 顆 → 期望約 1,000)
高一大截或低一大截都要追

Mean Reads per Cell

54,102

總 reads ÷ 細胞數

這是「定序花了多少」不是品質；
官方建議每顆至少 20,000 reads
細胞數灌水時它會被稀釋

Median Genes per Cell

2,412

每顆細胞測到基因數的中位數


跟組織、深度、化學版本都有關；
PBMC 在標準深度常見 1,000–2,500
驟低常是深度不足或細胞灌水

三個數字是連動的：細胞數被灌水 → 另外兩個同時被稀釋。單看一格會被騙

- Estimated Cells：對照上機預期，高低一大截都要追
- Mean Reads per Cell：定序深度指標，官方建議 $\geq 20,000$
- Median Genes per Cell：跟組織與深度連動，驟低要警覺
- 三個連動：細胞數灌水，另外兩個被稀釋


knee plot 形狀學

健康的膝蓋




陡崖清楚、平台乾淨
細胞與空滴分得開

塌掉的膝蓋



斜坡連續、沒有分界
低品質樣本或裂解／堵塞

雙膝蓋




兩個高原：兩種 RNA 含量
差很大的族群，不一定是壞事

模擬資料

健康的膝蓋、塌掉的膝蓋、雙膝蓋——形狀比數字更早說真話


Mapping 指標群與 Q30

數值為 PBMC 示意；紅虛線是常用判讀門檻（10x 的警告大致落在附近）



注意：v7 起 include-introns 預設打開，intronic reads 會計入基因——跨版本比較要留意

Sequencing Saturation 是什麼



saturation 的意思

「再定序一條 read，
它是重複分子的機率」
50% = 每兩條就有一條
是看過的 UMI

沒有及格線

高 = 這個 library 挖得深
低 = 還有分子沒看到
低不等於失敗，
是「加測還有得賺」

模擬資料

它量的是「這個 library 挖到多深」，不是及格考

saturation 低，要不要加測？

先問你的生物問題需要什麼，再談錢

先不加

median genes 已夠用

- 看 marker、分群、註釋：夠了
- 把預算留給補樣本或重複
- 附錄 F 有換算範例

值得加

訊號真的不夠

- 要抓低表現基因或稀有轉錄本
- saturation 低 → 每條新 read 還很划算
- 同一個 library 送回去加測即可

寫進你的分析筆記

**「警告幾則、細胞數對不對、
knee 形狀正不正、 mapping 去了哪。」**

四句話答得出來，這份 web_summary 才算看完。

05

outs/ 資料夾解剖

十來個檔案，每個都知道是誰要用的

先列出來看

```
$ ls outs/
```

```
analysis/                possorted_genom e_bam .bam  
c loupe.c loupe          possorted_genom e_bam .bam .bai  
filtered_feature_bc_m atrix/  raw_feature_bc_m atrix/  
filtered_feature_bc_m atrix.h5  raw_feature_bc_m atrix.h5  
m etrics_sum m ary.csv      web_sum m ary.htm l  
m olecule_info.h5
```

看起來很多，其實只有四類：報告、矩陣、分子層記錄、比對檔

每個檔案是誰要用的

outs/

web_summary.html

體檢報告，本集主角；先開它

metrics_summary.csv

同一批指標的 csv 版，寫 pipeline 用

filtered_feature_bc_matrix/

只含「判定為細胞」的矩陣 → Seurat 讀這個

raw_feature_bc_matrix/

whitelist 全部 barcode，幾乎都是空滴

molecule_info.h5

每個分子一筆記錄；aggr 合併樣本要吃它

possorted_genome_bam.bam

比對結果（數 GB）；velocityto、重新分析用

cloupe.cloupe

給 Loupe Browser 點著看的檔

analysis/


Cell Ranger 自帶的分群與降維（參考就好）

兩個矩陣資料夾裡都是同一組三件套：barcodes.tsv.gz + features.tsv.gz + matrix.mtx.gz（另有同內容的 .h5 單檔版）

B5 要的是 filtered 矩陣；B4 的 aggr 要 molecule_info.h5；BAM 給進階分析

filtered vs raw : 一定要分清楚


raw_feature_bc_matrix



v3 whitelist 全部 $\approx$ 680 萬個 barcode
絕大多數欄位是空滴，只有零星訊號

cell
calling

filtered_feature_bc_matrix



cell calling 留下的 1,187 欄
= 下游分析的起點

拿 raw 進 Seurat，你會得到上百萬顆「細胞」——等一下實跑給你看

同一批資料的兩種切面：raw 是全部 barcode，filtered 是 cell calling 的倖存者

拿錯會怎樣？跑給你看

```
# [踩雷示範] 在 R 裡把 raw 當 filtered 讀
library(Seurat)
raw <- Read10X("outs/raw_feature_bc_matrix/")
dim(raw)
filt <- Read10X("outs/filtered_feature_bc_matrix/")
dim(filt)
```

```
[1] 36601 6794880 # raw : 680 萬欄，幾乎全是空滴
[1] 36601 1187 # filtered : cell calling 留下的細胞
```

680 萬 對 1,187——建物件當場爆記憶體都算幸運，最怕的是沒爆、往下做

警告訊息怎麼讀

兩個等級，處理方式不同

WARN

黃色警告：帶著懷疑往下

- 如 saturation 偏低、genes 偏少
- 資料多半還能用，但要記進筆記
- 下游解讀時回頭對照

ERROR

紅色錯誤：先停下來

- 如 valid barcodes 過低、比對率崩盤
- 先找原因：樣本？定序？參考？
- 沒想清楚前，不要進下游

4-4 小結：帶走三個檔案

filtered 矩陣



B5 的 Read10X 就吃它——下游的起點

web_summary



存檔歸檔，寫論文方法段與 QC 描述要引用

molecule_info.h5



多樣本合併（B4 的 aggr）指名要它

06

踩雷區

三個雷，每一個都把後果攤開來看

雷一：細胞數比上機數還多

雷是什麼

上機 5,000 顆，web_summary 報 9,315 顆，你照單全收往下做。



為什麼會踩


「軟體算出來的」聽起來比自己的實驗記錄可信。

踩了會怎樣

幾千顆空滴與碎片混進矩陣當「細胞」，QC 只能救回一部分，分群裡多出整團垃圾。

回收率對不上，先看 knee plot

上機 5,000 顆，web_summary 卻報 9,315



為什麼會發生

樣本裂解、ambient 爆量、堵塞、
或 --expect-cells 給錯，讓演算法
把平台上的空滴一起收進來

一行檢查

細胞數 ÷ 上機數 應落在 0.4-0.7；
差太多就先看 knee plot 形狀

下游代價

幾千顆空滴混進矩陣，QC 也難救；
mean reads 與 median genes 全被稀釋

模擬資料

一行檢查：細胞數 ÷ 上機數 應約 0.4-0.7。超出就先追原因，不要往下跑

雷二：只看細胞數，不看 mapping

雷是什麼

細胞數漂亮就宣布成功， Mapping 區從來沒往下捲過。



為什麼會踩

hero 數字在最上面、字最大； Mapping 是一排小字表格。

踩了會怎樣

intronic 驟升、antisense 異常這些「樣本出事」的訊號全被錯過，
垃圾資料一路走到 DE 才發現。

mapping 分解表會說真話

細胞數再漂亮，這個分解表也會把出事的樣本抓出來（比例為示意）

健康的細胞樣本



出事的樣本（裂解／降解）



● Exonic ● Intronic ● Intergenic ● Antisense

細胞質 mRNA 流失 → 訊號只剩細胞核的未剪接 RNA → intronic 驟升；同一種形狀也可能只是 snRNA-seq

exonic 對 intronic 的比例翻轉＝細胞質 RNA 流失。同一形狀在 snRNA-seq 是正常的

雷三： saturation 低就急著下定論

雷是什麼

看到 saturation 33% ，立刻加訂兩倍定序量，或反過來宣判資料不能用。




為什麼會踩

百分比看起來像考試分數， 33 分像不及格。

踩了會怎樣

多花一倍錢換兩成訊號；或者一批本來夠用的資料被冤枉丟掉。兩邊都是浪費。

加測的邊際效益，算給你看



算給你看

reads 翻倍 → UMI 多 43%
再翻倍 → 只再多 19%
(新基因增加得更少：
新分子多落在看過的基因上)

先問對的問題

不是「saturation 幾 %」，
是「median genes 夠不夠
回答你的生物問題」
夠了就別加測

模擬資料

成本線性長、資訊對數長。判斷標準是「median genes 夠不夠回答問題」，不是百分比

踩雷區小結

web_summary 的每個數字都要「對照」：
對上機記錄、對組織預期、對你的問題。

沒有對照物的數字不叫判讀，叫看心情。

05+

複雜樣本策略室

同一份報告，換成腫瘤樣本——判讀的對照物整套要換

腫瘤 web_summary 的「正常異常」

腫瘤樣本 · 壞死核心取樣 · web_summary

Estimated Number of Cells **2,845**

上機 8,000 → 回收 36%

Median Genes per Cell **812**

遠低於 PBMC 行情

Fraction Reads in Cells **62.4%**

< 70% 觸發警告：ambient 偏高

Valid Barcodes **97.1%**

技術端健康

Mapped to Genome **91.3%**

技術端健康

警告：2 則

● 正常異常：組織的預期值

● 技術端健康

「正常異常」：對照物換掉

壞死核心＝活細胞少、湯很濃：
回收低、基因數低、Fraction Reads in Cells 偏低
都是這種取樣位置的預期值，不是流程失敗。
對照物不是 PBMC 行情，是同組織、同部位的
歷史批次——你的正常形狀庫

底線不動：技術端崩了照樣停

Valid Barcodes、Q30、Mapped to Genome
跟組織長什麼樣無關——它們崩盤，
是定序或 reference 出事，腫瘤背不了這個鍋

預期值是假設：下修多少、為什麼、根據哪幾批——寫下來

示意圖（數字為示意）

壞死核心樣本的低回收、低基因數是組織的預期值；技術端指標崩了照樣停

snRNA-seq：intronic 高是特徵，不是警訊

凍存腫瘤常走單核流程——同一個數字，先問實驗設計

全細胞 scRNA

intronic 兩三成是常態

- 驟升＝細胞質 mRNA 流失（雷二）
- include-introns 開關影響的是基因數多寡
- 對照物：全細胞樣本的歷史行情

單核 snRNA

intronic 四五成是特徵

- 凍存檢體膜已破——取的就是細胞核
- include-introns 必須開：關掉丟一半左右的訊號
- 開或關、為什麼——寫進紀錄

不同腫瘤，不同的回收行情

0.4-0.7 那條檢查線是 PBMC 的行情——換組織就要換數字

樣本	組織特性	web_summary 上的長相	判讀怎麼調
PBMC（對照）	懸浮細胞，不需解離	回收 0.4-0.7、膝蓋乾淨	標準行情直接用
乳癌（脂肪多）	脂肪細胞大而脆，解離時易破	回收偏低、ambient 偏高	回收預期下修，先查歷史批次
肝癌（纖維化）	基質緻密，解離要更強更久	回收低，組成偏向好解離的免疫細胞	組成偏差記進筆記，帶到下游
GBM（壞死核心）	活細胞少、ambient 濃	回收低、Fraction Reads in Cells 掉	預期值下修並記錄（前兩頁）

一句話總結

**count 產出的不是答案，是報告；
放行與否，由讀報告的你決定。**

警告、細胞數、knee 形狀、mapping——四關都過，才進下游。

自測 1

filtered 與 raw 矩陣的差別是什麼？

- A filtered 已做過基因過濾
- B filtered 只留 cell calling 判定為細胞的 barcode
- C filtered 已完成 normalization
- D 兩者相同，只是壓縮格式不同

答 B。兩個矩陣的基因列完全一樣，差在欄：raw 是 whitelist 全部 barcode（v3 約 680 萬），filtered 是 cell calling 的倖存者。沒有任何 normalization——那是 B6 的事。

自測 2

barcode rank plot 整條變成連續斜坡、沒有陡崖，最可能代表什麼？

- A 資料完全正常
- B 細胞與空滴的 UMI 分不開：低品質樣本、裂解或堵塞
- C 定序深度太深
- D 參考基因組版本錯誤

答 B。陡崖是「細胞遠比空滴多 RNA」的視覺表現；塌掉代表兩者混在一起——樣本裂解、輸入太少或流路堵塞。cell calling 在這種圖上切哪裡都是猜的。

自測 3

你的 web_summary：saturation 35%、median genes 2,100、目標是分群加註釋主要族群。要加測嗎？

- A 要，saturation 太低就是不及格
- B 先不用：median genes 已足以支撐分群註釋，記錄後往下做
- C 不能用，整批重做
- D 直接把 reads 數乘以三倍重新定序

答 B。saturation 不是考試分數。分群與主要族群註釋在 median genes 一兩千時就做得動；35% 只是說「還挖得到新分子」。把數字記進筆記，等問題升級到低表現基因時再回頭加測——同一個 library 可以直接補定序。

下集預告

B4：多樣本與多模態

一個樣本你會跑了。四個樣本呢——跑四次 count 再 aggr，還是一次 multi？選錯的代價是什麼？
（急著進 Seurat 的人可以先跳 B5：Cell Ranger 說的「細胞」，Seurat 可不一定承認。）