

B5 B 系列


讀入資料與 QC： 閾值到底怎麼定

用你這份資料的分布決定過濾線，而不是抄別人論文的數字。

約 40 分鐘 | 前置：B1（A 系列基礎） | 資料：PBMC 3k


同一份資料，兩套 QC 閾值

嚴格 QC → 5 群



模擬資料

寬鬆 QC → 7 群



多出來的「新群」其實是沒濾掉的壞細胞

左：嚴格閾值，5 群。右：寬鬆閾值，7 群。多出來的兩群是什麼？

本集的起點

QC 的每一條線， 都在決定你下游「看得到什麼」。

砍太鬆，垃圾變成「新發現」；砍太狠，稀有族群直接消失。兩邊都是災難。

這一集你會學到

- 1 從 10x 輸出建立 Seurat 物件，算出三大 QC 指標
- 2 用分布（小提琴圖、散點圖、MAD）為自己的資料定閾值，說得出理由
- 3 跑 DoubletFinder，把結果放進過濾決策


01

QC 要抓的是什麼

三種壞東西、三個指標，先建立對應關係


三種混進矩陣的壞東西

垂死／破損細胞




膜破了，胞質 RNA 漏出
粒線體 RNA 比例衝高

空滴與 ambient RNA



沒有細胞，只有背景 RNA
總量與基因數都極低


doublet



兩顆細胞進同一顆油滴
總量與基因數都偏高

它們都會拿到一個 barcode，在矩陣裡看起來就像「細胞」

三個指標，各自抓誰



三個指標，三種壞細胞——各自有對應的抓法

- nCount_RNA：每顆細胞的分子總數（UMI）
- nFeature_RNA：每顆細胞測到幾種基因
- percent.mt：粒線體基因的比例——細胞快死時它會衝高
- 低配對 → 空滴；雙高 → doublet；mt 高 → 垂死

本集核心觀念

**閾值是「你這份資料的性質」，
不是可以到處抄的常數。**

同一條 5% 的線，在 PBMC 是合理的，在心肌是災難。等一下會實際看到。

02

建立物件，算出指標

Read10X → CreateSeuratObject → PercentageFeatureSet

從 10x 輸出到 Seurat 物件

```
library(Seurat)
set.seed(1234) # 全系列固定，結果才能重現


pbmc.data <- Read10X(data.dir =
  "data/pbmc3k/filtered_gene_bc_matrices/hg19/")
pbmc <- CreateSeuratObject(counts = pbmc.data, project = "pbmc3k",
  min.cells = 3, min.features = 200)

pbmc
```

An object of class Seurat
13714 features across 2700 samples within 1 assay
Active assay: RNA (13714 features, 0 variable features)

Read10X 吃的是資料夾（三個檔案），不是單一檔案路徑

min.cells 與 min.features 在做什麼



min.cells = 3

只在 1-2 顆細胞出現的基因 → 刪掉這一行
(幾乎必是雜訊，留著只會拖慢後面每一步)

min.features = 200

只測到很少基因的細胞 → 刪掉這一欄
(多半是空滴或碎片，先粗篩一次)

這只是「建物件時的粗篩」，
真正的 QC 閾值等一下用分布來定。

- min.cells = 3：出現在少於 3 顆細胞的基因，整列刪掉
- min.features = 200：測到少於 200 個基因的細胞，整欄刪掉
- 這是建物件時的粗篩；真正的閾值等一下用分布決定

算出 percent.mt

```
pbm c[["percent.mt"]] <- PercentageFeatureSet(pbm c,  
                                              pattern = "^MT-")  
head(pbm c@meta.data, 3)
```

orig.ident	nCount_RNA	nFeature_RNA	percent.mt
AAACATACAACCAC -1	pbm c3k	2419	779 3.0177759
AAACATTGAGCTAC -1	pbm c3k	4903	1352 3.7935958
AAACATTGATCAGC -1	pbm c3k	3147	1129 0.8897363

人類粒線體基因叫 MT-xxx；小鼠是 mt-xxx，pattern 要改 "^mt-"

到這裡，你手上有什麼

一個矩陣



13,714 個基因 ×
2,700 顆細胞，存在
RNA assay 裡

一張 metadata 表



每顆細胞一行：
nCount、
nFeature、
percent.mt

還沒做任何判斷



指標算好了，但一顆
細胞都還沒濾——先
看分布

03

看分布，定閾值


先看再砍。順序不能反過來

三個指標的分布

```
VlnPlot(pbm c,  
        features = c("nFeature_RNA", "nCount_RNA", "percent.m t"),  
        ncol= 3)
```

這三張小提琴圖，是整集最重要的畫面

小提琴圖怎麼讀



模擬資料

主體是乾淨細胞；往下的尾巴是空滴與碎片，往上的離群是 doublet 與垂死細胞


兩張散點圖，交叉看

```
FeatureScatter(pbm c, feature1 = "nCount_RNA",  
               feature2 = "percent.m t")  
FeatureScatter(pbm c, feature1 = "nCount_RNA",  
               feature2 = "nFeature_RNA")
```


單一指標會誤判；兩兩配對看，三種壞細胞各佔一個角落

散點圖上的角落

nCount 對 percent.mt



nCount 對 nFeature



模擬資料

左：高 mt 的垂死細胞浮在上方。右：主帶沿對角線，左下是空滴、右上是 doublet 候選

兩種定閾值的方法

重點不是選哪派，是你能不能說出理由

固定閾值

看圖，手動畫線


- nFeature 200-2500、mt < 5% 這類
- 直覺、好溝通
- 但每份資料都得重新看一次

MAD

中位數 $\pm 3 \times \text{MAD}$

- 跟著分布走，對離群值穩健
- 可寫成程式，樣本多時特別好用
- 偏態指標記得先 log 再算

MAD 線跟著分布走



模擬資料

同一條規則，套到不同資料會給出不同的線——這正是它比抄 5% 好的地方

MAD 閾值，三行搞定

```
m.t <- pbmc.c$percent.m.t  
m.t.upper <- m.median(m.t) + 3 * m.ad(m.t) # m.ad() 已含 1.4826 校正  
m.t.upper
```

```
[1] 4.91
```

PBMC 3k 算出來剛好接近 5%——但那是算出來的，不是抄來的

寫進論文的方法段

**「細胞保留條件： nFeature 200-2500 、
percent.mt < 中位數 + 3×MAD （ =
4.9% ） 。」**

每一條線都有數字、有理由。審稿人問起來，你答得出「為什麼」。


動手過濾

```
pbm c <- subset(pbm c,  
               subset= nFeature_RNA > 200 &  
                     nFeature_RNA < 2500 &  
                     percent_m_t < m_t.upper)  
pbm c
```

An object of class Seurat
13714 features across 2638 samples within 1 assay

2700 → 2638 : 濾掉 62 顆。這個數字要記進分析筆記

每一步濾掉多少，都要留下紀錄



每一步濾掉多少要記下來——這一段要寫進論文的方法段

濾掉的比例異常高（>20-30%）時，先懷疑樣本或閾值，不要急著往下跑

04

Doublet：指標抓不到的那種

nCount 偏高只是「嫌疑」，要靠專門工具

兩種 doublet ， 難度天差地遠


異型 doublet (heterotypic)



兩種不同型的細胞黏在一起
profile 是 A + B 的混合

抓得到

同型 doublet (homotypic)



兩顆同型細胞
profile 就像一顆「特大號」細胞


幾乎抓不到

DoubletFinder 主要抓的是異型 doublet ； 同型的靠實驗設計（hashing）才防得住

演算法主要抓異型； 同型幾乎只能靠實驗設計（cell hashing）預防

DoubletFinder 的直覺

PC 空間



① 造假 doublet

隨機抽兩顆真細胞，把 profile 平均，
製造幾百顆「人工 doublet」丟回資料裡

② 看鄰居

每顆真細胞算 KNN 鄰居中
人工 doublet 的比例 (pANN)


③ 依預期率切線

上機越多細胞、doublet 率越高，
用查表的預期率決定要標掉幾顆

模擬資料

自己製造假 doublet，看誰跟它們當鄰居

要標掉幾顆？查表



預期率由上機細胞數決定，不是演算法自己知道的——這是你要提供的資訊

DoubletFinder：前置與 pK 掃描

```
# remotes::install_github("chris-mcginnis-ucsf/DoubletFinder")
library(DoubletFinder)
# 需要先跑完標準前處理——每一步 B6–B9 都會講透，這裡先照抄
pbmc <- NormalizeData(pbmc) |> FindVariableFeatures() |>
  ScaleData() |> RunPCA() |> RunUMAP(dims = 1:10)

sweep.res <- paramSweep(pbmc, PCs = 1:10, sct = FALSE)
sweep.stat <- summarizeSweep(sweep.res, GT = FALSE)
bcm.vn <- find.pK(sweep.stat) # 挑 BCmetric 最高的 pK
```

pK 是「鄰居範圍」的大小；用掃描選，不要用猜的

DoubletFinder：執行與結果

```
nExp <- round(0.023 * ncol(pbm c)) # ~2,600 顆 → 預期約 2.3%  
pbm c <- doubletFinder(pbm c, PCs = 1:10, pN = 0.25,  
                        pK = 0.09, nExp = nExp)  
table(pbm c$DF.classifications_0.25_0.09_61)
```

```
DoubletSinglet  
61    2577
```

結果存在 metadata 的新欄位裡；欄名帶著參數，方便之後對照

doublet 在圖上長什麼樣

doublet (紅) 常落在兩群之間，像一座假橋



示意圖

介於兩群之間的「橋」，下游會被誤讀成轉分化或中間態

抓到之後：丟掉還是標記？

兩種都有人做；重點是「做了什麼要說清楚」

直接移除

subset 掉 Doublet

- 下游乾淨，不用再操心
- 多數論文的做法
- 預期率抓錯會誤殺好細胞

標記觀察

留著，但標記起來

- 分群後檢查：某群全是 doublet → 整群可疑
- 適合第一次跑、還在探索的階段
- 最終分析前仍建議移除

05

踩雷區

三個雷，每一個都實際跑給你看

雷一： percent.mt 一律砍 5%

雷是什麼

不看組織、不看分布，直接套用教學範例裡的 5%。




為什麼會踩

教學範例用的是 PBMC，5% 剛好合理；你的組織不一定是。

踩了會怎樣

高代謝組織（心肌、腫瘤、肝）整型細胞被砍光，下游根本看不到它們。

同一條 5% 線，三種組織



模擬資料

percent.mt 的「正常值」是組織的性質。先看分布，再定線

雷二：先過濾，再看分布

雷是什麼

拿到資料先照抄一組閾值砍下去，之後才畫 VlnPlot。



為什麼會踩


順序感覺無所謂——反正都會看圖。

踩了會怎樣


分布已被截斷，尾巴消失。你再也無法判斷原始的線該畫哪，錯了也看不出來。

截斷之後，就回不去了

先看分布：尾巴看得見，知道線該畫哪



先砍再看：分布被切平，第二輪閾值全憑想像



模擬資料

原始物件在過濾前先存一份：`saveRDS(pbmc, "output/pbmc_raw.rds")`

雷三： QC 做一輪就定案

雷是什麼

過濾完就再也不回頭，直接一路跑到 DE 。




為什麼會踩

流程圖把 QC 畫在第一步，看起來像過了就過了。

踩了會怎樣

分群後才現形的殘渣群（高 mt、低 nFeature、壓力基因 marker）被當成新細胞型別寫進結果。

QC 是循環，不是關卡



QC 不是一次性的關卡，是「過濾 → 檢查 → 回頭」的循環

分群後回頭看每群的 QC 指標—— B8 會實際做這個檢查

踩雷區小結

**每一個閾值都是一個假設。
記錄它，並且準備好回頭改它。**

「我用了什麼線、為什麼、濾掉多少」——這三件事寫得出來，QC 就及格了。


05+

複雜樣本策略室


同一步 QC，換成腫瘤樣本——決策哪裡不同、為什麼

腫瘤的 QC 分布長怎樣

GBM：主體高+第二個峰



肝癌：基線整體上移




同一條 MAD 規則，兩種腫瘤各得其所——照抄 5% 則兩邊都是災難

模擬資料

高 mt 的惡性細胞是真細胞：GBM 的線落在兩峰之間，肝癌整條基線上移——MAD 兩邊都跟得上

per-sample QC：閾值逐樣本定



模擬資料

共用金線：對 A 太鬆、砍進 C 的主體。紅線 = 逐樣本 median + 3 × MAD：規則共用，數字各自算

多樣本腫瘤研究的標配：共用的是「規則」，不是「數字」——每個樣本各自算，各自記錄

解離壓力簽名： FOS / JUN / HSP

實體腫瘤解離又久又粗暴——細胞在管子裡就開始緊急轉錄

辨識



把 FOS、JUN、熱休克蛋白這組立即早期基因打成一個分數，畫在 UMAP 上

判讀



散在各群一點點是常態；某一群整群靠它定義，那是解離壓力群，不是新的細胞狀態

處置



解讀時把這組基因排除（B13 再回來講），或實驗端改冷解離降低誘導

SoupX：腫瘤的環境 RNA 特別濃

用空滴估「湯」的組成，算出每顆細胞的污染比例 ρ ，再決定扣不扣

$\rho < 5\%$

可以略過

- 乾淨樣本常見；PBMC 教學資料多在這區
- 校正對主要結論影響不大
- 但 ρ 要算出來、寫下來才算數

$\rho > 10\%$

建議校正

- 壞死多、解離久的腫瘤常見
- 不扣的話每一群都「表現一點」別群的 marker，註釋很痛苦
- 需要 raw + filtered 兩個矩陣——自己的資料記得保留 raw

snRNA-seq：QC 閾值全套要換

凍存腫瘤常用細胞核——材料換了，QC 的邏輯跟著反轉

指標	scRNA-seq（全細胞）	snRNA-seq（細胞核）
percent.mt	基線依組織而定，MAD 定上限	接近零；偏高＝胞質污染，線要畫得極低
intron 訊號	比例低	比例高是特徵不是警訊；計數要含 intron（B3）
nCount / nFeature	整顆細胞的 RNA	只有核內 RNA，整體偏低——下限也要下修
結論	教學範例的數字只適用它自己	scRNA 的閾值一條都不能沿用

本集 checklist



建物件時 min.cells / min.features 只做粗篩



三大指標的分布都畫出來看過，再定閾值



閾值有理由：固定值或 MAD，寫進方法段



每一步濾掉幾顆細胞都有記錄



跑過 doublet 偵測，結果放進 metadata



分群後回頭檢查有沒有 QC 殘渣群

六格全勾，才進 B6

一句話總結

**先看分布，再定閾值；
定了閾值，記下理由。**

QC 沒有標準答案，但有標準流程。

自測 1

percent.mt 衝高，主要抓的是哪一種壞細胞？

- A 空滴與碎片
- B 垂死或膜破損的細胞
- C doublet
- D 紅血球污染

答 B。細胞快死時膜先漏，胞質 RNA 流失，而粒線體 RNA 相對留下——比例於是衝高。空滴靠 nCount / nFeature 雙低抓，doublet 靠雙高加專門工具。

自測 2

nCount 與 nFeature 都異常偏高的一小撮細胞，最可能是什麼？

A 定序深度比較深的正常細胞

B 空滴

C doublet 候選

D 粒線體污染

答 C。兩顆細胞的 RNA 疊在一起，總量與基因種類都偏高。深度差異會讓 nCount 變高，但 nFeature 會飽和，不會同步衝高到離群。

自測 3

你拿到心肌組織的資料， **percent.mt** 中位數是 **18%**。閾值該怎麼定？

- A 照慣例砍 5%
- B 用 $\text{median} + 3 \times \text{MAD}$ 或組織特異上限，並記錄理由
- C **percent.mt** 不適用，直接跳過
- D 先砍 5% 再看分布

答 B。心肌本來就高粒線體含量，5% 會砍掉大多數健康細胞。跟著這份資料的分布走（例如 $\text{median} + 3 \times \text{MAD}$ ），把算出來的數字與理由寫進方法段。

下集預告

B6 : Normalization、HVG、Scaling

細胞乾淨了，但每顆細胞的總量差了十倍——直接比較，等於在比定序深度。

兩條路線：LogNormalize 與 SCTransform，我們各跑一次，看下游到底差在哪。