

B6 B 系列

# Normalization、HVG、 Scaling： 兩條路線實測

LogNormalize 與 SCTransform 各跑一次，比較下游差異，知道何時用哪個。

約 38 分鐘 | 前置：B5 | 資料：PBMC 3k (QC 完成版)

# 同一份資料，兩條 normalization 路線

路線 A：LogNormalize



路線 B：SCTransform



同一份  
資料



模擬資料

同一批細胞、同一個 seed——群的形狀不一樣。哪一張才是「對」的？

左：LogNormalize。右：SCTransform。群的形狀不一樣——哪張「對」？

本集的起點

**「哪張對？」——這個問題不成立。  
兩張都對，它們回答的是不同的模型。**

你要學的不是站隊，是知道兩條路線各在做什麼、下游差在哪、你的資料該走哪條。

# 這一集你會學到


- 1 說出 NormalizeData → FindVariableFeatures → ScaleData 三步各自解決什麼問題
- 2 跑 SCTransform，說出它替代了哪三步、原理差在哪
- 3 用同一份資料比較兩條路線的 HVG 重疊與 UMAP，做出有理由的選擇

# 01

## 三個問題，三步解


寫程式之前，先知道每一步在替誰收拾殘局

# 問題一：深度不同，counts 不能直接比



真資料裡，細胞之間的 nCount 可以差十倍——直接比 counts，等於在比定序深度

# 三個問題、三步解



每一步都吃上一步的輸出：counts → data → HVG 名單 → scale.data → PCA (B7)

每一步都吃上一步的輸出——順序不能換，也不能跳

## 本集核心觀念

**這三步不產生任何生物學結論，  
但下游每一個結論都建在它們上面。**

PCA 吃 scale.data、分群吃 PCA、註釋吃分群。地基歪一度，頂樓歪十度。

# 02

## NormalizeData : 把深度除掉

CP10K + log1p , 兩個動作一行完成

# 承接 B5：讀回 QC 完成的物件

```
library(Seurat)
set.seed(1234)           # 全系列固定

pbm c <- readRDS("output/pbm c_b05_qc.rds")
pbm c
```

An object of class Seurat  
13714 features across 2638 samples within 1 assay  
Active assay: RNA (13714 features, 0 variable features)  
1 layer present: counts

2,638 顆乾淨細胞； layer 只有 counts—— 正是本集的原料

# NormalizeData：一行、兩個動作

```
pbm c <- NormalizeData(pbm c,  
  normalization.method = "LogNormalize",  
  scale.factor = 10000)
```

Normalizing layer: counts

Performing log-normalization

0% 10 20 30 40 50 60 70 80 90 100%

[----|----|----|----|----|----|----|----|----|----|]

兩個參數都是預設值；寫出來是為了讓你知道它們存在、以後能改

# 為什麼除完總量還要取 log

log 之前：右偏，離群值主宰




長尾巴：少數細胞的大數值決定一切距離

CP10K 表現值

log1p



log 之後：攤開，倍數變加法



「+1」讓 0 有地方住：  
 $\log_{1p}(0) = 0$

$\log_{1p}(\text{CP10K})$

模擬資料

log 把「倍數」變「加法」、壓住離群值； +1 讓零有地方住

# LayerData：前後對比

```
LayerData(pbm c, layer= "counts")["LYZ",1:3] # 原始  
LayerData(pbm c, layer= "data")["LYZ",1:3] # normalize 後
```

```
AAACATACAACCAC -1 AAACATTGAGCTAC -1 AAACATTGATCAGC -1  
      21          1          42  
AAACATACAACCAC -1 AAACATTGAGCTAC -1 AAACATTGATCAGC -1  
      4.475061      1.112256      4.901619
```

counts 原封不動地留著—— B12 的 DE 還要用它。data 是新增的 layer

# 這一節做了什麼

## counts 還在



原始計數永遠不動，  
後面的 DE 與檢查都  
靠它

## data 誕生



$\log_{1p}(\text{CP10K})$ ：跨  
細胞可比較的表現值

## 下游誰在吃它



FeaturePlot、  
VlnPlot、  
FindMarkers 預設  
都讀 data

# 03

## FindVariableFeatures：挑出會說話的基因

一萬多個基因，多數只有雜訊


# vst 排名，取前 2000

```
pbm c <- FindVariableFeatures(pbm c,  
  selection.m e t h o d = "vst", n f e a t u r e s = 2000)  
  
top10 <- head (VariableFeatures (pbm c), 10)  
top10
```

```
[1] "PPBP" "LYZ" "S100A9" "IGLL5" "GNLY"  
[6] "FTL" "PF4" "FTH1" "GNG11" "S100A8"
```

PPBP 是血小板 marker、LYZ 是單核球 marker——名單本身就有生物學

# vst 在做什麼： mean-variance 曲線



灰點：貼著曲線 = 變異可由技術雜訊解釋，不挑

紅點：高於曲線 = 比「應有的」更變異 → HVG 候選


vst 的排名 = 離曲線的距離，跟表現高低脫鉤

模擬資料

比「這個平均值該有的變異」更變異的基因，才是 HVG—— 高表現不等於高資訊

# 2000 這個數字哪來的

HVG = 200



稀有亞型（紅）被吞進母群


紅點：占全體 2% 的稀有亞型

HVG = 2000



稀有亞型獨立成群

HVG = 5000



跟 2000 幾乎一樣，只是慢

模擬資料

太少會丟掉稀有訊號；太多只是變慢。2000 是「夠寬」的經驗值

什麼時候調 `nfeatures`

**預設 2000 起手；  
找稀有族群時往上調，並記下理由。**

往上調（3000-5000）的代價只是慢一點；往下調的代價可能是一整個族群。

# 04

## ScaleData : 把量級拉平

z-score + clip , 替 PCA 鋪路

# ScaleData : 預設只處理 HVG


```
pbm.c <- ScaleData(pbm.c) # 預設 features = HVG 那 2000 個  
LayerData(pbm.c, layer = "scale.data")["LYZ", 1:3]
```

```
AAACATACAACCAC -1 AAACATTGAGCTAC -1 AAACATTGATCAGC -1  
0.9438414      -1.5018971      1.2110247
```


要全基因都 scale (畫 heatmap 用) : `features = rownames(pbm.c)`

# z-score 與 clip 各做什麼

scale 前：量級差 7 倍



scale 後：平均 0、標準差 1



z-score 讓每個基因平等發言；clip ( $\pm 10$ ) 讓單一離群細胞不能綁架一個 PC

# vars.to.regress 的爭論

把 percent.mt、cell cycle 「回歸掉」——用還是不用？

不用（本系列）

## 預設不 regress

- QC 已把高 mt 細胞濾掉，殘餘影響有限
- transparent：資料沒被額外改動
- 速度快，結果好解釋

要用就有理由

## 確認干擾真的存在再用

- 分群後看到「cell cycle 群」「mt 梯度」再回頭 regress
- 每 regress 一個變數，都寫進方法段
- regress 掉的訊號永遠回不來——先確定它是雜訊

# 三個 layer 到齊了

## counts



原始 UMI 計數：  
DE ( B12 ) 與一切  
檢查的根據地

## data



$\log_{10}(\text{CP10K})$ ：畫  
圖與 marker 檢定  
讀這裡

## scale.data



z-score 後的  
HVG：只給 PCA  
吃 ( B7 )

# 05

## SCTransform：三步合一

另一條路線：一行流


# SCTransform：一行替代三步

```
# install.packages("sctransform") # 第一次需要  
pbm c.sct <- SCTransform (pbm c, vst.flavor = "v2",  
                           verbose = FALSE)  
pbm c.sct
```

An object of class Seurat  
26363 features across 2638 samples within 2 assays  
Active assay: SCT (12649 features, 3000 variable features)  
3 layers present: counts, data, scale.data  
1 other assay present: RNA

多了一個 SCT assay，自帶三個 layer 與 3000 個 HVG；RNA assay 原封不動

# residuals 是什麼：白話版



- ✓ 每個基因配一條「深度 → 預期」曲線
- ✓ v2：參數跨基因共享（regularization），低表現基因不會亂抖
- ✓ 殘差 = (實際 - 預期) ÷ 預期波動
- ➔ 一個動作同時完成：去深度 + 穩變異 = 三步合一

模擬資料

每個基因配一條「深度 → 預期」曲線；殘差 = 你比預期多或少幾個標準差（推導見 C2）

# SCT 物件導覽: data 已經 log 過

```
DefaultAssay(pbm c.sct) # 後續操作都在 SCT assay  
head(VariableFeatures(pbm c.sct), 3)
```

```
LayerData(pbm c.sct, layer = "data")["LYZ", 1:3]
```

```
[1] "SCT"  
[1] "GNLY" "LYZ" "S100A9"  
AAACATACAACCAC -1 AAACATTGAGCTAC -1 AAACATTGATCAGC -1  
3.135494 0.693147 3.401197
```

`data = log1p( 校正後 counts ) ; scale.data = residuals`。記住這句，踩雷區會回收

這一節的一句話

**SCT = normalization + HVG +  
scaling**

**一次完成，輸出住在自己的 assay 裡。**

代價：黑盒子多一層、物件大一倍、DE 前要切回 RNA assay（B12 會講）。

# 06

## 兩條路線對決

同一份資料，三個檢查點


# 檢查點一： HVG 名單重疊多少

```
hvg.log <- VariableFeatures(pbm c)          # 2000 個  
hvg.sct <- head(VariableFeatures(pbm c.sct), 2000)  
  
length(intersect(hvg.log, hvg.sct))
```

```
[1] 1245
```


約六成重疊：核心共識穩固，邊緣名單各有意見

# 重疊率怎麼讀



重疊率 60%：共識高，但不是同一份名單

前段排序分歧不小；名單拉長，共識才收斂



模擬資料

強訊號基因兩邊都抓得到；分歧集中在排序與邊緣——這是「模型不同」的正常結果

## 檢查點二： UMAP 並排

```
pbm c    <- RunPCA(pbm c)    |> RunUMAP(dim s = 1:10)
pbm c.sct<- RunPCA(pbm c.sct)|> RunUMAP(dim s = 1:10)

library(patchwork)
p1 <- DimPlot(pbm c)    + ggtitle("LogNorm alize")
p2 <- DimPlot(pbm c.sct)+ ggtitle("SCTransform ")
p1 + p2
```

PCA 的參數 B7 才講，這裡先用預設把兩張圖跑出來

# 檢查點三：下游穩不穩

兩條路線在 PBMC 3k 上的實測結論

一致的

## 主要結構完全一致


- T / B / NK / 單核球四大陣營都在
- 經典 marker ( CD3E 、 MS4A1 、 LYZ ) 兩邊都清楚
- 群的成員高度重疊

不同的

## 形狀、間距、細節

- 群的形狀與相對位置不同——這不是誰錯
- SCT 對低深度細胞的位置更穩定
- 邊緣小群的切分粒度略有差異

# 怎麼選：一張決策圖



常規分析 LogNormalize 起手；深度差異大、追稀有族群、整合前處理再考慮 SCT

本系列的選擇

**B7 到 B10 用 LogNormalize 這條路線。  
不是它比較「對」，是它透明、好教、生態最廣。**

換路線永遠可以：重跑一次下游就好。怕的不是選錯，是換了路線卻只重跑一半。

# 07

## 踩雷區

三個雷，每一個都實際跑給你看

# 雷一：跳過 normalization 直接 PCA

## 雷是什麼

counts 矩陣直接丟進 ScaleData + RunPCA，跳過 NormalizeData。



## 為什麼會踩


流程跑得動、不報錯，圖也長得出來——看起來沒事。

## 踩了會怎樣

PC1 變成定序深度軸：下游分群分的是「測得深不深」，不是細胞型別。


# 實跑： PC1 對 nCount

跳過 normalization：PC1 就是深度



顏色 = 定序深度 (淺 → 深)  
 **$\text{cor}(\text{PC1}, \text{nCount}) = 1.00$**

正常三步之後：深度退場



顏色 = 定序深度 (淺 → 深)  
 **$\text{cor}(\text{PC1}, \text{nCount}) = 0.00$**

模擬資料

一行檢查：`cor(pc1, pbmc$nCount_RNA)`—— 接近 1 就是中招

## 雷二：HVG 只抓 200 個

雷是什麼

覺得 2000 太多，把 nfeatures 砍到 200 「抓重點」。



為什麼會踩


前 200 名幾乎都是大族群的強 marker，看起來已經夠用。

踩了會怎樣

稀有亞型的 marker 排不進前 200，它們在 PC 空間失去座標，被吞進母群。


# 實跑：稀有亞型消失

HVG = 200




紅點散進大群，看不見了

HVG = 2000



紅點聚成自己的群

稀有細胞的鄰居  
還有多少是自己人



模擬資料

HVG=200 時鄰居純度只剩 5%—— 這個族群等於不存在； 2000 時完整回歸

# 雷三： SCT 之後又手動 log

雷是什麼

對 SCT 的 data layer 再跑一次 NormalizeData 或 log1p()。



為什麼會踩


肌肉記憶：「拿到表現值，先 log 再說」。

踩了會怎樣

雙重 log 把對比壓扁：陽性與陰性族群的差距塌掉，FeaturePlot 整張灰掉。

# 實跑：雙重轉換的分布


SCT 的 data：已經是 log 空間



模擬資料

再 log 一次：對比塌掉

多餘的  
log1p  
→



陽性 vs 陰性的差距：2.6 → 1.3，FeaturePlot 整張灰掉

記法：SCT 的 data 「出廠即 log」；LogNormalize 的 data 也是。永遠不要 log 第二次

### 踩雷區小結

**這三個雷都不會報錯。  
抓它們的是你的檢查，不是程式。**

一行保命：`cor(Embeddings(pbmc,"pca")[,1], pbmc$nCount_RNA)`。每次 PCA 之後都跑。


# 5+

## 複雜樣本策略室

標準流程走完了——現在想像你手上不是 PBMC，是一顆腫瘤

# 惡性細胞的 library size：假設被挑戰

同一顆腫瘤裡的 nCount：兩個族群、兩個量級



示意分布

## 模型的假設

LogNormalize 與 SCT 都假設：  
總 RNA 量 = 技術效應，不是生物學

## 腫瘤的現實

惡性細胞大、常多倍體、轉錄整體上調  
——被除掉的「深度」裡混著生物學

## 本頁決策

$\text{cor}(\text{PC1}, \text{nCount})$  0.3–0.5 在腫瘤常見：  
看 PC1 載荷是不是生物學，> 0.5 才回頭查

normalization 假設「總 RNA 量不是生物學」——惡性細胞恰好違反它。判讀靠載荷，不是靠係數

# 週期分數要不要回歸：一棵決策樹

前處理時先算 CellCycleScoring——只算分數，先不 regress



分群後，檢查兩件事

- ① DimPlot 按 Phase 上色：S / G2M 只集中在一小群嗎？
- ② PC1-PC5 的載荷：有沒有 MKI67、TOP2A 這類週期基因？

兩項都乾淨

不 regress——把那一群標成「增殖中的 X」  
在腫瘤，增殖本身常是訊號：  
分級、侵襲性、治療反應都看它

每個型別都被切成兩半

週期綁架了分群 → regress S.Score 與 G2M.Score  
或只 regress 「S - G2M」的差，  
保留「在不在分裂」這個資訊

regress 掉的訊號永遠回不來——先想研究問題，再動 vars.to.regress；動了就寫進方法段

增殖在腫瘤是訊號不是雜訊：動 vars.to.regress 之前，先想研究問題

# SCT 在腫瘤資料的取捨

深度差異大讓 SCT 更有理由上場——但紅線也更多

## 加分的地方

### 腫瘤是「深度差異大」的常客

- 惡性 vs T 細胞的 RNA 總量常差十倍：深度除得更乾淨
- HVG 挑得更穩；v2 對深度差大的資料特別好
- 低深度細胞與弱訊號的保留通常更好

## 紅線

### 腫瘤下游一堆分析只吃整數 counts

- DE (B12)、inferCNV (B16)、pseudobulk：全部回 RNA assay 的 counts
- FindMarkers 之前要先 PrepSCTFindMarkers
- 多樣本整合：每個樣本各自跑 SCT (B11)


# HVG 被病人效應綁架： per-sample 聯集

## 現象



多病人腫瘤合併挑  
HVG，名單前段被  
病人間差異佔據

## 為什麼



惡性細胞按病人分群：  
每個病人的 CNV 與  
基因體都不同

## 策略



每個樣本各挑  
HVG，再取聯集／  
排名共識  
(SelectIntegrationFeatures 的邏輯，  
B11 實作)

# 本集 checklist



任何跨細胞比較之前，先 normalize



一行檢查： $\text{cor}(\text{PC1}, \text{nCount})$  不該接近 1



HVG 用 vst 挑 2000；要調，理由寫下來



說得出 counts / data / scale.data 各是什麼



SCT 的 data 已 log 過，絕不再 log



換路線 = 下游全部重跑 + 記錄理由

六格全勾，才進 B7

一句話總結

**三步解三個問題：深度、雜訊、量級。  
兩條路線都合法，選了就整條走完。**

counts / data / scale.data 各是什麼、誰在吃它——說得出這句，本集就及格。

# 自測 1

**NormalizeData** 的預設動作是哪兩個？

- A z-score 加 clip
- B 除以細胞總量乘一萬，再取  $\log_{10}$
- C 挑 2000 個高變異基因
- D Pearson residuals 加 regularization

**答** B。LogNormalize = CP10K +  $\log_{10}$ ：先把深度除掉變成比例，再用  $\log$  把倍數變加法、壓住離群值。A 是 ScaleData、C 是 FindVariableFeatures、D 是 SCTransform 的事。

## 自測 2

**scale.data** 這個 layer，下游主要是誰在吃？

- A FeaturePlot 與 VlnPlot
- B FindMarkers 的差異檢定
- C RunPCA
- D saveRDS

**答** C。scale.data 是專門為 PCA 準備的 z-score 矩陣。畫圖與 marker 檢定預設讀 data；DE（B12）要回 counts。三個 layer 各有各的客人。

## 自測 3

你跑完 SCTransform，接著想畫 FeaturePlot。需要先 log 一次表現值嗎？

- A 要，表現值一律先 log
- B 不要，SCT 的 data 已是 log 空間，再 log 會壓扁對比
- C 看基因而定
- D 要，但要用 log2 不是 log1p

**答** B。SCT 的 data layer 是 log1p(校正後 counts)，出廠即 log。再 log 一次就是雷三：陽性陰性差距塌掉、整張圖灰掉。LogNormalize 的 data 同理。

下集預告

## B7：PCA 與維度選擇

資料整形完畢：兩萬個基因，即將被壓成幾十個數字。  
但「幾十」到底是幾？取 10 還是 30，圖會差多少？——答案可能比你想的寬容。