

B7 B 系列


PCA 與維度選擇： 到底取幾個 PC

三種方法決定 n_{PC} —— 並且知道這個決定，其實比你想的寬容。

約 32 分鐘 | 前置：B6 | 資料：PBMC 3k

同一份資料，只改 nPC

nPC = 5




糊掉：兩個亞群黏在一起

nPC = 10



結構完整

nPC = 30



跟 nPC=10 幾乎一樣

同一份資料、同一條流程，只改 nPC——為什麼 10 和 30 幾乎一樣？

模擬資料

nPC = 5 糊掉、10 與 30 幾乎一樣。為什麼「取多一點」通常比較安全？

本集的起點

**nPC 取太少，資訊永遠進不了下游；
取多，只是多帶一點雜訊。**

這個不對稱，是本集所有判斷的底層邏輯。三種方法都會回到它。

這一集你會學到




- 1 跑 RunPCA，看懂它的三種輸出：loadings、散點、DimHeatmap
- 2 用 ElbowPlot + 量化 cutoff + 穩定度掃描三法決定 nPC
- 3 說出取太少與取太多各會發生什麼，並用一行檢查防住兩個雷

01

為什麼要降維

兩萬個座標軸，大部分是雜訊——先建立直覺再動手


雜訊平均掉，訊號才浮出來



單一基因分不開的兩群，在上千個基因的加權和裡分得開——雜訊互相抵消（推導見 C4）

一個 PC = 一組基因的加權組合

PC1 的 loadings (每個基因一個權重)



一顆細胞的 PC1 分數

$$= 0.24 \times \text{CST3} + 0.21 \times \text{TYROBP} + \dots \\ - 0.20 \times \text{LTB} - 0.18 \times \text{IL32} - \dots$$

一組「一起變動」的基因＝一個表現程式。
權重同號的基因傾向在同一群細胞裡一起開。

13,714 個基因 → 50 個 PC：座標換掉，資訊還在

每個基因一個權重（loading）；一起變動的基因＝一個「表現程式」

本集核心觀念

PCA 只是換座標： 從兩萬個基因，換成五十個表現程式。

沒有資訊被發明出來，只是按「解釋變異的多少」重新排隊。取幾個，才是你要做的決定。

02

RunPCA 與輸出導覽

一行程式碼，三種看結果的方式

承接 B6 ， 跑 PCA

```
library(Seurat)
set.seed(1234)

pbm c <- readRDS("output/pbm c_b06_norm.rds") # B6 的產物
# 沒跑 B6 ? 從 B5 起手，重跑 normalization 三行即可：
# pbm c <- readRDS("output/pbm c_b05_qc.rds") |> NormalizeData() |>
#       FindVariableFeatures() |> ScaleData()

pbm c <- RunPCA(pbm c, features = VariableFeatures(object = pbm c))
```

features 指定 2000 個 HVG ; npcs 預設 50——先多算存著，取幾個是下游的事

輸出一：每個 PC 的配方表

```
print(pbm c[["pca"]], dim s = 1:5, nfeatures = 5)
```

PC_1

Positive: CST3, TYROBP, LST1, AIF1, FTL

Negative: MALAT1, LTB, IL32, IL7R, CD2

PC_2

Positive: CD79A, MS4A1, TCL1A, HLA-DQA1, HLA-DQB1

Negative: NKG7, PRF1, CST7, GZMB, GZMA

(PC_3 – PC_5 略)

PC1 正端是骨髓系 marker、負端是淋巴系——第一個 PC 抓的是資料裡最大的一道分界


輸出二與三：畫出來看

```
# loadings 的圖版：正負兩端的 top 基因  
VizDim Loadings(pbm c, dims = 1:2, reduction = "pca")  
  
# 細胞在 PC1 x PC2 平面上的位置  
DimPlot(pbm c, reduction = "pca") + NoLegend()
```

reduction 參數指定畫哪個空間；之後 UMAP、分群都用同一套函式


PC1 × PC2：先上型別，再上深度

上色：細胞型別



PC1 / PC2 抓的是最大的兩個型別差異

上色：定序深度 (nCount)



B6 的 normalization 做對了，深度就不該成為某個 PC 的軸

模擬資料

左：前兩個 PC 抓最大的型別差異。右：深度應該混在各群裡，不該自成一軸

一行檢查： PC1 是不是深度軸

```
cor(pbm c$nCount_RNA, Em beddings(pbm c, "pca")[, 1])
```

```
# 順手看 PC1 的 top 20 loadings 裡核糖體基因佔多少  
top.pc1 <- nam es(sort(abs(Loadings(pbm c, "pca")[, 1]),  
                        decreasing = TRUE))[1:20]  
m ean(grep l("^ RP[LS]", top.pc1))
```

```
[1] 0.11
```

```
[1] 0.05
```

相關低、核糖體佔比低 → PC1 是生物學。這兩行是踩雷區雷二的疫苗

到這裡，你手上有什麼

一個 pca reduction



每顆細胞 50 個新座標，存在物件的 reductions 裡

一疊配方表



每個 PC 的 loadings：哪些基因、往哪個方向

一個待決定的數字



下游要用前幾個 PC？這是本集剩下的全部問題

03

DimHeatmap：逐 PC 看訊號衰減

訊號不是突然消失，是逐漸淡出


每個 PC 一張極端細胞熱圖

```
# 單看 PC1：分數最極端的 500 顆細胞 x top loading 基因  
DimHeatmap(pbm c, dims = 1, cells = 500, balanced = TRUE)  
  
# 一次看前 15 個，衰減的過程一目瞭然  
DimHeatmap(pbm c, dims = 1:15, cells = 500, balanced = TRUE)
```

balanced = TRUE：正負兩端各取一半，兩個方向的程式都看得到


從區塊分明到鹽粒雜訊

PC 1




區塊分明：強訊號

PC 5




還有結構

PC 7



弱，但還是訊號——
亞群就住在這裡

PC 15



鹽粒雜訊：沒訊號了

列＝該 PC 的前幾名基因；欄＝分數最極端的細胞。訊號隨 PC 往後逐漸變成雜訊

模擬資料

弱訊號不等於沒訊號——亞群差異常常就住在中段那些「弱但有結構」的 PC 裡

04

ElbowPlot 與量化 cutoff


先目測拐點，再算出一個能寫進方法段的數字

方法一： ElbowPlot

```
ElbowPlot(pbm c, ndim s = 50)
```

y 軸是每個 PC 的標準差； ndims 預設只畫 20，改 50 才看得到整條尾巴

拐點怎麼讀



模擬資料

拐點是一個「區間」不是一個點——你說 7 我說 12，都是可以辯護的答案

方法二：把拐點變成數字

```
pct <- pbm c[["pca"]]/stdev / sum (pbm c[["pca"]]/stdev) * 100
cum u <- cum sum (pct)


co1 <- which(cum u > 90 & pct < 5)[1] # 累積 90%、單 PC < 5%
co2 <- sort(which(diff(pct) < -0.1), decreasing = TRUE)[1] + 1
c(cum u %>% 90 = co1, drop0.1 = co2)
```

cum u %>% 90	drop0.1
44	13


累積 90% 給保守的上限；「相鄰差 < 0.1%」抓曲線變平的位置，比較接近目測拐點

兩個量化 cutoff 在圖上的位置

每個 PC 各解釋多少變異



累積起來看：cutoff 有數字可寫



模擬資料

有數字，審稿人就無話可說——但數字是輔助，不是聖旨

寫進論文的方法段

**「取前 10 個 PC（ElbowPlot 拐點 7-12；
相鄰變異差 $<0.1\%$ 落在 PC 13）。」**

一句話、兩個依據。比「we used 10 PCs」有底氣得多。

05

方法三：穩定度掃描

不確定就多跑幾個 nPC，看下游動不動

nPC = 5 到 30，各跑一次下游

```
for (d in c(5, 10, 15, 20, 30)) {  
  pbm c <- FindNeighbors(pbm c, dims = 1:d, verbose = FALSE)  
  pbm c <- FindClusters(pbm c, resolution = 0.5, verbose = FALSE)  
  pbm c@meta.data[[paste0("npc", d)]] <- Idents(pbm c)  
}  
sapply(pbm c@meta.data[paste0("npc", c(5, 10, 15, 20, 30))],  
       \ (x) length(unique(x)))
```

```
npc5 npc10 npc15 npc20 npc30  
7    9    9    9    9
```

FindNeighbors / FindClusters 是 B8 的主角，今天先當黑盒子用； dims 是唯一要動的參數

成員有沒有跟著變？ 交叉表


```
table(npc10 = pbm c$npc10, npc30 = pbm c$npc30)
```

```
      npc30  
npc10 0  1  2  3  4  
0 684  0  0  0  0  
1  0 481  0  0  0  
2  0  0 476  0  0  
3  0  0  0 344  0
```

(其餘列略：對角線之外幾乎全為 0)

對角線乾淨 = nPC 10 與 30 給出幾乎同一套分群。跨 run 對照永遠用交叉表，不要比編號

穩定度曲線：平原上取哪個都對



模擬資料 · 分群實跑 (Ward, k=7)

掉出平原 (nPC 太少) 分群才會亂動——這就是「這個決定很寬容」的證據

JackStraw 去哪了？

老教學都有它，v5 官方流程卻拿掉了

JackStraw (歷史)

打亂資料，檢定真 PC

- 統計上優雅：每個 PC 一個 p 值
- 慢，大資料上幾乎每個 PC 都「顯著」
- SCTransform 流程不支援

v5 現況

ElbowPlot + 經驗 + 穩定度

- 快，夠用：拐點區間 + 量化 cutoff
- 結論寬容：平原上取哪個都行
- 不確定時用掃描直接看下游

本集定案

**PBMC 3k：三法同指 8-12，
定 nPC = 10，理由記進筆記。**

複雜組織（腫瘤、發育）拐點更晚、亞群更多——往 20-30 取。B8 的 dims = 1:10
就從這裡來。

06

踩雷區

兩個雷，都實際跑給你看

雷一： nPC 抓太少

雷是什麼

看到 ElbowPlot 前五個 PC 最壯觀，就取 `dims = 1:5` 往下跑。



為什麼會踩


「主要變異都在前面」聽起來很合理；而且少算一點，跑得比較快。

踩了會怎樣


住在 PC 6-9 的亞群差異從此進不了下游：兩個亞群合併成一群，分群、UMAP、註釋全部看不到它。

nPC = 5 : 亞群就地消失

nPC = 5 : 亞群 B1、B2 合併成一坨



nPC = 20 : 兩個亞群分開



亞群差異住在 PC 6-9 ; nPC=5 根本沒把它帶進來，下游永遠看不到

灰色 = 其他細胞型別 (實跑模擬資料)

一行檢查：你選的 nPC 在 ElbowPlot 上還在陡坡，就不要停在那裡

雷二：把 PC1 當生物學

雷是什麼

看到 PC1 把細胞排成一條梯度，就開始詮釋：「這是分化軌跡！」



為什麼會踩


PCA 忠實地抓最大變異——但最大變異不保證是生物學，技術性變異一樣被抓。

踩了會怎樣

normalization 沒做好時，PC1 的 loadings 被核糖體／管家基因洗版、分數與 nCount 相關 0.9——你詮釋的是定序深度。


被深度綁架的 PC1 長這樣

PC1 的前十名 loadings



RP 開頭＝核糖體蛋白基因

PC1 對定序深度： $r = 0.98$



模擬資料（故意跳過 normalization 實跑）

top loadings 全是 RPL / RPS、PC1 對 nCount 相關 0.98——先檢查，再詮釋

兩個雷，三行防身術

```
# 雷一： nPC 是否已在平原上（不在就往多的取）
```

```
ElbowPlot(pbm c, ndim s = 50)
```

```
# 雷二： PC1 是深度軸嗎？ top loadings 被核糖體洗版嗎？
```

```
cor(pbm c$nCount_RNA, Embeddings(pbm c, "pca")[, 1])
```

```
mean(grep("^RP[LS]", top.pc1))
```

三行進 R/B07_pca.R 的正式流程——每份新資料都跑，不是出事才跑

踩雷區小結

**nPC 的錯誤只有一種真正致命：
太少。其他都有救。**

多取的代價是一點雜訊與幾秒計算；少取的代價可能是一個看不見的細胞亞群。


5+

複雜樣本策略室

標準流程走完了——現在想像你手上不是 PBMC，是一顆腫瘤

CNV 驅動的 PC：前排坐著染色體事件

腫瘤資料的 PC1：載荷不散在各處，擠在染色體上



示意資料

載荷多一個檢查維度：標上染色體。整段 chr7 擠在正端、chr10 擠在負端——這條軸是基因體，不是表現程式

怎麼發生

惡性細胞帶 CNV：某段染色體多一份，
整段基因表現一起被拉高——
B16 的 inferCNV 靠的正是這個訊號


檢查法

top loadings 標上染色體：
散在各處 = 表現程式 (PBMC 的 PC1)
擠在一兩條染色體 = CNV 軸

判讀

不是雷、不用丟——是真生物學；
但要註記：它也是惡性細胞按病人
成島的原因之一 (B11、B16 回來用)

腫瘤的 nPC：拐點更晚、往多的取



為什麼更晚

型別多、惡性狀態、
增殖、病人效應——
每一個都要佔軸

決策

dims 往 20-30 取：
稀有亞群住在後段 PC，
取少 = 無聲消失

三法重走一遍——
參數是假設：有數字、
有理由、有紀錄

示意曲線

三法照走，數字重走一遍：GBM 5k 三法交集 12-22、定案 25——方法不變，數字要重新掙來

全體 PCA vs per-patient PCA

兩個空間各有工作——問題問誰，就用誰的空間

全體 PCA (所有病人一起)

看跨病人「共同」的結構


- 免疫、基質這些每位病人都有的型別：註釋、整合（B11）都在這裡
- 惡性細胞在這個空間按病人成島——現象，不是 bug
- 適合全景圖與跨病人對齊

per-patient PCA (一位病人)

看一位病人「內部」的結構

- 病人內 CNV 背景一致，病人效應消失，PC 讓位給狀態與亞群
- HVG 重挑、PCA 重跑、nPC 重選，整套重走
- 惡性細胞的精細分析標配（Q 系列與 B11 會實際操作）

nPC 決策流程



猶豫的時候一律往多的取：多取的 PC 只是多帶一點雜訊，
少取的 PC 卻可能少掉一整個細胞亞群

四步走完，nPC 就有數字、有理由；猶豫時一律往多的取

本集 checklist



RunPCA 跑在 HVG 上，接的是 B6 的輸出



print 過前幾個 PC 的 loadings，看得懂它在說什麼



ElbowPlot 看過拐點，量化 cutoff 算過數字



nPC 定案偏「多」的那一側，並記錄理由



檢查過 PC1：loadings 不是核糖體／深度殘留



下游 dims 參數與這裡選的 nPC 一致

六格全勾，才進 B8

一句話總結

**三法框出區間，往多的一側定案，
記下理由——然後停止焦慮。**

在平原上，取 10 或 30 給你的是同一份生物學。

自測 1

為什麼分群前要先做 **PCA**，而不是直接在兩萬個基因上算距離？

- A 因為記憶體放不下兩萬維的距離矩陣
- B 單基因雜訊在加權和中互相抵消，距離才反映真實的型別差異
- C PCA 會把批次效應移除
- D Seurat 規定必須先跑 RunPCA

答 B。每個基因都帶著取樣雜訊，兩萬維的距離會被雜訊淹沒；PC 是上千個基因的加權和，雜訊方向各異、互相抵消，訊號被濃縮進前幾十個軸。A 是實務順帶的好處不是理由；C 是 B11 的工作；D 因果顛倒。

自測 2

ElbowPlot 的拐點模糊，7 到 12 看起來都像。下一步最合理的是？

- A 取 7，維度越少越乾淨
- B 重跑 RunPCA 直到拐點變清楚
- C 取區間高端再加一點（如 15），不放心就做 nPC 穩定度掃描
- D 放棄 PCA，改用全基因分群

答 C。拐點本來就是區間不是點。取太少的代價（亞群消失）遠大於取太多（一點雜訊），所以往高端取；掃描能直接驗證「平原到了沒」。B 沒有用——PCA 是確定性的，重跑結果一樣。

自測 3

你要分析腫瘤組織：族群複雜、預期有稀有亞群。nPC 策略該怎麼調？

- A 跟 PBMC 一樣取 10 就好
- B 往多的取（例如 30-50），因為亞群訊號住在更後面的 PC
- C 取更少，避免腫瘤的雜訊
- D nPC 不影響稀有亞群的偵測

答 B。族群越複雜，需要的表現程式越多，弱而重要的訊號（稀有亞群、活化狀態）住在越後面的 PC。10 是 PBMC 3k 這種乾淨小資料的答案，不是通則；照決策流程重新走一遍，拐點會告訴你它變晚了。

下集預告

B8：分群—— resolution 掃描與 clustree

距離算好了，下一步是把距離變成「群」。同一份資料，可以分 6 群也可以分 16 群——控制這件事的參數叫 resolution，而所有人都在問：到底該設多少？