

B8 B 系列

分群：

resolution 掃描與 clustree

群數不是資料告訴你的，是你問出來的——所以要學會怎麼問。


約 38 分鐘 | 前置：B7 | 資料：PBMC 3k

同一份資料，兩個 resolution

resolution 低 → 9 群



resolution 高 → 15 群



同一份
資料



模擬資料

兩張都「跑得出來」，也都「看起來合理」——選哪張，理由是什麼？

resolution 0.5 分出 9 群；1.2 分出 15 群。哪一張才是「真的」？

本集的起點

「為什麼選這個 resolution？」 「Seurat 預設」不是答案。

審稿人真的會問這一題。這一集給你一套答得出來的流程。

這一集你會學到

- 1 說出 FindNeighbors 與 FindClusters 各在做什麼，以及 k.param、dims、resolution 三個參數的意義
- 2 對 0.2-1.4 做 resolution 掃描，用 clustree 讀出穩定層與亂流層
- 3 用 marker 與每群 QC 指標驗證「那一刀切得有沒有道理」，定案並記錄理由


01

分群在做什麼

提出假說，不是發現真理


從點到圖到社群

① 點：PC 空間裡的細胞




只有座標，沒有結構

② 圖：每顆連向 k 個近鄰



FindNeighbors (k.param)

③ 社群：內密外疏的一塊




FindClusters (resolution)

分群不看嵌入圖的座標——它從頭到尾都發生在 KNN 圖上

FindNeighbors 建圖， FindClusters 在圖上找「內部連得密、對外連得疏」的社群

resolution：放大鏡的倍率



三張都是同一份資料。倍率沒有對錯，只有適不適合你的問題

- 低倍率：只看到大陸塊—— T 細胞、B 細胞、單核球
- 再高：開始切出雜訊，群與群只差幾個基因的機率波動
- 高倍率：大陸塊裂成亞群—— naive 與 memory、CD14 與 FCGR3A
- 沒有「正確倍率」，只有「適合你問題的倍率」

本集核心觀念

**「正確的群數」不存在。
存在的是這個解析度下的穩定結構。**

分群輸出的是假說清單，等著你用 marker 與 QC 去驗證——不是答案。

02

兩行程式碼，兩個步驟

FindNeighbors 建圖 → FindClusters 切社群

FindNeighbors：把細胞連成圖

```
pbm c <- readRDS("output/pbm c_b05_qc.rds") # 承接 B5-B7 的物件  
pbmc <- FindNeighbors(pbm c, dims = 1:10) # dims: B7 選的 nPC
```

Computing nearest neighbor graph
Computing SNN

k.param 預設 20：每顆細胞找 20 個最近鄰。距離算在 PC 空間，不是基因空間

FindNeighbors 的三個關鍵

dims = 1:10




承接 B7 的 nPC 決定。改它，圖就變，下游全變

k.param = 20 (預設)



調小群會變碎，調大群會被抹平；沒特殊理由先不動

輸出：兩張圖



RNA_nn 與
RNA_snn 存進物件；
SNN 才是分群用的
那張

FindClusters : 在圖上切社群

```
pbc c <- FindClusters(pbc c, resolution = 0.5)
```

Modularity Optimizer version 1.3.0 by Ludo Waltman and
Nees Jan van Eck

Number of nodes: 2638
Number of edges: 95927

Running Louvain algorithm ...
Maximum modularity in 10 random starts: 0.8723
Number of communities: 9

Elapsed time: 0 seconds

algorithm = 1 (Louvain) 是預設; resolution 是這一集的主角

algorithm 參數：Louvain 與 Leiden

兩者都是「社群偵測」；數學細節指向 C 系列

Louvain

algorithm = 1 , Seurat 預設

- 快、穩、用了十幾年
- 已知缺陷：偶爾產生內部斷裂的社群
- 本集全程用它

Leiden

algorithm = 4 , 改良版

- 保證社群內部連通（Traag 2019）
- scanpy 世界的預設
- Seurat 要另裝 Python 的 leidenalg 才能跑

看結果：多了一個欄位，多了一組身分

```
table(Ids(pbm c))
```

```
DimPlot(pbm c, reduction = "um ap", label= TRUE)  
# UMAP 是 B9 的主角，今天先借它的座標看結果
```

0	1	2	3	4	5	6	7	8
684	481	476	344	291	162	155	32	13

編號 0 起跳、按群大小排。記住：編號是任意的——這句話踩雷區會收回來用

這一節做了什麼

一張 SNN 圖



FindNeighbors 在
10 個 PC 的空間裡
把 2,638 顆細胞連
起來

九個社群



FindClusters 在
resolution 0.5 下切
出 9 群，存進
seurat_clusters

九個假說



每一群都還沒驗證。
0.5 也還不是定案—
下一節開始問問題

03

resolution 掃描與 clustree

不挑一個值，先看整條光譜

掃描： 0.2 到 1.4 ，一個迴圈

```
for (r in seq(0.2, 1.4, by = 0.2)) {  
  pbmc <- FindClusters(pbmc, resolution = r, verbose = FALSE)  
}  
  
grep("^RNA_snn_res", colnames(pbmc@meta.data), value = TRUE)
```

```
[1] "RNA_snn_res.0.5" "RNA_snn_res.0.2" "RNA_snn_res.0.4"  
[4] "RNA_snn_res.0.6" "RNA_snn_res.0.8" "RNA_snn_res.1"  
[7] "RNA_snn_res.1.2" "RNA_snn_res.1.4"
```

每個 resolution 一個 metadata 欄位，全部留著。注意 1.0 的欄名是「res.1」

每個 resolution 各分幾群

```
res.cols <- grep("^RNA_snn_res", colnames(pbm.c@meta.data),  
                 value = TRUE)  
sapply(pbm.c@meta.data[res.cols], \x) length(unique(x))
```

RNA_snn_res.0.5	RNA_snn_res.0.2	RNA_snn_res.0.4	RNA_snn_res.0.6
9	6	8	10
RNA_snn_res.0.8	RNA_snn_res.1	RNA_snn_res.1.2	RNA_snn_res.1.4
11	13	15	16

6 到 16 群都做得出來。另外注意：掃完之後 active identity 停在最後跑的 1.4


clustree：把掃描結果畫成一棵樹

```
# install.packages("clustree")  
library(clustree)  
  
clustree(pbm c, prefix = "RNA_snn_res.")
```

prefix 對準欄位名的共同開頭，它就把每個 resolution 疊成一層、畫出細胞的流向

clustree 長這樣



—列一個 resolution；節點大小 = 細胞數；線寬 = 流過去的細胞數



模擬資料 (KNN 圖 + Louvain 實跑)

—列一個 resolution；節點是群、大小是細胞數；箭頭是細胞從上一層流到下一層的去向

怎麼讀：穩定層與亂流層



示意圖

res 低

res 高

定案的位置：最深的那個「還穩定」的層——再往下就是亂流

上半段結構穩定、分裂乾淨；再往下箭頭開始交叉、細胞在群間換來換去——那就是切過頭了

往下讀樹的三個問題

這一層穩定嗎



連續幾個 resolution
結構都不變的層，是
定案的候選人

分裂是單向的嗎



一個節點乾淨裂成兩
個、沒有回流——值
得拿 marker 去驗

有沒有交換





箭頭交叉、一個群的
細胞來自多個上游——
亂流層，退回去

04

用 marker 驗證那一刀

clustree 說「穩定」，生物學才能說「有道理」

相鄰 resolution，多出來的那一刀



模擬資料

同樣是「一群變兩群」：左邊兩套 marker 各據一方；右邊兩群的表现譜根本是同一個

先找出被切開的是誰

```
# 相鄰兩個 resolution 的交叉表：一列一個舊群  
table(pbm c$RNA_snn_res.0.4, pbm c$RNA_snn_res.0.6)
```

	0	1	2	3	4	5	6	7	8	9
0	644	0	0	0	0	0	0	40	0	0
1	0	436	0	0	0	0	158	0	0	0
2	0	0	476	0	0	0	0	0	0	0
...										

0.4 的 1 號群，在 0.6 被切成 436 顆與 158 顆兩塊——就驗這一刀

這一刀的兩邊，差在哪些基因

```
Idents(pbm c) <- "RNA_snn_res.0.6"  
split.m k <- FindMarkers(pbm c, ident.1 = 1, ident.2 = 6,  
                        min.pct = 0.25)  
head(split.m k, 4)
```

	p_valavg	log2FC	pct.1	pct.2	p_valadj
S100A8	3.1e-172	3.90	0.975	0.229	4.3e-168
S100A9	8.4e-165	3.51	0.996	0.400	1.2e-160
LGALS2	6.0e-151	2.87	0.908	0.078	8.2e-147
CD14	2.2e-106	1.82	0.667	0.028	3.0e-102

CD14 一側衝高；反方向的名單裡是 FCGR3A、MS4A7。這是教科書級的兩型單核球

拿到圖上對質： FeaturePlot 與 VlnPlot

```
FeaturePlot(pbm c, features = c("CD 14", "FCGR3A"))
```

```
VlnPlot(pbm c, features = c("CD 14", "LYZ", "FCGR3A", "MS4A7"),  
        ids = c(1, 6), ncol = 4)
```

FeaturePlot 看位置對不對得上那一刀； VlnPlot 看兩群的表現量是不是真的分家

切，還是不切？

同一套檢查，跑在兩刀上，給出兩個不同的答案

0.4 → 0.6 那一刀

有 marker 撐腰：切

- CD14/LYZ 對 FCGR3A/MS4A7 ，兩套 marker 各據一群
- 對應已知生物學：古典與非古典單核球
- 這一刀讓資料多說了一件真話

0.6 → 0.8 那一刀

沒有證據：先不切

- top 基因全是核糖體蛋白，log2FC 不到 0.5
- pct.1 與 pct.2 都是 99%——兩邊根本都在表現
- 多這一刀只是把雜訊切成兩半

05

定案前的驗屍：QC 與 doublet

B5 留下的兩個鉤子，今天回收

每群的 QC 指標：殘渣群現形記


```
library(dplyr)

qc.tab <- pbmc@meta.data |>
  group_by(cluster = RNA_snn_res.0.6) |>
  summarise(n = n(),
            mt = median(percent_mt),
            nF = median(nFeature_RNA))
arrange(qc.tab, desc(mt)) |> head(3)
```

```
# A tibble: 3 x 4
  cluster    n    mt   nF
  <fct>    <int> <dbl> <dbl>
1 8         15  3.4  692
2 4        291  3.1  814
3 5        206  2.9  889
```

你要看的是：有沒有哪一群 mt 一枝獨秀、nFeature 墊底。這份資料——沒有

殘渣群長什麼樣



mt 中位數 12%、nFeature 只有別群一半、marker 全是壓力基因——這不是新細胞型別

模擬資料


每群的 doublet 比例： B5 標籤的用途

```
df.col <- grep("^ D F.classifications",  
               colnames(pbm.c@meta.data), value = TRUE)  
  
round(prop.table(table(pbm.c$RNA_snn_res.0.6,  
                       pbm.c@meta.data[[df.col]]), 1), 3)[1:5, ]
```

	Doublet	Single
0	0.011	0.989
1	0.018	0.982
2	0.008	0.992
3	0.015	0.985
4	0.021	0.979

全部貼著整體預期率 2.3% 走——過關。要抓的是「過半都被標 doublet」的那種群

doublet 群長什麼樣



某一群 38% 被標 doublet、位置又卡在兩大群之間——那不是群裡有 doublet，是整群就是 doublet


寫進論文的方法段

**「 FindNeighbors (dims=1:10) +
Louvain ;
掃描 0.2-1.4 , 依 clustree 穩定性
與 marker 證據取 resolution 0.6 。 」**

三個資訊缺一不可：參數、掃描範圍、選擇的理由。「預設值」三個字從此離開你的方法段。

整套決策流程，一張圖

resolution 不是挑出來的，是「篩選 + 驗證」剩下來的



掃描 → clustree → marker 驗證 → 每群 QC → 定案記錄；發現殘渣群就回 B5 修線重跑

06

踩雷區

三個雷，每一個都實際跑給你看

雷一：調到出現想要的群數為止

雷是什麼

「這組織應該有 12 種細胞」，於是調 resolution 直到剛好分出 12 群。



為什麼會踩


感覺很合理——群數對上文獻，好像互相印證了。

踩了會怎樣

循環論證。你用結論挑參數，再用參數產生結論；掃描表已經證明 6 到 16 群任你點菜。

任何群數都做得出來


你要 4 群



你要 8 群



你要 16 群



模擬資料

同一份資料，指定 4、8、16 群都「成功」了——群數本身永遠不是證據

同一份資料：你要 4 群、8 群、16 群，演算法都照辦。群數本身不是證據

雷二：編號不對應還硬比

雷是什麼

換了 dims 或 k.param 重跑，然後說「cluster 3 還是 cluster 3，結果穩定」。



為什麼會踩

編號長得一樣，直覺上就是同一群。

踩了會怎樣

編號只反映群大小的排序，兩次跑的 3 號可能是完全不同的細胞。跨 run 對照要用交叉表，不是看編號。

兩個「cluster 3」，兩群細胞

跑法 A (k.param=15) 的 cluster 3



跑法 B (k.param=8) 的 cluster 3



同一個編號
不同的細胞

對應要靠
table(A, B)
交叉表

模擬資料

編號只是「群大小的排名」。參數一動、排名一動，編號就全部洗牌

一行檢查：table(舊標籤, 新標籤)。對角線亂掉，就代表編號已經洗牌

雷三：把 QC 殘渣群當新細胞型別

雷是什麼

分群多出一個小群，marker 看起來「很特別」，直接寫成新發現。



為什麼會踩

它真的自成一群，而且 FindAllMarkers 真的會給它一張 marker 清單。

踩了會怎樣

高 mt、低 nFeature、marker 全是粒線體與熱休克基因——那是垂死細胞聚成的殘渣群。解法不是刪掉它，是回 B5 修過濾線重跑。

踩雷區小結

**群數可以訂做、編號可以洗牌、
殘渣也會自成一群。
唯一的防線是證據，不是參數。**

marker 證據、QC 指標、doublet 比例——三道檢查做完，這一群才算數。

5+


複雜樣本策略室

標準流程走完了——現在想像你手上不是 PBMC，是五個病人的腫瘤

分群表的腫瘤標配欄：病人組成

● 病人 1 ● 病人 2 ● 病人 3

每群的病人組成（比例）



示意圖

怎麼算

table(群標籤, 病人標籤)
——頁 25 的交叉表，第二維換成樣本

怎麼讀

惡性群按病人成島是腫瘤常態：
每人 CNV 不同——不是批次效應失控

本頁決策

每群 QC 表加一欄「病人組成」
——B10 註釋、B11 整合、B12 統計都要看

TME 群人人有份；惡性群一人一座島。table(群, 病人) 一行就看得到——這是常態，不是批次失敗

先粗後細：層級式分群

第一層：粗切定譜系



低 resolution 先分開免疫／基質／惡性；
clustree 頂層通常很穩，先定案先註釋

第二層： **subset 亞群**



重跑 細胞亞群：
subset 出來，
HVG、PCA、分群
整條重跑——不是調高全體的 resolution

兩個煞車



亞群 < 200 顆別再往下切；subset 之後沿用全體的 PC 是常見錯誤

惡性大陸內部：那一刀是什麼？

clone、狀態、雜訊——在 clustree 上是同一張臉

三種可能

resolution 分不出它們

- clone：CNV 不同的亞克隆——真的基因體差異
- 狀態：增殖、缺氧、壓力——同一群細胞的不同心情
- 雜訊：marker 表被狀態基因與 CNV 效應混在一起

策略

換更硬的證據，不是更高的 resolution

- 分 clone：等 B16 的 CNV 證據
- 描述狀態：已發表基因集打分數——連續、跨病人可比
- 今天的標籤寫到「malignant + 病人」就停

壞死樣本：殘渣群還是生物群？三證據並用

① QC 的相對位置




跟同譜系的鄰居群比，
不跟全體比——惡性
細胞的 mt 基線本來
就高

② marker 的內容



扣掉粒線體與熱休克
基因，還剩譜系
marker 與成套缺氧
簽名嗎？殘渣群什麼
都不剩

③ 跨樣本出現



生物群在多個病人、
多個壞死核心樣本重
複現身；殘渣群通常
跟著單一樣本走

本集 checklist



FindNeighbors 的 dims 承接 B7，k.param 有意識地留在預設



resolution 0.2–1.4 掃描跑過，結果全部留在 metadata



clustree 畫過，說得出穩定層在哪、亂流從哪開始



定案那幾刀，每一刀都有 marker 證據



每群的 QC 指標與 doublet 比例檢查過



resolution、參數與理由寫進分析筆記

六格全勾，才進 B9

一句話總結

**分群給的是假說；
clustree 找穩定層， marker 定生死，
理由寫下來。**

下次審稿人問「為什麼選 0.6」，你有一頁掃描圖、一棵樹、一張 marker 表可以回答。

自測 1

FindNeighbors 與 FindClusters 各在做什麼？

- A 前者算 PCA，後者算 UMAP
- B 前者在 PC 空間建 KNN/SNN 圖，後者在圖上跑社群偵測
- C 前者過濾細胞，後者指定群數
- D 兩者都在算細胞間距離，只是演算法不同

答 B。FindNeighbors 把每顆細胞和它在 PC 空間的鄰居連成圖；FindClusters 用 Louvain 或 Leiden 在圖上找「內密外疏」的社群。群數是結果，不是輸入。

自測 2

clustree 上，哪種長相代表「解析度可能切過頭了」？

- A 節點隨 resolution 增加而變多
- B 一個節點乾淨地分裂成兩個
- C 箭頭交叉、細胞在相鄰層的群之間互相交換
- D 最下層的群比最上層多

答 C。群數變多是掃描的本意，乾淨的單向分裂值得用 marker 驗證；但細胞開始在群間來回交換，代表切出來的邊界已經不穩定——那是亂流層。

自測 3

resolution 0.8 比 0.6 多切一刀，FindMarkers 的 top 基因全是核糖體蛋白、log2FC 都小於 0.5、pct 兩邊都 99%。你怎麼定案？

- A 選 0.8，群多資訊多
- B 選 0.6，那一刀沒有生物學證據支持
- C 取中間值 0.7 重跑
- D 改用 Leiden 再說

答 B。核糖體基因人人都表現，pct 兩邊 99% 代表那一刀切的是表現量的連續變化，不是型別邊界。沒有 marker 撐腰的刀不切——停在 0.6，把這個理由記進筆記。

下集預告

B9：UMAP / t-SNE——參數、隨機性與可重現性

群定案了，但它們在紙上還只是一串編號。下一集把它們畫到二維上——
同一行程式碼跑兩次，你的 UMAP 長得一樣嗎？如果不一樣，論文的圖怎麼辦？