

B10 B 系列


細胞註釋： marker、 FindAllMarkers、SingleR / Azimuth

手動與自動兩條路都走一遍，吵架的時候知道聽誰的。

約 40 分鐘 | 前置：B8（建議 B9） | 資料：PBMC 3k

同一群細胞，兩個名字

PBMC 3k • res 0.6 的十群



模擬資料

SingleR 說

NK_cell

相似度最高分：NK 0.42 (T cells 0.40)
delta 0.017——全場最低

marker 說

CD8 效應 T

CD3E+ CD8A+ (TCR 零件，NK 沒有)
同時亮 NKG7 / GNLY 胞殺程式

誰對？——先別選邊，先看兩邊的證據各是什麼

7 號群，40 顆細胞：SingleR 說 NK，你的 marker 說 CD8 效應 T。誰對？

本集的起點

註釋不是查表， 是一場「證據對證據」的裁決。

問「誰對」之前先問：兩邊各拿出了什麼證據？這一集教你怎麼開這個庭。

這一集你會學到


- 1 用 FindAllMarkers 產出每群 marker，讀懂輸出表的每一欄
- 2 用經典 marker 面板手動註釋 PBMC 的十個群
- 3 跑 SingleR 與 Azimuth，設計交叉驗證表裁決不一致的群

01


註釋在做什麼

把群對應到已知生物學——而且永遠帶著不確定性

三種證據，三個等級



示意圖



等級高的證據永遠壓過等級低的——
衝突時照這個順序裁決

- 最強：canonical marker——教科書級的專屬基因
- 次之：參考資料集相似度——SingleR / Azimuth 的分數
- 最弱：富集猜測——「這群富集了 XX 通路，也許是……」
- 等級高的證據，永遠壓過等級低的

本集核心觀念

**每一個標籤都是假說。
差別只在你掛了幾級的證據。**

「cluster 3 = B 細胞」永遠是推論，不是觀測。方法段要寫的是推論的依據。

02

FindAllMarkers：每群的證人名單

一行指令，把十個群的差異基因一次找完

跑 FindAllMarkers

```
library(Seurat)
library(dplyr)
set.seed(1234)

pbm.c <- readRDS("output/pbm.c_b08_clustered.rds")
Idents(pbm.c) <- "RNA_snn_res.0.6" # 明確指定，不靠默契

pbm.c.markers <- FindAllMarkers(pbm.c, only.pos = TRUE,
                                min.pct = 0.25,
                                logfc.threshold = 0.25)
dim(pbm.c.markers)
```

```
[1] 3178  7
```

每個群輪流「一群 vs 其他全部」比一輪；三千多列，十個群的證人都到齊

看輸出：以 3 號群為例

```
pbm c.m markers |>
  filter(cluster == 3) |>
  slice_head(n = 4)
```

	p_valavg_log2FC	pct.1	pct.2	p_valadj	cluster	gene
CD79A	1.1e-182	4.31	0.936	0.041	1.5e-178	3 CD79A
MS4A1	4.4e-180	4.20	0.855	0.053	6.1e-176	3 MS4A1
TCL1A	2.9e-155	4.53	0.622	0.023	3.9e-151	3 TCL1A
CD79B	6.2e-149	3.87	0.891	0.142	8.5e-145	3 CD79B

CD79A、MS4A1——B 細胞受體的零件。這個群的身分幾乎寫在臉上

這張表，逐欄解剖

3 號群的前三列 (B 細胞 marker)

先看：差幾倍 (log2)
4.31 = 約 20 倍

第二看：群內 vs 群外表現比例
0.94 vs 0.04——差距越大越好

	p_val	avg_log2FC	pct.1	pct.2	p_val_adj	cluster	gene
CD79A	1.1e-182	4.31	0.94	0.04	1.5e-178	3	CD79A
MS4A1	4.4e-180	4.20	0.86	0.05	6.1e-176	3	MS4A1
TCL1A	2.9e-155	4.53	0.62	0.02	3.9e-151	3	TCL1A

未校正 p 值：不要直接用
持家基因也能小到爆表 (雷一)

Bonferroni 校正後：最後把關
乘上基因總數 13,714

哪一群的哪個基因
列名重複時 gene 欄才是正身

先看 avg_log2FC 與 pct 差，再看 p_val_adj——順序跟你直覺相反，踩雷區會解釋

每群前五名，一次點名

```
top5 <- pbmc.markers |>
  group_by(cluster) |>
  slice_max(avg_log2FC, n = 5) |>
  ungroup()

top5 |> filter(cluster == 9) |>
  select(gene, avg_log2FC, pct.1, pct.2)
```

	gene	avg_log2FC	pct.1	pct.2
1	PPBP	8.58	1.000	0.011
2	PF4	7.24	1.000	0.010
3	GNG11	6.94	0.929	0.019
4	SDPR	6.65	0.929	0.011
5	TUBB1	6.26	0.857	0.005

9 號群：PPBP、PF4——血小板的教科書 marker，pct.2 幾乎是零

這一節做了什麼

一張證人名單



3,178 列，每群的候選 marker 都在裡面

三個要看的欄位



avg_log2FC、
pct.1 vs pct.2、
p_val_adj——按這個順序

表不會自己說話



名單要跟已知生物學對質——下一節先學畫圖

03

marker 視覺化三件套

FeaturePlot、VlnPlot、DotPlot——同一個問題的三種問法

三件套，各一行

```
# 在哪裡亮：表現量塗在 UMAP 上
FeaturePlot(pbm c, features = "M S4A1")

# 各群分布：一群一把小提琴
VlnPlot(pbm c, features = "M S4A1", pt.size = 0)


# 多基因 × 多群總覽：大小 = 比例、深淺 = 強度
DotPlot(pbm c, features = c("M S4A1", "CD 79A", "CD 3E", "NKG 7")) +
  RotatedAxis()
```

A5 講過怎麼讀這三種圖；今天換你自己畫

同一個 marker ，三種視角


模擬資料 • marker : MS4A1 (B 細胞)

FeaturePlot : 亮在哪裡




只有 B 群 (3 號) 亮

VlnPlot : 各群分布



整群高，不是幾顆細胞撐場面

DotPlot : 多基因總覽



大小=表現比例、深淺=強度

位置、分布、總覽——三張圖互相補位，單看任何一張都可能被騙

何時用哪個

工具	它給你什麼	什麼時候用
FeaturePlot	表現量畫在嵌入圖上，看「亮在哪裡」	檢查 marker 亮區與群的位置是否吻合
VlnPlot	每群一把小提琴，看分布與雙峰	判斷是整群高，還是少數細胞撐場面
DotPlot	多基因 × 多群，大小 = 比例、顏色 = 強度	整個面板一頁總覽；論文附圖的常客

04

手動註釋：拿面板逐群走

PBMC 的經典 marker 面板 + 十個群，一個一個定罪

PBMC 經典 marker 面板

型別 (cluster)	正字標記 marker	一句話記法
 Naive CD4 T (0)	CD3E • IL7R • CCR7	T 的底 + 天真態的 CCR7
 Memory CD4 T (2)	CD3E • IL7R • S100A4	同上，但 S100A4 取代 CCR7
 CD8 T (4)	CD3E • CD8A	T 的底 + CD8A
 效應 CD8 T (7)	CD3E • CD8A • NKG7 • GNLY	T 的底 + 胞殺程式——會跟 NK 撞臉
 NK (5)	NKG7 • GNLY (CD3E 陰性)	胞殺程式但沒有 TCR
 B (3)	MS4A1 • CD79A	B 細胞受體的零件
 CD14 單核球 (1)	CD14 • LYZ	古典型；LYZ 高到刺眼
 FCGR3A 單核球 (6)	FCGR3A • MS4A7	非古典型 (CD16)
 樹突細胞 DC (8)	FCER1A • CST3	抗原呈現專職
 血小板 (9)	PPBP • PF4	嚴格說不是細胞——沒有核

這張表值得背下來——做 PBMC 的人一輩子用得到

面板上場

```
panel<- c("CD3E", "IL7R", "CCR7", "S100A4", # T 與 CD4 亞群
          "CD8A",          # CD8 T
          "MS4A1",          # B
          "CD14", "LYZ",      # 古典單核球
          "FCGR3A", "MS4A7",  # 非古典單核球
          "NKG7", "GNLY",     # NK 與胞殺程式
          "FCER1A", "CST3",   # DC
          "PPBP")             # 血小板
```


```
FeaturePlot(pbm c, features = c("CD3E", "MS4A1", "CD14", "NKG7"))
DotPlot(pbm c, features = panel) + RotatedAxis()
```

CD4 轉錄本容易 dropout，靠 IL7R 佐證 CD4 T—— 蛋白與 mRNA 不是一回事

逐群走一遍


模擬資料

CD3E




左下整片亮
→ T 系 (0/2/4/7)

MS4A1




只亮一塊
→ B (3)

CD14



上方亮一葉
→ 古典單核球 (1)

NKG7




亮 NK——加上 7 號
→ 7 號要多查一步

一個 marker 一個問題：亮在哪？對應面板上的誰？有沒有反證？

每個群問三個問題：哪些 marker 亮？面板上對應誰？有沒有反證？

DotPlot 全景：十群一次看

點的大小 = 表現該基因的細胞比例 | 顏色深淺 = 平均表現量



同時亮 T 底與胞殺——
交叉驗證段的主角

模擬資料

對角線一塊一塊亮，代表每群都有自己的證據； 7 號同時亮 T 與胞殺兩組——記住它

掛上名字

```
new.ids <- c("Naive CD4 T", "CD14 Mono", "Memory CD4 T",  
            "B", "CD8 T", "NK", "FCGR3A Mono",  
            "Effector CD8 T", "DC", "Platelet")  
names(new.ids) <- levels(pbm.c)  
pbm.c <- RenameIds(pbm.c, new.ids)  
pbm.c$celltype.manual <- Idents(pbm.c) # 存進 metadata  
table(pbm.c$celltype.manual)
```

Naive CD4 T	CD14 Mono	Memory CD4 T	B
711	436	467	344
CD8 T	NK	FCGR3A Mono	Effector CD8 T
271	165	158	40
DC	Platelet		
32	14		

十個群、九種型別——存進 metadata 欄位，原始編號不覆蓋

05

自動註釋：SingleR 與 Azimuth

讓參考資料集投票——然後學會讀它的信心

SingleR：跟參考集比相似度

```
# BiocManager::install(c("SingleR", "celldex"))
library(SingleR)
library(celldex)
ref <- HumanPrimaryCellAtlasData() # HPCA : 37 種主標籤

pred <- SingleR(test = GetAssayData(pbm c, layer = "data"),
               ref = ref, labels = ref$labelmain,
               clusters = pbm c$RNA_snn_res.0.6)
pred$labels
```

```
[1] "T_cells" "Monocyte" "T_cells" "B_cell"
[5] "T_cells" "NK_cell" "Monocyte" "NK_cell"
[9] "DC"      "Platelets"
```

clusters 參數 = 逐群註釋；第 8 個標籤（7 號群）：NK_cell——cold open 的來源

score 熱圖：分數怎麼讀

金框 = 該欄最高分 (SingleR 的答案)



7 號欄：NK 0.42 vs
T_cells 0.40——
幾乎平手


其他欄：贏家甩開
第二名一大截

示意圖 (分數為示意值)


看的不是「最高分是誰」，是「最高分甩開第二名多少」

delta：SingleR 的自信心

每群的 delta（最高分 - 次高分）




7 號群 delta 0.017，全場最低——SingleR 自己都說「這題我不太確定」



Azimuth：把細胞放上參考地圖

Azimuth 參考地圖 (16 萬顆 PBMC)



你的細胞
投影上去



你的 2,638 顆落在地圖上




示意圖 • 不重新分群，只認位置——像把 GPS 點疊到現成地圖

落點附近的參考細胞投票 → 標籤 + prediction score

不是重新分群，是把你的細胞「投影」到別人做好的高品質地圖上認位置

跑 Azimuth

```
# remotes::install_github("satijalab/azimuth")
library(Azimuth)
pbmc <- RunAzimuth(pbmc, reference = "pbmc_ref")

head(pbmc@meta.data[, c("predicted.celltype.l2",
                        "predicted.celltype.l2.score")], 3)
```

	predicted.celltype.l2	predicted.celltype.l2.score
AAACATACAACCAC -1	CD4 Naïve	0.943
AAACATTGAGCTAC -1	B naïve	1.000
AAACATTGATCAGC -1	CD4 TCM	0.741

l1 / l2 / l3 三層標籤由粗到細； score 是對參考地圖的一致度，不是「正確率」

SingleR vs Azimuth

不是二選一——它們錯的方式不一樣，所以一起用

SingleR

跟任何參考集比相似度

- bulk、微陣列參考也能吃，彈性大
- 輸出 score 與 delta，可逐群或逐細胞
- 品質取決於你選的參考集

Azimuth

投影到官方參考地圖

- PBMC 等常見組織有高品質官方參考
- 三層標籤，細到 CD8 TEM 這種亞群
- 冷門組織沒地圖，就無用武之地

06

交叉驗證：三方對質

手動、SingleR、Azimuth 排成一張表，逐群裁決

三方交叉驗證表

群 (顆數)	手動 marker	SingleR	Azimuth (l2 多數)	判定
0 (711)	Naive CD4 T	T_cells	CD4 Naive	✓ 一致
1 (436)	CD14 Mono	Monocyte	CD14 Mono	✓ 一致
2 (467)	Memory CD4 T	T_cells	CD4 TCM	✓ 一致
3 (344)	B	B_cell	B naive	✓ 一致
4 (271)	CD8 T	T_cells	CD8 Naive	✓ 一致
5 (165)	NK	NK_cell	NK	✓ 一致
6 (158)	FCGR3A Mono	Monocyte	CD16 Mono	✓ 一致
7 (40)	效應 CD8 T	NK_cell	CD8 TEM	⚠ 開庭裁決
8 (32)	DC	DC	cDC2	✓ 一致
9 (14)	Platelet	Platelets	Platelet	✓ 一致

「T_cells vs CD4 Naive」是解析度粗細之差，不算衝突；真正吵架的只有 7 號

九個群三方一致；唯一吵架的 7 號，正是 cold open 那一群

開庭： 7 號群 vs 真 NK

```
# SingleR 說 NK、Azimuth 說 CD8 TEM、手動說效應 CD8 T。  
# 讓 7 號跟公認的 NK (5 號) 當面對質：  
Idents(pbm c) <- "RNA_snn_res.0.6"  
vs.nk <- FindMarkers(pbm c, ident.1 = 7, ident.2 = 5,  
                      min.pct = 0.25)  
vs.nk[c("CD3E", "CD8A", "GNLY", "NKG7"),  
       c("avg_log2FC", "pct.1", "pct.2")]
```

	avg_log2FC	pct.1	pct.2
CD3E	3.94	0.975	0.061
CD8A	3.11	0.850	0.024
GNLY	-1.22	0.700	0.964
NKG7	-0.48	0.950	0.994


有 TCR 零件 (CD3E/CD8A) 就是 T 細胞；共享胞殺程式騙得過相似度，騙不過 canonical marker

寫進論文的方法段

**「以 canonical marker 手動註釋為主，
SingleR 與 Azimuth 交叉驗證；
不一致之群以 marker 證據裁決。」**

附上那張交叉驗證表當補充資料，審稿人對你的註釋將無話可說。

整套註釋流程，一張圖



先手動建假說，再自動驗證，吵架看證據等級——這條流程適用任何組織

07

踩雷區

三個雷，每一個都實際跑給你看

雷一： p 值最小的就是最好的 marker

雷是什麼

把 FindAllMarkers 的表按 p 值排序，取最上面的當 marker。



為什麼會踩

統計課教我們 p 越小越顯著，直覺就這麼排了。

踩了會怎樣

兩千多顆細胞的檢定裡，人人都表現的持家基因 p 值也小到爆表；你的「最佳 marker」誰都有，什麼都區分不了。

兩個基因，p 值同樣漂亮

5 號群（NK）的兩個候選 marker——p 值都趴在零

B2M



p_val_adj = 3.1e-146

pct.1 1.00

pct.2 0.99

avg_log2FC = 0.58

持家基因：人人都表現

p 值
分不出

NKG7



p_val_adj = 1.9e-151

pct.1 0.99

pct.2 0.13

avg_log2FC = 4.05

真 marker：只有 NK 高

按 p 排序你會選到 B2M；按 FC 與 pct 差排序你會選到 NKG7

p 值分不出它們；pct 差與 log2FC 一眼分出。看表的順序：FC → pct 差 → p

雷二：自動註釋的輸出直接當結論

雷是什麼

SingleR 或 Azimuth 給什麼標籤就用什麼標籤，不做任何檢查。



為什麼會踩

工具很有名、分數看起來很高，感覺比自己判斷可靠。

踩了會怎樣

參考集裡「沒有」的型別，會被硬塞一個最像的標籤——工具沒有「以上皆非」的選項，你的血小板就這樣變成了單核球。

實跑：把血小板交給沒見過血小板的參考集

```
# DICE 參考集：只有 T / B / NK / 單核球——沒有 DC、沒有血小板
ref.dice <- DatabaseImmuneCellExpressionData()
pred.d <- SingleR(test = GetAssayData(pbm.c, layer = "data"),
  ref = ref.dice, labels = ref.dice$label.main,
  clusters = pbm.c$RNA_snn_res.0.6)
# 8 號 (DC) 與 9 號 (血小板) 拿到什麼標籤?
pred.d$labels[9:10]
round(pred.d$delta.next[9:10], 3)
```

```
[1] "Monocytes" "Monocytes"
[1] 0.021 0.008
```

兩群都被塞成單核球，delta 趴在地上——低 delta 是你唯一的警報器

雷三：在 subcluster 層級用大類 marker

雷是什麼

把 T 細胞切成四個亞群之後，還拿 CD3E 這種大類 marker 去區分它們。



為什麼會踩


CD3E 是「最有名」的 T 細胞 marker，名氣大到讓人忘了它的解析度。

踩了會怎樣

四個亞群全部 CD3E 陽性、全部標成「T cell」，切了等於白切；亞群層級要換亞群層級的面板。


marker 的解析度要配得上群的解析度

大類 marker : CD3E



面板跟著
解析度換

亞群 marker : CCR7 / S100A4 / CD8A / GZMB



四個亞群全亮 → 全部標成「T cell」
切了等於白切

模擬資料

一個亞群一個 marker → 名字掛得上去

大類 marker 分大類，亞群 marker 分亞群——面板跟著解析度換

踩雷區小結

**工具給的是分數，
名字永遠是你給的。**


p 值、相似度、prediction score 都只是證據——蓋章定案的人是你，出錯負責的人也是你。

05+

複雜樣本策略室

同一套註釋，換成腫瘤——順序、面板、參考集、名字全要重想

註釋順序策略：譜系先行，惡性延後



腫瘤 UMAP：四個譜系大陸——膠質那塊，今天定不了惡性



示意圖

marker 只能定譜系；惡性與否等 B16 的 CNV 證據——第一天就寫 Malignant，是用標籤預設結論

層級式註釋：亞群要整條流程重跑

免疫類群 subset 出來，HVG、PCA、分群、UMAP 全部重算，再換亞群面板

為什麼要重跑



全體的 HVG 與前幾個 PC 被「惡性 vs 免疫」佔滿，亞群的訊號擠不進名單

面板跟著換層



P2RY12/TMEM119
認小膠質、CD163/L
YZ 認血液來源
TAM；CD8A、
FOXP3、PDCD1
分 T 亞群

兩條底線



少於兩百顆的亞群不要再切；惡性的「亞群」不分群，用狀態分數


參考圖譜選擇：不同腫瘤不同 reference

按「你要註釋誰」選參考集——同一份腫瘤資料，三塊要分開想

要註釋誰	參考集怎麼選	陷阱
TME 免疫細胞	免疫專用參考最準：Monaco、CellTypist 免疫圖譜	廣譜集（HPCA）到亞群層級解析度不夠
正常基質與譜系	HPCA ／器官圖譜即可；寡樹突、內皮通常沒爭議	涵蓋不全時照樣硬塞——delta 要盯
惡性細胞	沒有參考集收錄「你這顆腫瘤」	必被塞成最像的正常型別（GBM→星狀細胞）——雷二的放大版

惡性細胞的註釋是「狀態」，不是型別

惡性大陸內部：狀態是連續的，象限之間都是過渡細胞



← OPC/NPC 樣 AC/MES 樣 →

AddModuleScore

基因集平均 - 對照平均：快，但吃定序深度

UCell

排名法：對深度最穩健，不一致時信它

AUCell

前 5% 排名的 AUC：SCENIC 的算法



分數描述狀態，不證明惡性——
四狀態定義在「已確認惡性」的細胞裡

模擬資料

Neftel 四狀態用基因集打分數：連續、跨病人可比；分數描述狀態，不證明惡性

命名規範

**證據到哪裡，名字寫到哪裡：
譜系 + possibly malignant。**

I1 類群、I2 型別、I3 狀態三層分欄存 metadata；惡性欄位等 B16 的 CNV 證據再定案。

本集 checklist



marker 表看的順序：FC → pct 差 → p_val_adj



每個群都在面板上找得到 canonical marker 支持



SingleR 跑過，score 熱圖與 delta 檢查過



Azimuth 跑過，prediction score 檢查過



三方交叉驗證表做完，不一致的群逐一裁決並記錄



最終標籤存進 metadata，原始 cluster 編號保留

六格全勾，你的註釋才算定案

一句話總結

**手動建假說，自動來驗證；
吵架的時候，證據等級說了算。**

canonical marker > 參考集相似度 > 富集猜測。這個順序，整集只講了這一件事。

自測 1

FindAllMarkers 輸出裡的 **pct.1** 與 **pct.2** 各是什麼？

- A 本群與其他群的平均表現量
- B 本群與其他群中「表現此基因的細胞比例」
- C 第一與第二主成分的載荷
- D 調整前與調整後的 p 值

答 B。pct.1 是這個群裡表現該基因的細胞比例，pct.2 是其他所有群合起來的比例。好 marker 的長相是 pct.1 高、pct.2 低——「我這群幾乎人人有、別群幾乎沒有」。

自測 2

下面哪一個最像「好 marker」的數字組合？

A $p=1e-250$ 、 $\log_2FC=0.3$ 、 $pct.1=0.99$ 、 $pct.2=0.97$

B $p=1e-90$ 、 $\log_2FC=3.8$ 、 $pct.1=0.94$ 、 $pct.2=0.05$

C $p=0.04$ 、 $\log_2FC=1.2$ 、 $pct.1=0.15$ 、 $pct.2=0.02$

D $p=1e-120$ 、 $\log_2FC=-2.5$ 、 $pct.1=0.10$ 、 $pct.2=0.88$

答 B。倍數差夠大、群內幾乎全表現、群外幾乎沒有——三個條件齊了， p 值只要過關就好。A 是持家基因的長相（雷一）；C 效果大但只有 15% 細胞表現，太弱；D 是「反向 marker」，別群才高。

自測 3

SingleR 說某群是 NK，但這群 CD3E、CD8A 明確陽性。正確的處置是？

- A 信 SingleR，它看的基因比較多
- B 信 marker：canonical marker 證據等級高於相似度分數，定為效應 CD8 T 並記錄裁決依據
- C 兩個標籤都寫進論文
- D 刪掉這個群，避免爭議

答 B。 CD3E 是 TCR 複合體的零件，NK 細胞沒有——這是教科書級的排他證據。效應 CD8 T 與 NK 共享胞殺程式（NKG7、GNLY），相似度分數會被騙，canonical marker 不會。同時檢查 delta：這種群的 delta 通常趴在地上。

下集預告

B11：多樣本整合與批次效應診斷

單一樣本到此完整走完。但你的實驗有處理組、對照組、三個批次——
兩批細胞在 UMAP 上各自成島：是批次效應要修掉，還是生物差異要保留？下一集：整合，以及什麼時候不該整合。