

B11 B 系列

多樣本整合： batch effect 與 Harmony


跑 Seurat v5 的 IntegrateLayers 與 Harmony，並且判斷得出「整合過頭了沒」。

約 40 分鐘 | 前置：B5-B10 | 資料：ifnb（對照 vs IFN- β 刺激）

兩個條件，各自成島

模擬資料

合併後直接跑 UMAP (未整合)



解讀一：這是 batch effect

技術差異把同一種細胞拆成兩坨，
應該用整合把它修掉

解讀二：這是生物差異

IFN- β 刺激本來就改變了全部細胞的
表達程式，分開才是對的

同一張圖，兩種解讀——都對

這是該修掉的 batch effect，還是該保留的刺激反應？兩種解讀都說得通

本集的起點

圖不會告訴你 哪些差異是技術、哪些是生物。

整合工具人人會跑。難的是知道它動了什麼、賭了什麼、什麼時候賭輸了。

這一集你會學到

- 1 用 ifnb 資料在 v5 的 layer 架構下跑 CCA、RPCA、Harmony 三種整合
- 2 說出批次效應與生物差異為什麼在圖上分不開、整合在賭什麼
- 3 用已知 marker 與混合度檢查整合品質，抓出「整合過頭」

01

batch effect 到底是什麼

先分清楚兩種差異，再談怎麼修

技術性差異 vs 生物性差異

技術性差異（想丟掉的）

- 實驗日期／操作者
- 試劑批號、解離條件
- 10x 化學版本（v2 / v3）
- 定序深度與機型

生物性差異（想研究的）

- 刺激 vs 對照（本集）
- 病人／個體
- 組織部位、疾病狀態
- 取樣時間點



兩種差異在 UMAP 上長得一模一樣——圖不會告訴你哪個是哪個；能分開它們的是實驗設計，不是演算法

你想丟掉左邊、留下右邊——但兩者在資料裡疊在一起


混淆了，就無解了

混淆設計：批次＝條件



技術與生物 100% 重疊
事後任何方法都拆不開

平衡設計：每批都有兩種條件



批次差異可以估計、可以校正
條件差異被保護下來

這一步發生在上機之前。設計混淆了，B11 的所有工具都救不了你。


批次＝條件的設計，任何整合方法都拆不開——這是實驗設計的事

本集核心觀念

整合在賭一件事： 兩批資料有「相同的細胞型別結構」。

賭對了，同型細胞對齊；賭錯了，真實的生物差異被抹掉。

整合的本質：把對應的型別拉到一起



整合的賭注：假設兩批有「相同的細胞型別結構」，把對應的型別拉到一起

假設錯了（某型別只在一批出現）→ 它會被硬塞給別人——這就是過度整合的來源

對齊的單位是「細胞型別」，不是「全部細胞」——這個區別是全集的鑰匙

為什麼這集不用 pbmc3k 了

pbmc3k：單一樣本



一個樣本、一個批次，
根本沒有 batch
effect 可以示範

ifnb：兩個條件




對照 vs IFN- β 刺激的
PBMC，13,999
顆細胞（Kang et
al. 2018）

而且自帶考題



條件差異是真生物—
—整合必須對齊型別、
又不能抹掉刺激

Seurat v5 的 layer 心智模型



校正結果活在 reduction 裡，不在表達值裡——JoinLayers 不會弄丟整合

split → 各自前處理 → IntegrateLayers → JoinLayers：整條流程的地圖

02

載入 ifnb , 拆成 layer

SeuratData 一行下載; split 一行拆層

載入 ifnb 資料集

```
library(Seurat)
library(SeuratData)
set.seed(1234) # 全系列固定，結果才能重現

# 第一次使用要先安裝資料集（約 100 MB，之後有快取）
# installData("ifnb")
ifnb <- LoadData("ifnb")
ifnb <- UpdateSeuratObject(ifnb) # 把舊版物件升級到 v5 結構
ifnb
```

An object of class Seurat
14053 features across 13999 samples within 1 assay
Active assay: RNA (14053 features, 0 variable features)
1 layer present: counts

13,999 顆 = 對照 6,548 + 刺激 7,451；條件標籤存在 ifnb\$stim

按條件拆 layer

```
table(ifnb$stim)          # 條件標籤: CTRL / STM
```

```
ifnb[["RNA"]] <- split(ifnb[["RNA"]], f = ifnb$stim)  
ifnb
```

CTRL STM

6548 7451

An object of class Seurat

14053 features across 13999 samples within 1 assay

4 layers present: counts.CTRL, counts.STM,
data.CTRL, data.STM

細胞一顆都沒動，只是同一個 assay 裡的資料被分抽屜放

前處理：每個 layer 各自跑

```
# split 狀態下，這四步會對每個 layer 「各自」執行
ifnb <- NormalizeData(ifnb)
ifnb <- FindVariableFeatures(ifnb)
ifnb <- ScaleData(ifnb)
ifnb <- RunPCA(ifnb)
```

```
Normalizing layer: counts.CTRL
Normalizing layer: counts.STM
Finding variable features for layer counts.CTRL
Finding variable features for layer counts.STM
...
```

訊息逐 layer 印出——這就是「各自處理」正在發生的證據

這一節做了什麼

一個物件



兩個條件住在同一個
Seurat 物件裡，各
佔幾個 layer

各自的前處理



HVG、scale、
PCA 都是每個條件
自己算自己的

還沒整合



下一步先看「不整合
會怎樣」——這步很
多人跳過

03

未整合的基線

先看問題長什麼樣，才知道整合改變了什麼

直接分群、直接畫 UMAP


```
ifnb <- FindNeighbors(ifnb, dims = 1:30, reduction = "pca")
ifnb <- FindClusters(ifnb, resolution = 0.5,
                     cluster.name = "unintegrated_clusters")
ifnb <- RunUMAP(ifnb, dims = 1:30, reduction = "pca",
               reduction.name = "umap.unintegrated")
DimPlot(ifnb, reduction = "umap.unintegrated",
        group.by = c("stim", "unintegrated_clusters"))
```

reduction 與 cluster 都取名字，之後才能跟整合後的版本並排對照


未整合：同型細胞被拆成兩坨

模擬資料

按條件上色



按細胞型別上色



● CTRL ● STIM ● 單核球樣 ● T 樣 ● B 樣 ● NK 樣 ● 刺激特異

左：按條件分成兩片領土。右：同一個型別在兩邊各出現一次

鐵則

**沒有這張未整合的圖，
你就無法判斷整合「改變了什麼」。**

這張圖是基線。把它存進物件裡，全集結束前我們會一直回頭看它。

04

IntegrateLayers：一個介面，三種方法

CCA、RPCA、Harmony——換方法只換一個參數

第一種： CCAIntegration

```
ifnb <- IntegrateLayers(  
  object      = ifnb,  
  method      = CCAIntegration,    # 換方法只換這裡  
  orig.reduction = "pca",          # 吃哪個未整合的降維  
  new.reduction = "integrated.cca", # 校正結果的名字  
  verbose      = FALSE  
)  
Reductions(ifnb)
```

```
[1] "pca"          "um ap .unintegrated"  
[3] "integrated.cca"
```

注意輸出：多了一個 reduction。表達值一個都沒被改

三種方法怎麼選

RPCAIntegration

互相投影到對方的 PCA 空間找 anchor

- 保守：不易過度校正
- 快，適合同平台多樣本
- 批次差很大時可能校不動

HarmonyIntegration

在 PC 空間迭代：軟分群 → 逐群校正

- 快、省記憶體、樣本多也撐得住
- 只輸出校正後嵌入 (reduction)
- 不產生校正後表達值

CCAIntegration

找兩批共同的變異方向再配 anchor

- 強：差異很大也拉得齊
- 慢、記憶體重
- 最容易過度校正

保守（校得少）

積極（校得多）

一條「校正強度」的光譜：RPCA 保守、Harmony 居中而快、CCA 強但易過頭

CCA vs RPCA：一體兩面

同一套 anchor 框架，找 anchor 的空間不同

CCA

找共同變異方向

- 條件差異大時仍能對齊（本集情境）
- 計算慢、記憶體重
- 代價：最容易過度校正

RPCA

互相投影對方的 PCA

- 保守：不易把生物差異校掉
- 快，適合同平台、多樣本
- 批次差異太大時可能校不動

Harmony 與 RPCA：各一行

```
# install.packages("harmony") # Harmony 後端要另外裝
ifnb <- IntegrateLayers(ifnb, method = HarmonyIntegration,
                        orig.reduction = "pca",
                        new.reduction = "harmony")
ifnb <- IntegrateLayers(ifnb, method = RPCAIntegration,
                        orig.reduction = "pca",
                        new.reduction = "integrated.rpca")
Reductions(ifnb)
```


```
[1] "pca"          "um ap.unintegrated"
[3] "integrated.cca" "harmony"
[5] "integrated.rpca"
```

三個校正版本共存在同一個物件裡，下游要用哪個自己指定

Harmony 在做什麼

模擬資料

校正前：每群裡兩批錯開




① 軟分群（跨批次一起分）

② 算每群內各批次的偏移

③ 把各批次往群中心拉

④ 重複，直到批次混勻收斂

收斂後：批次在群內混勻



全部發生在 PC 空間（低維、快）；輸出是一個新的 reduction，叫 harmony

在 PC 空間反覆「分群 → 逐群把各批次拉向群中心」，快而省記憶體

整合後的下游：指定 reduction


```
ifnb <- FindNeighbors(ifnb, reduction = "ham ony",  
                      dims = 1:30)  
ifnb <- FindClusters(ifnb, resolution = 0.5,  
                     cluster.name = "ham ony_clusters")  
ifnb <- RunUMAP(ifnb, reduction = "ham ony", dims = 1:30,  
                reduction.name = "um ap.ham ony")  
DimPlot(ifnb, reduction = "um ap.ham ony",  
         group.by = c("stim ", "ham ony_clusters"))
```

跟 B8、B9 完全同一套動作，唯一差別：reduction 從 pca 換成 harmony


整合前後

模擬資料

整合前：按條件分開



整合後 (Harmony)：條件混合



● CTRL

● STIM

同型細胞跨條件疊在一起了；刺激特異族群仍自成一群——這才叫成功

JoinLayers : 把抽屜合回來

```
ifnb <- JoinLayers(ifnb)  
ifnb
```

An object of class Seurat
14053 features across 13999 samples within 1 assay
Active assay: RNA (14053 features, 2000 variable features)
2 layers present: data, counts

時機：整合與分群做完、要做 DE 或 marker 檢定之前

這一節做了什麼

三種整合



CCA、RPCA、
Harmony 各產生一
個新 reduction

下游換座標



分群與 UMAP 改吃
harmony；表達值
從頭到尾沒動過

layer 合回



JoinLayers 合併
counts 與 data；
校正安全地住在
reduction 裡

05

整合做完，做得好嗎？

三個檢查：看圖、算比例、問 marker

檢查一與二：分開看、數字化

1. 分開畫：同一群應該出現在兩邊的同一個位置

```
Dim Plot(ifnb, reduction = "um ap.harm ony", split.by = "stim ")
```


2. 每群的條件組成：大群應該接近對半

```
prop.table(table(ifnb$ham ony_clusters, ifnb$stim ),  
            margin = 1) |> round(2)
```

	CTRL	STM
0	0.47	0.53
1	0.52	0.48
2	0.49	0.51
3	0.55	0.45
4	0.31	0.69

偏斜特別大的群不是整合失敗的證據——先去查它的 marker 再說

檢查三：已知 marker 跨條件對齊



模擬資料


CD14、CD3D、MS4A1——同一個 marker 在兩個條件亮同一個位置

量化混合度：LISI 與 kBET 的直覺


模擬資料

沒混合：鄰居幾乎全是同一批

混合好：鄰居一半一半



$LISI \approx 1$ (鄰域裡只「看得到」1個批次)



$LISI \approx 2$ (鄰域裡看得到2個批次)

兩個常見指標

LISI

鄰域裡「有效批次數」，
越接近批次總數越混勻

kBET

檢定鄰域的批次比例
是否符合全體比例

小心：混合度只該在「同型細胞」裡看——全圖完全混勻，反而可能是校過頭

概念知道就好，本集不實作——重點是「混合度要在同型細胞裡看」

評估的黃金句

**整合是讓「同型細胞」對齊，
不是讓「條件差異」消失。**

刺激 vs 對照本來就該有差異。全部混勻不是成功，是警報。

這一節做了什麼

三個檢查



split 圖、每群條件
比例、已知 marker
的位置

一隻金絲雀



該存在的條件特異族
群還活著，就還沒校
過頭

兩個名詞



LISI 與 kBET：混
合度的量化指標，概
念先放口袋

06

踩雷區

三個雷，每一個都把後果攤開來看

雷一：跳過未整合的基線

雷是什麼

拿到多樣本資料，第一件事就是跑整合，從來沒看過未整合的圖。



為什麼會踩

教學範例都直接整合，看起來像是「標準流程的第一步」。

踩了會怎樣

整合永遠會給你一張「混得很好」的圖——但你不知道它修了什麼、修得對不對，也講不出資料原本的問題有多嚴重。

一行保險：把基線存進物件

```
# 整合前，先把未整合的 UMAP 以獨立名字存好（本集已做）
ifnb <- RunUMAP(ifnb, dims = 1:30, reduction = "pca",
               reduction.name = "umap.unintegrated")
```

```
# 之後任何時候都能一秒對照
```

```
DimPlot(ifnb, reduction = "umap.unintegrated",
        group.by = "stim") |
DimPlot(ifnb, reduction = "umap.harmoney",
        group.by = "stim")
```

reduction 不佔多少記憶體；名字取好，前後對照永遠只差一行

雷二：把生物差異當 batch 校掉

雷是什麼

看到任何分開就想整合抹平——包括刺激 vs 對照這種真實差異。



為什麼會踩

「圖上分開 = batch effect」的直覺很誘人；強方法（CCA）又真的抹得平。

踩了會怎樣

刺激特異的活化族群被硬塞進對照的群裡，「刺激造成了什麼」這個問題再也答不出來——你研究的東西被前處理刪掉了。

金絲雀測試


模擬資料

你早知道該存在的「條件特異族群」，就是整合的金絲雀——它消失，代表校過頭了

未整合



適度整合



過度整合



金絲雀還在：自成一群✓

金絲雀被塞進別群：訊號沒了

● CTRL

● STIM

● 刺激特異族群（金絲雀）

你早知道該存在的條件特異族群＝金絲雀。牠消失，就是校過頭的鐵證

雷三：拿校正後的值去做 DE

雷是什麼

整合完，直接在 integrated assay 或校正輸出上跑 FindMarkers 比較條件。




為什麼會踩

v4 時代的 IntegrateData 會產生一個 integrated assay，長得就像表達值，順手就用了。

踩了會怎樣

校正把變異壓縮、又在細胞之間互相借了資訊——檢定的前提全毀，p 值不可信。DE 一律回 RNA 的表達值做。

幾何用整合，統計回 RNA



口訣：整合的成果用在「幾何」（距離、分群、圖），statistics 回「原始表達值」（B12 續）

v5 的 IntegrateLayers 只給 reduction，幫你擋掉半個雷——另外半個是忘記 JoinLayers

踩雷區小結

**整合是「借來的對齊」，
不是新的測量。**

用它排版面（距離、分群、圖），別用它算統計——測量值永遠在 RNA layer 裡。

5+

複雜樣本策略室


標準流程走完了——現在想像兩個 layer 不是 CTRL 與 STIM，是四位病人的腫瘤

整合兩難：TME 要對齊，惡性不能硬拉


整合空間只拿來對齊、註釋正常細胞；惡性細胞回未整合空間、按病人分開看

模擬資料


未整合・按病人上色



整合後・按病人上色



整合後・按型別上色



惡性：一人一島（CNV 不同）

TME：跨病人本來就混

● 病人 1

● 病人 2

● 病人 3

● 病人 4

● 惡性

● 免疫

● 寡樹突

惡性被拉成一團＝病人差異被抹掉

圖「乾淨」了——但代價已經付了

免疫與基質跨病人是同一種東西——該對齊；惡性細胞帶著各自的 CNV——被拉成一團就是抹掉生物學

策略表：整合什麼、不整合什麼

兩難的解法不是換更聰明的方法，是限制整合空間的用途

細胞	用哪個空間	為什麼
免疫細胞	整合空間：對齊＋註釋	跨病人是同一種東西，差異主要是技術的
基質、血管、寡樹突等正常細胞	整合空間：同一套邏輯	正常細胞的亞群註釋也在這裡做
惡性細胞	未整合空間： per-patient 各自分析	跨病人是不同的東西——差異是 CNV ，不是 batch
跨病人比較惡性	比狀態分數／ meta-program ，不比分群	Tirosh、Neftel、Puram 等腫瘤圖譜的標準做法

不同腫瘤，不同整合戰法

GBM：策略表直接套用



惡性一人一島、CNV 明確——TME 走整合空間，惡性 per-patient

血液腫瘤：惡性像正常



AML 惡性像正常前驅、CNV 常乾淨，「一人一島」訊號消失——靠正常骨髓參照與分化阻滯


多區域：同病人可整合



同一位病人的 core 與 margin 共享 CNV 家系，可以整合；病人之間仍分開

正負對照與 LISI 判讀

模擬資料



負對照多半不會「通過」——比較整合方法時，比的是誰失得少，不是誰過關

正對照（免疫）的 LISI 要上升、負對照（惡性）要盡量不動——選整合方法比的是「誰失得少」

參考圖譜 label transfer：另一條路

正常細胞：投影 繼承標籤



Azimuth /
MapQuery 投上現
成圖譜，免疫亞群註
釋最省事也更準

惡性細胞：不能 投影



圖譜裡沒有這位病人
的腫瘤——GBM 常
被標成星狀細胞或
OPC；是提醒，不是
答案

惡性判定：交給 CNV



按病人分群 + CNV
+ 譜系，三角驗證—
— B16 整集處理

本集 checklist



實驗設計先確認：批次與條件有沒有混淆



整合前留了一張未整合 UMAP 當基線



取捨說得出來：RPCA 保守／Harmony 快／CCA 強



整合後用已知 marker 檢查同型細胞跨條件對齊



金絲雀還活著：條件特異族群沒有被抹掉



DE 之前 JoinLayers，統計回 RNA 的表達值做

六格全勾，才進 B12

一句話總結

**先看未整合的基線，再整合；
整合後，用金絲雀驗收。**

同型細胞要對齊，條件差異要活著，DE 要回 RNA。三句話就是全集。

自測 1

未整合的 **UMAP** 上，兩個條件各自成島。這代表什麼？

- A 一定是 batch effect，該整合掉
- B 一定是生物差異，該保留
- C 技術與生物差異都會長這樣，光看圖分不開
- D UMAP 參數設錯了

答 C。分開只是「有很大的差異」，圖不會告訴你差異的來源。判斷靠實驗設計（批次與條件有沒有混淆）與領域知識，不靠圖。

自測 2

關於三種整合方法，哪個敘述正確？

- A CCA 最保守，幾乎不會過度校正
- B RPCA 最強，適合差異極大的批次
- C Harmony 只輸出校正後的嵌入，不產生校正後的表達值
- D 三種方法都會改動 counts

答 C。Harmony 在 PC 空間迭代校正，產物是一個新 reduction。A 與 B 剛好說反：CCA 強而易過頭、RPCA 保守；v5 的三種方法都不動 counts。

自測 3

整合後有一群 98% 是 STIM 細胞，top marker 是 ISG15 等干擾素反應基因。你該？

- A 換更強的整合方法把它混勻
- B 當作整合失敗，重跑
- C 保留它——條件特異族群本來就該分開，這是生物訊號
- D 把這群刪掉再分析

答 C。干擾素反應正是刺激該做的事，這一群是「金絲雀活著」的證明。A 是雷二本人：硬混勻等於把研究問題校掉。

下集預告

B12：差異表達的正確做法

兩組對齊了，該回答老闆真正的問題：刺激改變了哪些基因？

直接 FindMarkers，三千個基因顯著、p 值小到 $1e-200$ ——先別高興。為什麼那是統計幻覺？