

B12 B 系列


差異表達的正確做法： **pseudobulk + DESeq2**

為什麼 FindMarkers 直接比條件會給你三千個「顯著」基因——而其中大半是統計幻覺。

約 40 分鐘 | 前置: B11 | 資料: ifnb (IFN- β 刺激 vs 對照) | 主線 B1-B12 收官

三千個顯著基因，p 值小到 1e-200

FindMarkers：把 2,700 顆細胞當獨立樣本



模擬資料：8+8 個樣本、有 donor 變異、12% 基因有真效應

顯著基因

303 / 900

其中 205 個其實沒有條件效應

最小 p 值

~1e-320

小到超出浮點數下限

stim vs ctrl 直接跑 FindMarkers：結果漂亮到不像話——這正是問題所在

本集的起點

**p 值不是太好，
是好到根本不可能。**

一個 16 人的實驗， $p = 1e-200$ 意味著什麼？意味著檢定在數錯東西。

這一集你會學到

- 1 區分兩種 DE 問題：群 vs 群找 marker、同型細胞跨條件比較
- 2 說出 pseudoreplication 讓 p 值膨脹的機制，並用模擬親眼看到它
- 3 實作 AggregateExpression → DESeq2 全流程，正確判讀火山圖與結果表


01

你在問哪一種差異？

兩個長得很像的問題，統計單位完全不同

兩種 DE 問題，兩套工具

問題一：這一群是什麼？




cluster A vs cluster B
(同一批樣本裡的兩群)

FindMarkers 可以用

B10 做過：找 marker、給群命名

問題二：刺激改變了什麼？



同型細胞，CTRL vs STIM
(跨樣本、跨條件)

pseudobulk + DESeq2


本集：結論要推廣到「處理」本身

兩個問題長得很像，但「一個觀察值」是什麼完全不同——工具也不同

marker 尋找 B10 做過；本集的問題是「刺激改變了什麼」——結論要推廣到處理本身


獨立的單位是樣本，不是細胞

CTRL



VS

STIM



統計看的：獨立的生物重複

$n = 3$ vs 3 (樣本)

細胞層級檢定看的：每顆細胞算一票

「 $n = 12,000$ vs $13,000$ 」？



同一個樣本的細胞彼此相似、共享 donor 與批次——它們不是獨立觀察值


同一個樣本的三萬顆細胞共享 donor 與批次——把它們當 n ，就是 pseudoreplication

親眼看 p 值膨脹

模擬資料

細胞層級 wilcoxon (naive)

802 個無效應基因中 205 個被判顯著 (BH 後)




這些基因的條件效應是零——理想的 p 值分布應該貼著虛線（均勻）

模擬：條件效應為零的基因，細胞層級檢定照樣判出兩百多個「顯著」

pseudobulk（樣本層級）

802 個無效應基因中 9 個被判顯著 (BH 後)




本集核心觀念

生物重複是樣本。 細胞只是同一個樣本的重複測量。

A1 講過 $n=1$ 的故事。三萬顆細胞不會把 $n=8$ 變成 $n=30,000$ 。

pseudobulk：把資料變回「每樣本一欄」



dropout 的零被加總吸收、獨立單位變回樣本——兩個問題一次解決

依樣本 × 細胞型別把 counts 加總，然後把矩陣交給成熟的 bulk 統計

pseudobulk 一次解決三件事

n 誠實了



檢定單位回到樣本，
p 值回到能相信的量
級

零被吸收了



加總後不再是稀疏矩
陣， dropout 不需
要特殊模型

統計是現成的



DESeq2 / edgeR
十多年的方法學直接
繼承

02

載入資料，先跑一次天真做法

留著這個結果，等一下打臉用

承接 B11：讀入整合後的 ifnb

```
library(Seurat)
set.seed(1234) # 全系列固定 seed

ifnb <- readRDS("output/ifnb_b11_integrated.rds")
ifnb <- JoinLayers(ifnb, assay = "RNA") # 把 split 的 layer 合回來
table(ifnb$stim)
```

CTRL STM
6548 7451

DE 用的是 RNA assay；JoinLayers 把 B11 拆開的 counts 層合回一份

天真做法： FindMarkers 直接比條件

```
Idents(ifnb) <- "seurat_annotations"  
m_ono <- subset(ifnb, idents = "CD14 Mono") # 先鎖定同一型細胞  
Idents(m_ono) <- "stim "  
  
naive <- FindMarkers(m_ono, ident.1 = "STM ", ident.2 = "CTRL")  
head(naive, 3)  
sum(naive$p_val_adj < 0.05)
```

```
      p_val avg_log2FC pct.1 pct.2 p_val_adj  
ISG15      0      4.98 0.998 0.229      0  
IFI3       0      4.50 0.964 0.052      0  
IFI6       0      4.38 0.969 0.080      0  
[1] 3187
```

預設 wilcox 檢定，每顆細胞當一個觀察值—— 3,187 個顯著基因，p 直接歸零

把這三個數字記下來

3,187 個顯著



超過檢定基因的三分之一都「有差異」

p_val = 0



小到 R 的浮點數存不下——不是真的零

等一下對帳



pseudobulk 跑完，
回來看這份名單縮成多少


03

AggregateExpression：做出 pseudobulk 矩陣

樣本 × 細胞型別，一組一欄

group.by 的三把鑰匙

```
group.by = c("seurat_annotations", "stim", "donor_id")
```



加總的是 RNA assay 的原始 counts——不是 data、不是 scale.data、更不是 integrated

CD14 Mono : 8 個 CTRL 欄 + 8 個 STIM 欄 → 給 DESeq2 的 16 個「樣本」

ifnb 的 donor 資訊來自 demuxlet (Kang et al. 2018) ; R 腳本附下載與比對程式碼

依 型別 × 條件 × donor 加總

```
# donor_id 欄位的建立見 R/B12_pseudobulk_de.R 第 2 節
pseudo <- AggregateExpression(ifnb, assays = "RNA",
                              group.by = c("seurat_annotations", "stim ", "donor_id"))
counts <- pseudo$RNA
dim (counts)
```

```
[1] 14053  198
```

14,053 個基因 × 198 欄： 13 種細胞型別 × 2 條件 × 8 donor（部分組合沒細胞）

取出 CD14 Mono ，整理樣本表

```
cd14 <- counts[,grep("^CD14 Mono_", colnames(counts))]  
colnames(cd14)[1:2]  
parts <- strsplit(colnames(cd14), "_")  
coldata <- data.frame(  
  condition = factor(sapply(parts, `[`, 2),  
                     levels = c("CTRL", "STM")),  
  donor     = sapply(parts, `[`, 3),  
  row.names = colnames(cd14))  
table(coldata$condition)
```

```
[1] "CD14 Mono_CTRL_101" "CD14 Mono_CTRL_1015"  
CTRL STM  
8 8
```

16 個 pseudobulk 樣本： $n = 8$ vs 8 。這才是 DESeq2 該看到的世界

這一節的鐵則

**pseudobulk 加總的是 RNA assay 的
原始 counts—— 不是任何校正值。**

integrated、scale.data 都不行。B11 的雷三在這裡正式接上本集。

04


DESeq2：三行程式碼的成熟統計

DESeqDataSetFromMatrix → DESeq → results

整條 DESeq2 流程

DESeq2：bulk RNA-seq 十年的統計功力，pseudobulk 直接繼承

負二項分布模型 + 樣本間變異估計——這正是細胞層級檢定缺的兩塊



整條流程三行程式碼；每一步的數學 C 系列會算給你看

負二項模型加上樣本間變異估計——正是細胞層級檢定缺的兩塊

建立 DESeqDataSet

```
library(DESeq2)
keep <- rowSums(cd14) >= 10      # 全部樣本加起來不到 10 個
                                # counts 的基因，先剔除
dds <- DESeqDataSetFromMatrix(countData = cd14[keep, ],
                              colData = colData,
                              design = ~ condition)

dds
```

```
class: DESeqDataSet
dim: 12446 16
colData names(2): condition donor
```

design = ~ condition : 「表現量由條件解釋」。design 是模型宣告，不是選項


一行跑完估計與檢定

```
dds <- DESeq(dds)
```

```
estimating size factors  
estimating dispersions  
gene-wise dispersion estimates  
mean-dispersion relationship  
final dispersion estimates  
fitting model and testing
```

這六行訊息就是流程圖的六步； size factor 與離散度都在這裡估完

離散度收縮：小樣本的保命裝置



為什麼要收縮？

16 個樣本估不準
單一基因的變異；
向全體趨勢「借力」
穩住估計

模擬資料

16 個樣本估不準單一基因的變異；向全體趨勢「借力」，估計才穩得住

取結果，看總覽

```
res <- results(dds, contrast = c("condition", "STM ", "CTRL"),  
               alpha = 0.05)  
summary(res)
```

```
out of 12446 with nonzero total read count  
adjusted p-value < 0.05  
LFC > 0 (up)      : 1024, 8.2%  
LFC < 0 (down)    : 906, 7.3%  
low counts [2]    : 2413, 19%
```

上調加下調約 1,930 個——跟天真做法的 3,187 對帳，差了一個量級的假陽性

results 表逐欄讀

results() 的一列 = 一個基因的完整判決書

	baseMean	log2FoldChange	lfcSE	pvalue	padj
ISG15	6006.7	8.01	0.29	1.9e-165	2.1e-161
IFIT1	2929.5	8.75	0.38	1.1e-119	6.2e-116
IFIT3	3622.8	7.13	0.30	4.9e-125	3.7e-121
CXCL10	1274.2	6.42	0.41	3.5e-62	8.8e-59

↑
所有樣本的平均
表現量：判斷這個基因
「量夠不夠」

↑
效應量：STIM 對 CTRL
的 log2 倍數變化
(判讀主角之一)

↑
log2FC 的
標準誤

↑
未校正 p 值
(不能拿來篩)

↑
BH 多重檢定校正後
——篩選看這一欄

判讀鐵三角：padj 把關 → log2FC 看效應 → baseMean 看表現量夠不夠

判讀鐵三角： padj 把關、 log2FC 看效應、 baseMean 看表現量夠不夠

lfcShrink : 把不可靠的大 FC 收回來

```
res.shr <- lfcShrink(dds, coef = "condition_STM_vs_CTRL",  
                    type = "apeglm")  
head(res.shr[order(res.shr$padj), ], 3)
```

	baseMean	log2FoldChange	lfcSE	pvalue	padj
ISG15	6006.7	8.01	0.293	1.9e-165	2.1e-161
IFIT1	2929.5	8.75	0.375	1.1e-119	6.2e-116
IFIT3	3622.8	7.13	0.300	4.9e-125	3.7e-121

低表現基因的誇張 FC 被往 0 收；干擾素刺激基因 ISG15 / IFIT 家族穩坐榜首

這一節做了什麼

一個 dds 物件



counts + 樣本表 +
design , 三位一體

一份結果表



12,446 個基因，每
個一列判決

一個習慣



報告用 shrink 後的
log2FC , 排序不再
被雜訊綁架



05

對帳與判讀

naive vs pseudobulk，然後把結果變成圖

對帳結果：差一個數量級

顯著基因數：差一個數量級



模擬資料

紅帶上的基因：naive 說顯著、pseudobulk 說沒有——它們多半是 donor 變異，不是刺激效應


火山圖：十行 ggplot

```
library(ggplot2)
df <- as.data.frame(res.shr)
df$sig <- !is.na(df$padj) & df$padj < 0.05 &
  abs(df$log2FoldChange) > 1
ggplot(df, aes(log2FoldChange, -log10(padj), colour = sig)) +
  geom_point(size = 0.6) +
  scale_colour_manual(values = c("grey70", "#C0392B")) +
  geom_vline(xintercept = c(-1, 1), linetype = 2) +
  geom_hline(yintercept = -log10(0.05), linetype = 2) +
  theme_classic()
```

顯著的定義寫在程式碼裡： $padj < 0.05$ 「而且」 $|\log_2FC| > 1$ ，兩關都要過

火山圖怎麼讀

pseudobulk + 檢定後的火山圖：一點 = 一個基因



報告時同時交代



- padj 閾值 (0.05)
- $\log_2 \text{FC}$ 閾值 ($|\text{FC}| > 1$)
- 上調 / 下調基因數

模擬資料

一點一基因；右上紅色是刺激誘導、左上藍色是刺激壓抑；報告時三個數字都要交代

發表前的最後一關：每樣本一個點

模擬資料



發表前的最後一關：把「每個樣本」畫成一個點——差異要在樣本層級站得住

真差異在樣本層級站得住；假訊號在這張圖上原形畢露——投稿前把 top 基因都畫一遍

寫進論文的方法段

**「以 AggregateExpression 依樣本 × 型別加總
counts ,
用 DESeq2 檢定, BH 校正, $\text{padj} < 0.05$ 且 $|\log_2\text{FC}| > 1$ 。」**

一句話講清楚單位、工具、校正與閾值——審稿人要的四件事都在。

06

踩雷區

三個雷，每一個都實際跑給你看

雷一：拿 integrated 值做 DE

雷是什麼

B11 整合做完，順手把 integrated assay 的值餵給差異表達。



為什麼會踩


「整合後的資料比較乾淨」聽起來很合理。

踩了會怎樣

校正值連批次帶條件差一起抹、可為負、非整數——DESeq2 直接報錯，硬轉還會做出假訊號。


counts 與 corrected 值，長相就不同

RNA layer 的 counts



counts：整數、非負——DESeq2 的模型就是為它設計的

integrated 的「表現量」



corrected 值：連續、可為負，批次差與部分條件差已被模型抹掉

integrated 值是「畫 UMAP 用的座標」，不是表現量——DE 一律回 RNA assay 的 counts

integrated 值是畫 UMAP 用的座標，不是表現量——DE 一律回 RNA assay 的 counts

雷二：沒有生物重複也硬做

雷是什麼

只依條件聚合：CTRL 一欄、STIM 一欄， $n = 1$ vs 1 也照跑統計。



為什麼會踩


「反正 pseudobulk 就是要把細胞縮成樣本」，縮到底好像也行。

踩了會怎樣

組內變異無從估計，DESeq2 直接拒跑；ifnb 靠 demuxlet 才有 8 個 donor 可用——你的實驗要在設計時就準備 n 。

n 是設計出來的，不是算出來的

ifnb 表面上：n = 1 vs 1



每條件 1 個生物重複

一管 CTRL、一管 STIM
組內變異根本無從估計
DESeq2 直接拒跑

加上 demuxlet donor : 8 vs 8



每條件 8 個生物重複

8 位捐贈者混樣上機
遺傳變異拆回個人
本集示範的做法

你的實驗：設計時就決定 n



每條件 3 個生物重複

每條件至少 3 個生物重複
定序後才想補 n 已經太遲

pseudobulk 不會變出重複：樣本設計裡沒有的 n，任何統計都補不回來

每條件至少三個生物重複；定序完才想補 n，任何統計都救不回來

雷三：火山圖只看 p ，不看效應與表現量

雷是什麼

結果表按 p_{adj} 排序，前十名直接寫進論文。



為什麼會踩



「 p 最小的就是最重要的」——從第一堂統計課帶來的直覺。

踩了會怎樣

低表現高變異基因混進榜單：兩三個樣本撐起整個 FC，換一批樣本就消失。

$p = 0.002$ 的基因，真面目可以很難看

模擬資料



低表現基因的 FC 分母很小、一顆雜訊就能翻倍——看 FC 之前先看 baseMean 與每樣本 counts

看 FC 之前先看 baseMean 與每樣本 counts——一顆雜訊就能讓低表現基因翻倍

踩雷區小結

DE 的三個守門員： RNA counts、真實的 n 、效應量。

資料層對了、樣本數誠實了、效應量看過了—— p 值才有資格說話。


06+

複雜樣本策略室

同一套 pseudobulk，換到多病人腫瘤的核心 vs 邊緣——決策哪裡不同、為什麼

病人是統計單位——腫瘤把假重複放大

cell-level 檢定以為的 $n=2,400$



核心 1,200 顆

邊緣 1,200 顆


Wilcoxon : 3,486 個「顯著」

真實的設計： $n=4$ 對病人



pseudobulk+配對 DESeq2 : 608 個

為什麼腫瘤更兇？



同病人的細胞共享整套 CNV——
相關性比 PBMC 更高，
把細胞當 n ，灌水更嚴重

示意；顯著基因數出自 GSE84465 免疫細胞 core vs margin 實跑

同一位病人的惡性細胞共享同一套 CNV，相關性比 PBMC 細胞更高—— n 是 4 對病人，不是 2,400 顆細胞

每種型別各自比 + 兩道門檻

GBM 四病人核心 vs 邊緣資料 (GSE84465) 的實戰教訓

混合 = 比組成



全部細胞一起 DE ,
榜首是 MBP /
PLP1——那是邊緣
寡樹突多, 不是表達
變化; 分型別後
MBP 完全不動

MIN_CELLS = 20



每個「病人 × 部位」
至少 20 顆才算一個
pseudobulk 樣本——
三顆細胞加總出的
「bulk」是噪音

MIN_PAIRS = 2



至少兩位病人兩部位
都過關, 配對才成立;
那份 GBM 資料只有
免疫細胞過門檻——
邊緣的惡性細胞全部
只有 31 顆

配對設計的統計紅利

同病人 core vs margin : design 從 $\sim$ condition 長成 $\sim$ patient + tissue

跨病人比較

病人差異全灌進誤差項

- GBM 病人間差異巨大—— B11 看過：惡性細胞按病人成島
- 部位效應要跟病人變異拔河，中等效應幾乎看不到
- 需要的病人數比配對設計多得多

同病人配對

先吸掉病人差異，再比部位

- design = $\sim$ patient + tissue : 病人項先把個體差異扣掉
- 4 對病人就抓得到大效應；免疫細胞 4 對跑出 608 個顯著基因
- 中等效應仍要約十對以上——多一位病人比多一萬顆細胞值

不能 pseudobulk 的備案：三道防線

湊不出 MIN_PAIRS 就退回 cell-level——但定位永遠是「假說產生」，不是結論

防線	做法	它抓出什麼
① 病人當共變量	MAST，latent.vars = patient；與預設 Wilcoxon 對照	只在 Wilcoxon 榜上的基因＝病人差異假扮的差異（如 XIST：其實是性別）
② 逐病人一致性	top 基因每位病人各算一次 logFC，方向全一致才留	靠單一病人撐起的「差異」；整欄 NA＝「為何不能 pseudobulk」的視覺化
③ 標籤置換	條件標籤在病人內打散重跑（正式分析 ≥ 100 次），比對真實顯著數	真訊號應遠多於置換值；病人與條件幾乎重合時，置換本身沒有鑑別力

三種 log2FC ，各自何時報

同一個 DESeq2 結果裡就有三個效應量，各有崗位，別混用


哪一個	性質	用在哪
未收縮 log2FC	results() 直接給；低 count 基因 FC 大、SE 也大	火山圖橫軸——火山圖要的就是原始形狀
Wald stat	$\log_2FC \div SE$ ：效應量與不確定性一起帶，幾乎不同分	GSEA 的排序統計量（B13 用它）
收縮後 log2FC	小 n 下穩定：保留大效應、壓掉雜訊	報告效應量、挑驗證基因——論文表格用它
收縮方法怎麼選	apegln 在只有 8 個樣本（4 對）時先驗太強，LFC 會壓成一根柱	本集 16 個樣本用 apegln 沒事；腫瘤配對常只有 3-5 對，改用 ashr

B 系列全景地圖：主線走完了

上游 B1-B4：從 FASTQ 到 count 矩陣



核心流程 B5-B10



應用 B11-B12

你這裡

下一集

DE 給了你一張基因清單——B-IV 進階下游回答「然後呢」：



主線 B1-B12 已走完；B13-B19 依研究問題選修（B19 是橫貫的策略總論，建議 B17→B19→B18），收官在 B18

十九集地圖：主線 B1-B12 已全部走完，B13-B19 進階下游依研究問題選修（B19 是橫貫的策略總論）

一句話總結

**把細胞加總回樣本，
把統計交還給樣本。**

pseudobulk 不是新方法，是把單細胞資料放回正確統計單位的翻譯器。

自測 1

同一群 CD14 Mono，比較 STIM 與 CTRL 的表達差異，該用哪套做法？

- A FindMarkers 預設 wilcox，細胞當觀察值
- B AggregateExpression 加總後用 DESeq2
- C 在 integrated assay 上跑 FindMarkers
- D 每群抽 100 顆細胞再跑 wilcox

答 B。跨條件比較的獨立單位是樣本，先依樣本 × 型別把 RNA counts 加總，再用 DESeq2 檢定。A 與 D 都把細胞當 n——抽樣只是把膨脹的 n 變小，單位還是錯的；C 用了校正值，資料層就錯了。

自測 2

為什麼細胞層級檢定的 p 值會膨脹到 $1e-200$?

- A wilcox 檢定本身有 bug
- B 定序深度不夠，雜訊太大
- C 同樣本的細胞不獨立，卻被當成上萬個獨立觀察值
- D 多重檢定校正做得不夠嚴格

答 C。檢定力隨 n 暴漲，而細胞共享 donor 與批次效應、彼此相關——有效樣本數其實是 8 對 8。donor 間的生物變異被誤讀成條件效應，連零效應基因都能拿到天文級 p 值。A、B、D 都碰不到「單位錯了」這個核心。

自測 3

pseudobulk 結果：某基因 $\text{padj} = 1\text{e-}8$ 、 $\log_2\text{FC} = 3.9$ 、 $\text{baseMean} = 2.1$ 。下一步？

- A 效應大又顯著，直接寫進結果
- B 看每樣本 counts：低表現基因的大 FC 可能是少數樣本撐的
- C padj 夠小，不用再看別的欄位
- D 把 $\log_2\text{FC}$ 閾值調高到 4 重篩一次

答 B。 $\text{baseMean} 2.1$ 代表平均每樣本才兩個 counts——分母極小，一顆雜訊就能翻出 $\log_2\text{FC} 3.9$ 。把 16 個樣本的 counts 畫出來：差異若只由兩三個樣本撐起，這個基因就不該當主角。A 與 C 正是雷三；D 是用另一個任意閾值掩蓋問題。

主線完結 · 下一集 B13

主線走完了，路才剛開始

DE 給了你一張基因清單——下一集 B13 回答：所以生物學上發生了什麼？功能富集與基因集分析。之後 B14 通訊、B15 軌跡、B16 inferCNV、B17 反卷積依需求選修，系列完整收官在 B18。我們 B13 見。