

B13 B 系列


DE 之後： 功能富集與基因集分析

把 1,930 個基因變成一句生物學結論——而且不掉進富集分析的經典陷阱。

約 40 分鐘 | 前置：B12 | 資料：ifnb（承接 B12 的 DE 結果）

火山圖之後，審稿人的問題

B12 的 pseudobulk 火山圖 (CD14 Mono)



IFIT1 IFI6 LY6E
IFI35 STAT1 LY6E
BST2 RSAD2 IFITM3
BST2 LY6E IFI6
SAMD9 IFITM3 CXCL10
STAT1 BST2 IFITM3
PLS
BST
IFI
...

審稿人：
「所以，生物學上
發生了什麼？」

把 1,930 個名字唸一遍，不是答案

B12 給了你 1,930 個顯著基因。然後呢？

本集的起點

基因清單不是結論。 從清單到生物學，中間還有一步。

這一步叫富集分析：拿幾十年累積的基因集知識，來問你的清單「像什麼」。

這一集你會學到

- 1 分清 ORA 與 GSEA 各自回答什麼問題、什麼時候用哪個
- 2 用 fgsea + Hallmark 對 B12 的 DE 結果實跑 GSEA，讀懂 NES 與 leading edge
- 3 在單細胞層級用 AddModuleScore / AUCell 給細胞打基因集分數並正確解讀

01

基因集：把先驗知識封裝起來

兩種問法：ORA 問名單，GSEA 問排序

四個你會一直遇到的資料庫

GO

基因功能的「受控詞彙」
三支：BP／MF／CC

GO Consortium 維護
數萬條術語、階層結構

KEGG

人工繪製的通路「地圖」
代謝與訊號傳遞為主

KEGG（京都）維護
數百條通路

Reactome

反應層級的通路資料庫
逐條人工彙編、開放

Reactome 團隊維護
涵蓋訊號到代謝

MSigDB

集大成的「基因集超市」
Hallmark 是它的精選櫃

Broad／UCSD 維護
三萬多個基因集、分館

基因集＝一份「有共同功能標籤的基因名單」——把幾十年的生物學知識封裝起來

它們封裝的都是同一種東西：一份有功能標籤的基因名單

MSigDB 與 Hallmark：起手式

MSigDB 的分館（節選）

H	Hallmark：50 個精選集
C2	curated：含 KEGG、Reactome
C5	ontology：GO 全套
C7	immunologic：免疫特徵集
C8	cell type：細胞型別特徵集

為什麼起手式選 Hallmark？


- ✓ 只有 50 個集，一張表看得完
- ✓ 刻意去冗餘：一個生物過程一個集
- ✓ 名字直白：INTERFERON_ALPHA_RESPONSE
- ✓ 先用它定方向，再進 GO／Reactome 挖細節

例：HALLMARK_INTERFERON_ALPHA_RESPONSE（97 個基因）

- MSigDB 把各家基因集收進同一個超市，分成多個分館
- Hallmark（H 館）：50 個精選集、刻意去冗餘


- 先用 Hallmark 定大方向，再進 GO / Reactome 挖細節
- R 端入口：msigdbR 套件，一行抓下來

ORA：抽球模型



藍球 = 某通路的成員 $K = 85$

抽出
DE 清單
 $n = 300$



超幾何檢定問：

隨機抽 300 顆，
預期藍球 ≈ 2.1 顆；
實際抽到 30 顆

這麼極端的機率
 $p \approx 5.0e-27$


p 為實算值

ORA 只吃「名單」：清單裡誰進來、背景是誰，直接決定 p 值

超幾何檢定：我清單裡的通路成員，比隨機抽該有的多嗎？

GSEA：不切閾值，看整份排序

模擬資料



GSEA 不切顯著閾值——它問：這個集的成員，在整份排序裡有沒有擠向某一端？

它問的是：這個集的成員，有沒有集體擠向排序的某一端？

ORA 對 GSEA：什麼時候用哪個

不是二選一的信仰題，是輸入決定的

ORA

你手上只有一份名單

- 輸入：切好閾值的清單 + 背景
- 超幾何 / Fisher 檢定
- 對閾值敏感；背景設錯全盤皆錯

GSEA

你手上有完整的排序

- 輸入：全部基因的排序統計量
- 不必切顯著閾值，弱訊號也能累積
- 本集主線：DE 表天生就是排序

本集核心觀念

**富集分析檢定的不是你的資料，
是「你的清單」對「一個背景」。**

清單怎麼來的、背景是誰，這兩件事決定結果的意義。踩雷區的三個雷全都從這裡長出來。

02

從 DE 結果到 ranked list

讀入 B12 的產物，算一支排序向量

讀入 B12 的 DE 結果

```
library(Seurat)
library(dplyr)
set.seed(1234) # 全系列固定，結果可重現

de <- readRDS("output/ifnb_b12_de_results.rds")
names(de)
pb <- de$pseudobulk # DESeq2 shrink 後的結果表
head(pb[order(pb$padj), ], 3)
```

```
[1] "naive" "pseudobulk" "coldata" "audit"
      baseMean log2FoldChange lfcSE  pvalue  padj
ISG15  1520.3      5.08 0.211  2.1e-31  3.4e-27
IFI1  980.6      5.42 0.243  8.9e-30  7.2e-26
IFI3  1213.9      4.61 0.222  5.0e-29  2.7e-25
```

四個欄位裡，今天要用的是 log2FoldChange 與 pvalue

排序指標：兩派都講清楚

B12 的 DE 結果表

gene	log2FC	pvalue
ISG15	5.1	2e-31
IFIT3	4.6	8e-29
CXCL10	4.9	3e-24
SELL	-1.9	6e-09
RPL9	-0.1	0.62

每個基因
算一個分數

排序指標

$$\text{sign}(\log_2\text{FC}) \times (-\log_{10} p)$$

上調且顯著 → 大正值
下調且顯著 → 大負值

由大到小
排序

ranked list (具名向量)

ISG15	+30.7
IFIT3	+28.1
CXCL10	+23.5
...	
RPL9	+0.21
...	
SELL	-8.2

另一派直接用 DESeq2 的 Wald stat 欄——兩者高度一致；報告 FC 用 shrink 值、排序用統計量

方向 × 顯著程度；或直接用 Wald stat。排序用統計量、報告效應量用 shrink 後的 FC

動手建 ranks

```
pb <- pb[!is.na(pb$pvalue) & !is.na(pb$log2FoldChange), ]  
# 方向 × 顯著程度; p = 0 的基因以 1e-300 保底再取 log  
pb$metric <- sign(pb$log2FoldChange) *  
  -log10(pmax(pb$pvalue, 1e-300))  
ranks <- sort(setNames(pb$metric, rownames(pb)),  
  decreasing = TRUE)  
length(ranks); head(ranks, 3); tail(ranks, 2)
```

```
[1] 11143  
ISG15 IFI1 IFI3  
30.7 29.1 28.3  
CCL2 SELL  
-10.8 -12.4
```

一支具名向量：名字是基因、值是排序分數、由大到小

交給 fgsea 之前，三個檢查

長度



11,143 個基因——
是「檢定過的全部」，
不是顯著清單

兩端是誰



頭是 ISG15 這類干
擾素基因、尾是下調
基因——方向沒接反

沒有 NA、沒 有重複名



fgsea 對這兩件事零
容忍，先清乾淨

03

fgsea + Hallmark 實跑

已知答案驗證法：IFN- β 刺激的資料，該亮的是誰？

用 msigdb 抓 Hallmark

```
# install.packages("msigdb")
library(msigdb)
hm <- msigdb(species = "Homo sapiens", collection = "H")
# 舊版 msigdb 的參數名是 category = "H", 內容相同
hallmark <- split(hm$gene_symbol, hm$gs_name)
length(hallmark)
sapply(hallmark[1:2], length)
```

```
[1] 50
```

```
      HALLMARK_ADIPOGENESIS HALLMARK_ALLOGRAFT_REJECTION
      200                  207
```

split 之後就是 fgsea 要的格式：一個 list，每個元素是一包基因名

跑 fgsea

```
# BiocManager::install("fgsea")
library(fgsea)
set.seed(1234)

gsea <- fgsea(pathways = hallmark,
              stats = ranks,
              minSize = 15, # 太小的集：估不穩
              maxSize = 500, # 太大的集：什麼都沾一點
              eps = 0) # p 值算到底，不設下限
```

三個參數都有預設；這裡的值是常用慣例，理由在口說

結果表：先看榜首

```
gsea %>% arrange(padj) %>%  
  select(pathway, NES, padj, size) %>% head(5)
```

	pathway	NES	padj	size
1	HALLMARK_INTERFERON_ALPHA_RESPONSE	2.88	4.1e-23	95
2	HALLMARK_INTERFERON_GAMMA_RESPONSE	2.79	4.1e-23	186
3	HALLMARK_INFLAMMATORY_RESPONSE	1.94	1.2e-05	169
4	HALLMARK_IL6_JAK_STAT3_SIGNAL	1.81	3.4e-04	79
5	HALLMARK_TNFA_SIGNALING_VIA_NF	1.62	1.1e-03	188

IFN- β 刺激的資料， IFN response 就該是榜首——已知答案，對上了

方法學的好習慣

新工具上手的第一步： 先跑一份你知道答案的資料。

ifnb 的答案寫在實驗設計裡。答案對了，才輪到你相信它在別的資料上的輸出。

04

判讀：NES、enrichment plot、leading edge

三個東西讀懂，GSEA 才算做完


NES 怎麼讀

NES 的三個性質

正負號=方向
(往上調端或下調端擠)

已依基因集大小標準化
→ 集與集之間可比

永遠和 padj 一起看



NES (normalized enrichment score)


示意結果 (依 ifnb 實驗趨勢繪製)

方向+強度+跨集可比；單獨一個 NES 沒有意義，永遠配 padj

enrichment plot 與 leading edge

enrichment plot：沿著排序走，遇到成員加分（依統計量加權）、非成員扣分

leading edge：峰值之前的成員基因



沿排序走：遇到成員加分、非成員扣分。峰值前的成員 = leading edge

畫圖，並掏出 leading edge

```
plotEnrichment(
  hallmark$HALLMARK_INTERFERON_ALPHA_RESPONSE, ranks) +
  labs(title = "HALLMARK_INTERFERON_ALPHA_RESPONSE")
ggsave("output/B13_gsea_ifna.png", width = 6, height = 4)

ia <- which(gsea$pathway ==
  "HALLMARK_INTERFERON_ALPHA_RESPONSE")
head(gsea$leadingEdge[[ia]], 8)
```

```
[1] "ISG15" "IFI1" "IFI3" "MX1"
[5] "OAS1" "RSAD2" "IFI6" "CXCL10"
```

leadingEdge 是 list 欄位：每條通路一包「真正扛訊號」的基因

報告一條 GSEA 結果的三件套

數字



NES 方向與大小+
padj ; 不要只報 p

圖



enrichment plot
一張，讓人看到成員
怎麼擠

leading edge



點名扛訊號的基因，
接回你的生物學問題

05

ORA 路線: clusterProfiler 與 GO

清單是你的，背景也必須是你的

清單與背景，一起準備

```
sig.up <- rownames(pb)[!is.na(pb$padj) &  
                        pb$padj < 0.05 &  
                        pb$log2FoldChange > 1]  
length(sig.up)           # 上調且效應夠大的清單  
  
universe <- rownames(pb) # 背景 = 這次檢定過的基因  
length(universe)
```

```
[1] 473  
[1] 11143
```

universe 不是選配，是 ORA 的一半。忘了它，工具會拿全基因組頂上

enrichGO 與 simplify


```
# BiocManager::install(c("clusterProfiler","org.Hs.eg.db"))
library(clusterProfiler)
library(org.Hs.eg.db)
ego <- enrichGO (gene      = sig.up,
                  universe = universe, # 關鍵參數
                  orgDb    = org.Hs.eg.db,
                  keyType  = "SYMBOL",
                  ont       = "BP")
ego <- simplify(ego) # 合併語義高度重疊的條目
as.data.frame(ego)[1:3,
  c("Description", "GeneRatio", "p.adjust")]
```

	Description	GeneRatio	p.adjust
GO :0051607	defense response to virus	58/442	1.2e-38
GO :0009615	response to virus	61/442	3.5e-37
GO :0034340	response to type I interferon	42/442	8.9e-33

GeneRatio 的分母 442：清單裡對得上 GO 註釋的基因數

GO 是階層：父子項共享基因

GO 是階層（DAG）：子項的基因都算在父項裡



後果：同一批 IFN 基因


讓「干擾素反應」「防禦反應」
「細胞激素反應」「免疫過程」
整串父子項一起顯著

→ 結果表看似 40 條，其實一件事

**對策：simplify() 去冗餘、
報告時按「主題」收斂（⑤ 會示範）**

一批 IFN 基因能點亮整串父子項——結果表看似 40 條，其實一件事

背景基因集決定 p 值



換一個背景，管家基因類的通路 p 值暴衝——訊號沒變，是分母被灌水了


scRNA-seq 只偵測到一萬多個基因——背景就該是它們，不是兩萬

06

細胞層級：把分數畫回 UMAP

AddModuleScore 與 AUCell

AddModuleScore 的原理



每顆細胞的分數

平均(基因集表現)
- 平均(對照基因表現)

扣掉對照 → 校掉深度與
整體表現量的影響；
分數是相對值，0 只是基準

AddModuleScore：一個基因集 → 每顆細胞一個分數，存進 metadata

基因集平均，減掉「同表現量 bin 抽出的對照」平均——分數是相對值


打分，畫回地圖

```
ifnb <- readRDS("output/ifnb_b11_integrated.rds")
ifnb <- JoinLayers(ifnb, assay = "RNA")

ifn.genes <- hallm ark$HALLMARK_INTERFERON_ALPHA_RESPONSE
ifnb <- AddModuleScore(ifnb,
  features = list(ifn.genes),
  name = "IFNa_score") # 預設 nbins = 24, ctrl = 100
FeaturePlot(ifnb, "IFNa_score1", split.by = "stim ")
```

欄名會自動加編號：IFNa_score1。多給幾個集，就多幾欄

兩張地圖，一個尺度



模擬資料


同一張地圖、同一個分數尺度：刺激後的單核球整群亮起——訊號有「位置」了

pseudobulk 說「CD14 Mono 有 IFN 反應」；這張圖讓你看到它在地圖上的位置

AUCell：用排名取代平均

模擬資料

recovery curve (實算)



① 每顆細胞：基因按表現量排名
(只用排名，不用數值)

② 看排名前 5% 裡，基因集
成員出現得多快

③ 曲線下面積 = AUC 分數
→ 對深度與 normalization 穩健

AUCell：用「排名」取代「平均」——來自 SCENIC 的打分引擎

每顆細胞內部排名 → 前 5% 的曲線下面積。對深度與 normalization 穩健

三個層級，各回答什麼

排序層級：

GSEA

這個對比裡，哪些生物程式整體動了



清單層級：

ORA

我這份名單，像哪些已知的基因集



細胞層級：模組分數

這個程式在地圖上的哪些細胞裡開著



07

踩雷區

三個雷，每一個都實際跑給你看

雷一：背景用全基因組

雷是什麼

enrichGO 不給 universe，讓它拿整個基因組註釋當背景。



為什麼會踩


參數是選填的，不填也能跑，輸出還更「豐富」。

踩了會怎樣

凡是 scRNA-seq 測得到的基因類別全部「顯著」：轉譯、核糖體、代謝……真訊號被淹沒。

實跑：同一份清單、兩種背景

同一份 DE 清單，只換背景——管家類條目全體「顯著」，真訊號被淹沒



模擬情境、實算超幾何 p

R 腳本的踩雷段有這個對照：顯著條目數與榜單長相都面目全非

雷二：拿 marker 清單問它富集什麼

雷是什麼

把某群的 top marker 當基因集，再對同一份資料打分或檢定富集。



為什麼會踩

流程跑得通，圖也很漂亮——那群細胞當然分數最高。

踩了會怎樣

循環論證：結論早就藏在輸入裡。這種「驗證」沒有任何資訊量，卻常被當成證據寫進論文。

循環長什麼樣



正確做法

基因集要來自
「獨立於這份資料」
的先驗知識：

MSigDB／文獻
另一份資料的特徵集

自家 marker 只能
拿去「命名」，不能
拿回來「驗證」

基因集必須來自獨立於這份資料的先驗知識： MSigDB、文獻、另一份資料

雷三：只報 p 最小的 20 條 GO

雷是什麼

把 GO 結果按 p 排序，取前二十條貼進論文表格。




為什麼會踩

表格總得截斷，按 p 截看起來最客觀。

踩了會怎樣

父子項重複計數：二十條裡十幾條是同一件事的不同說法；還為挑櫻桃開了門——想講哪條就挑哪條。

收斂：報主題，不報條目



simplify() 去冗餘、按 NES 方向與語義把條目聚成主題，每個主題挑代表項

踩雷區小結

**富集分析最會生產的，
是「看起來像結論的輸出」。**

背景對不對、清單獨不獨立、條目有沒有收斂——三關都過，輸出才升格為結論。

07+

複雜樣本策略室

同一套 fgsea ，換到多病人腫瘤的 DE 表——基因集用誰、榜單先排除誰、要跑幾次

腫瘤的基因集： Hallmark 之外還有 meta-programs

Hallmark 照舊起手；「惡性細胞在哪個狀態」要用腫瘤研究自己整理的基因集問

要問什麼	用哪包基因集	備註
通用程式：缺氧、增殖、EMT...	Hallmark 50 集（msigdb 內建）	起手式不變：先掃一遍定大方向
GBM 惡性細胞的狀態	Neftel 2019 四狀態：MES / AC / OPC / NPC 樣	來源是論文附表；split 成 list 後格式同 Hallmark
其他癌種的狀態程式	黑色素瘤 Tirosh 2016（MITF/AXL）、頭頸癌 Puram 2017（p-EMT）	不同腫瘤不能互抄——拿 Neftel 打肝癌，跑得動、沒意義
不綁定單一癌種	跨腫瘤 ITH meta-programs（Gavish 2023 整理）	多癌種、或不確定該用哪套時的通用選項
注意：狀態分數 ≠ 惡性證據	這些程式多在「已確認惡性」的細胞裡定義	分數高只是狀態傾向；判惡性靠 CNV（B16）

解離壓力與缺氧：先排除，再解讀

B5 策略室欠的那筆帳，在富集層還：這兩類訊號過了關，才允許進結論

解離壓力簽名



FOS/JUN/HSP 家族
是酶消化的印痕；打
成分數後散在每種型
別各一撮——不是亞
群，也不是通路

缺氧：真假都有



腫瘤核心真的缺氧
（GBM 資料
SLC2A1 核心高
log2FC 5.7）；但
離體缺血也會製造缺
氧樣表現

兩道判別



方向對得上已知答案
嗎（核心該缺氧）；
訊號是每種型別都亮
的微環境，還是跟壓
力簽名一起走的假象


每病人各自 GSEA：跨病人一致才算數

四位病人合併，一次 GSEA

同一套檢定，每位病人各自一次



逐病人
重跑



三條看起來一樣可信——分不出誰在扛

紅＝該病人 NES 為正（核心較高）、藍＝負；格上數字為 NES

結論後面要能寫出「4 位病人中 4 位一致」——病人是統計單位，在富集層也一樣

示意（模擬 NES）；情境沿用 GSE84465 GBM 核心 vs 邊緣

合併榜單分不出「四位一致」與「一位撐起」——逐病人重跑、NES 排成表，一眼判

一句話總結

**GSEA 問方向，ORA 問名單，
模組分數問位置——答案要互相對得上。**

ifnb 的三層答案都指向同一句話：刺激後的單核球開啟了第一型干擾素反應程式。

自測 1

ORA 與 GSEA 各吃什麼輸入？

- A 兩者都吃顯著基因清單
- B ORA 吃清單＋背景； GSEA 吃全部基因的排序
- C ORA 吃排序； GSEA 吃清單
- D 兩者都吃表現矩陣

答 B。ORA 是抽球模型：清單裡的通路成員比隨機多嗎——所以它需要清單，也需要定義「隨機」的背景。GSEA 不切閾值，把檢定過的全部基因按統計量排成一列，看成員往哪端擠。

自測 2

fgsea 給某通路 NES +2.9、padj 1e-23。正確的解讀是？

- A 該通路的基因都顯著上調
- B 成員整體擠向上調端，且此富集程度已對基因集大小標準化
- C 該通路的表現量是背景的 2.9 倍
- D 有 2.9% 的成員在清單裡

答 B。 NES 說的是「成員在排序上的集體偏移」：正號代表往上調端擠，大小已依基因集大小標準化，所以集與集可比。它不保證每個成員都顯著——個別基因要回 leading edge 看。

自測 3

enrichGO 沒設 universe，跑出 200 條顯著、滿是轉譯與代謝。第一步該做什麼？

- A 挑跟假說相關的條目寫進論文
- B 把 p 閾值改嚴成 0.01
- C 把 universe 設成這次檢定過的基因，重跑
- D 換 KEGG 資料庫再跑一次

答 C。滿版管家類條目是「背景 = 全基因組」的招牌症狀：偵測不到的基因灌爆了分母。A 是挑櫻桃、B 只是把錯的結果砍短、D 換資料庫但背景照樣是錯的。先把背景改對，再談其他。

下集預告

B14：細胞通訊——配體、受體與 CellChat

富集告訴你「這群細胞在做什麼」。可是單核球開啟干擾素程式之後，對 T 細胞說了什麼？
下一集把配體對上受體，推出一張通訊網路——並且說清楚這種推論的邊界在哪。