

B16 B 系列

# 腫瘤場景： inferCNV 與惡性細胞判定


用 CNV 訊號把惡性細胞和正常細胞分開——並且知道這個推論什麼時候會騙你。

約 38 分鐘 | 前置：B5-B10 | 資料：infercnv 內建 oligodendroglioma 範例

# 三群上皮，哪一群是癌？

模擬資料

分群：上皮分成三群



T 細胞

巨噬細胞

EPCAM：三群全都陽性



marker 只說「這是上皮」，不說「這是不是癌」

哪一群是惡性細胞？

一份腫瘤樣本：分群給了三群上皮，EPCAM 三群全陽性。分群幫不了你

本集的起點

# 惡性的定義寫在基因組上， 而分群和 **marker** 都只看轉錄組。

要判惡性，就得從 RNA 裡把基因組的影子挖出來。這正是 inferCNV 做的事。

# 這一集你會學到



- 1 說出為什麼腫瘤資料裡「惡性 vs 正常」不能靠分群和 marker 解決
- 2 理解 inferCNV 的原理鏈（座標排序 → 滑動窗口 → 相對 reference），實跑內建範例
- 3 讀懂 heatmap 的 clone 結構，用三角驗證下判定，說出三個常見假訊號

# 01

## 訊號從哪裡來

scRNA 沒測 DNA——CNV 是推論出來的，不是測出來的

# 惡性的定義性特徵在基因組




scRNA 沒有測 DNA——但大段的擴增與缺失，會在「染色體區段的平均表達」留下影子

大段的擴增與缺失，會在「染色體區段的平均表達」留下影子

# 原理鏈：排序 → 開窗 → 比基線

## ① 基因亂序（原始矩陣）


每基因對 reference 的 log 比值



只有雜訊，看不出任何事件

## ② 依基因組座標排序


chr1 → chr2 依座標排



1p 區隱約偏低

## ③ 滑動窗口平均 (w=51)

窗口內 51 個基因取平均




chr1p 缺失現形

模擬資料

同一批數字：排序讓訊號「站到一起」，平均把雜訊壓下去——單基因的雜訊 ~1 個 log2 單位，窗口平均後剩約 1/7

同一批數字走三步：依基因組座標排序、滑動窗口平均、相對 reference 讀偏移

# reference：拿誰當「正常」



reference = 「正常」的定義

觀察組每基因的表達  
- reference 的平均  
= 相對偏移 (CNV 的原料)

首選：同一份樣本裡的免疫／基質細胞

heatmap 上的每一個顏色，都是「相對這條基線」的偏移——基線選錯，整張圖跟著錯

首選同一份樣本裡的免疫／基質細胞——它們的基因組幾乎必然正常



本集核心觀念

# **CNV 訊號是統計上的影子： 單一基因毫無意義，成段才算數。**

一個基因表達掉一半，理由有一百種；一整條染色體臂同時掉一半，理由通常只有一種。

# 02

## 三件輸入與範例資料

counts、 annotations、 gene order——一個都不能少

# inferCNV 吃三個檔案

## ① counts 矩陣

|      | MGH36_A01 | MGH53_B02 |
|------|-----------|-----------|
| DLL3 | 0         | 12        |
| EGFR | 3         | 0         |
| S0X4 | 8         | 21        |

基因 × 細胞的原始計數  
(Seurat 物件抽得出來)

## ② annotations

|            |                  |
|------------|------------------|
| MGH36_A01  | malignant_MGH36  |
| MGH53_B02  | malignant_MGH53  |
| Mic_93_C07 | Microglia/Macro. |
| Oli_97_D11 | Oligodendrocytes |

每顆細胞屬於哪一組  
reference 用組名指定

## ③ gene order file

|        |      |        |
|--------|------|--------|
| WASH7P | chr1 | 14363  |
| NOC2L  | chr1 | 879584 |
| SAMD11 | chr1 | 860260 |
| ...    | ...  | ...    |

每個基因的染色體與座標  
排序、開窗都靠它

`CreateInfercnvObject(counts, annotations, gene_order, ref_group_names)`

counts 你本來就有； annotations 來自你的註釋； gene order 是新朋友

# 載入套件與內建範例路徑

```
# BiocManager::install("infercnv") # HMM 功能需要先裝 JAGS
library(infercnv)
set.seed(1234)

counts_f <- system.file("extdata",
  "oligodendroglioma_expression_downsampled_counts_matrix.gz",
  package = "infercnv")
anno_f <- system.file("extdata",
  "oligodendroglioma_annotations_downsampled.txt",
  package = "infercnv")
gene_f <- system.file("extdata",
  "encode_downsampled.EXAMPLE_ONLY_DONT_REUSE.txt",
  package = "infercnv")
```

system.file 抓的是套件自帶的檔案——不用下載任何東西

# 建立 infercnv 物件

```
anno <- read.table(anno_f, sep = "\t",
                   colnames = c("cell", "group"))
head(table(anno$group), 3)

cnv <- CreateInfercnvObject(
  raw_counts_matrix = counts_f,
  annotations_file = anno_f,
  gene_order_file = gene_f,
  delim = "\t",
  ref_group_names = c("Microglia/Macrophage",
                      "Oligodendrocytes (non-malignant)"))
```

|                      |                                  |
|----------------------|----------------------------------|
| Microglia/Macrophage | Oligodendrocytes (non-malignant) |
| 27                   | 22                               |
| malignant_MGH36      |                                  |
| 33                   |                                  |

ref\_group\_names 必須一字不差對上 annotation 的組名——打錯會直接報錯

# 到這裡，你手上有什麼

## 一個矩陣



Smart-seq 的  
oligodendroglioma  
計數，基因上萬、細  
胞一百多顆

## 兩種身分



reference 兩組（微  
膠、寡樹突）+ 多個  
腫瘤樣本的觀察組

## 一份地圖



每個基因的染色體與  
座標——排序和開窗  
全靠它

# 03

## 實跑與參數

cutoff、window、denoise 各自管一件事

# infercnv::run : 第一輪


```
cnv <- infercnv::run(cnv,  
  cutoff = 1,    # 平均計數低於它的基因剔除:  
                # Smart-seq 用 1, 10x 用 0.1  
  out_dir = "output/b16_infercnv",  
  cluster_by_groups = TRUE, # 觀察組各自聚類  
  denoise = TRUE,         # 壓掉基線附近的白噪音  
  HMM = FALSE)           # 第一輪先看連續訊號
```

```
INFO [...] ::process_data:Start  
INFO [...] STEP 15: computing tum or subclusters  
INFO [...] Making the final infercnv heatmap
```

跑幾分鐘，log 幾百行——重點只有最後一句：heatmap 畫好了



# 三個參數，各自管什麼



- cutoff：把低表達基因踢出分析——雜訊基因進窗口只會稀釋訊號
- window（預設 101 個基因）：太小雜訊殺不乾淨，太大邊界暈開
- denoise：把 reference 波動範圍內的值壓回白色，圖乾淨很多

# 跑完之後： `out_dir` 裡有什麼

```
list.files("output/b16_infercnv") |> head(6)
```

```
[1] "infercnv.png"  
[2] "infercnv.preliminary.png"  
[3] "infercnv.references.txt"  
[4] "infercnv.observations.txt"  
[5] "infercnv.observation_groupings.txt"  
[6] "run.final.infercnv_obj"
```

`infercnv.png` 是主圖； `run.final.infercnv_obj` 是等一下要讀回來的結果物件


# 04

## heatmap 判讀

先看 reference，再看事件，最後看 clone

# heatmap 的解剖


列=細胞（分組排）；欄=基因（依基因組座標排）




上半 reference 要接近全白；下半觀察組裡，成段的藍與紅才是事件

# 教科書事件： chr1p/19q 共缺失

chr1：p 臂掉下去，q 臂回到基線



chr19：q 臂掉下去



reference

惡性細胞平均

模擬資料



1p 與 19q 同時缺失=oligodendroglioma 的教科書事件——臨床上就用它分型

oligodendroglioma 的分子定義事件——真實範例資料跑出來就是這兩條



# subclone：腫瘤內部的家族樹

只看 4 條染色體（實算結果的子集）



共同事件＝主幹；只有部分細胞有的事件＝分支

模擬資料

共同事件是主幹，部分細胞才有的事件是分支—— heatmap 的列聚類會把它排出來

## 判讀的固定順序

- ① **reference 乾淨嗎？**
- ② **有沒有成段事件？** ③ **事件怎麼分層？**

reference 不乾淨，後面全部免談——那代表基線本身有問題。

# 05

## HMM 與 CopyKAT

從「顏色深淺」到「離散判定」



# HMM 模式：把顏色變成狀態


```
cnv_hmm <- infercnv::run(cnv0, # 用未跑過的原始物件
  cutoff = 1,
  out_dir = "output/b16_infercnv_hmm",
  cluster_by_groups = TRUE,
  denoise = TRUE,
  HMM = TRUE,
  HMM_type = "i6") # i3 = 缺失 / 中性 / 增加; i6 再分程度
```

HMM 慢很多（多幾倍時間），第一輪探索先關、要下結論再開

# HMM 狀態與 per-cell 判定

模擬資料

HMM：把連續訊號翻譯成離散狀態（缺失／中性／增加）




判為缺失

判為增加

subclone B 平均訊號 + 三狀態 Viterbi 實算

inferCNV 的 i3 模式＝這三個狀態；i6 模式再細分增加的程度，  
輸出從「顏色深淺」升級成「整數拷貝數估計」

per-cell 判定：兩團自然分開



CopyKAT 概念：對「每一顆細胞」做 aneuploid / diploid 判定，不必先分組

左：連續訊號翻譯成離散狀態。右：CopyKAT 思路——每顆細胞自己判 aneuploid / diploid

# inferCNV vs CopyKAT

不是對手，是互補——常常兩個都跑

## inferCNV

### 組層級、可視化強

- 需要你指定 reference 組
- heatmap 是溝通神器，subclone 模式清楚
- 判定單位偏「組／cluster」

## CopyKAT

### cell 層級、自動基線

- 免指定 reference，自己找二倍體基線
- 輸出每顆細胞 aneuploid / diploid
- 正常上皮混在腫瘤裡時特別有用

# 06

## 判定流程：三角驗證

CNV × 分群 × marker，寫進 metadata

# 從結果物件算 per-cell CNV 分數


```
obj <- readRDS("output/b16_infercnv/run.finalinfercnv_obj")  
expr <- obj@expr.data      # 基因 × 細胞，中性值在 1 附近  
dim(expr)  
  
cnv_score <- colMeans((expr - 1)^2) # 偏移平方的平均  
ref_cells <- unlist(obj@reference_grouped_cell_indices)  
summary(cnv_score[ref_cells])      # reference 的分數範圍
```

```
[1] 7113 184
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.   
0.000876 0.001392 0.001729 0.001846 0.002206 0.004215
```

expr.data 是平滑、置中後的矩陣——分數就是每顆細胞「離 1 多遠」

# 三角驗證流程



判定結果寫進 metadata (malignant / normal / ambiguous)，下游分析從這個欄位出發

單一證據都可能騙你；三路交叉之後，錯的機率才小到可以接受

# 下判定，寫進 metadata

```
m_al_mean <- rowMeans(expr[, -ref_cells]) # 惡性平均 profile
corr_mal <- apply(expr, 2, cor, y = m_al_mean)

s_hi <- quantile(cnv_score[ref_cells], 0.95)
lab <- ifelse(cnv_score > s_hi & corr_mal > 0.4, "malignant",
             ifelse(cnv_score <= s_hi & corr_mal < 0.2, "normal",
                    "ambiguous"))
table(lab)
```

```
lab
ambiguous malignant normal
      7       117       60
```

有 Seurat 物件時，這個 lab 向量用 AddMetaData 掛回去，下游照常用

# 這一節做了什麼

## 量化



每顆細胞一個 CNV  
分數 + 一個與惡性  
profile 的相關

## 交叉



分數 × 分群 ×  
marker，三路證據  
對答案

## 留痕



malignant /  
normal /  
ambiguous 寫進  
metadata，不硬判



# 07

## 踩雷區

三個雷，每一個都實際算給你看

# 雷一： reference 選錯

## 雷是什麼

把「疑似惡性」的群放進 reference，或 reference 裡混進大量腫瘤細胞。



## 為什麼會踩

註釋不確定時，看起來「最大最正常」的上皮群很容易被當成基線。

## 踩了會怎樣

惡性細胞的 CNV 被藏進基線：全圖歸零，正常細胞反而長出假「增加」，方向整個反轉。


# 實算：基線選錯，全圖歸零

正確：免疫+寡樹突當 reference

reference (真正常)

subclone A


subclone B



染色體 1 → 22

該有的訊號都在

錯誤：把 subclone A 當 reference



染色體 1 → 22

惡性列被「歸零」，正常列反而出現假的「增加」——缺失被藏進基線，方向整個反過來

模擬資料

同一批細胞、同一套演算法，只換 reference—— 左右對照

## 雷二：把基因簇的表達當 CNV

### 雷是什麼

HLA、IG 這類「同座標、共調控」的基因簇，一起上調時被窗口平滑成一段假『擴增』。



### 為什麼會踩


滑動窗口假設鄰居基因彼此獨立——共調控基因簇正好打破這個假設。

### 踩了會怎樣

活化免疫細胞在 chr6p21 長出假事件、漿細胞在 IG 基因座爆紅一段——被當成腫瘤 clone 寫進結果。

# 實算： HLA 簇的假訊號

模擬資料



## 高危險基因簇

HLA (chr6p21)  
IG 基因座 (chr2 / 14 / 22)  
增殖、熱休克等共調控簇

共同點：同座標、同方向、  
一起大幅變動 → 平滑後像 CNV

處置：把這些區域排除  
或至少不要單獨採信

平滑窗口假設「鄰居基因彼此獨立」——共調控的基因簇正好打破這個假設

這 80 顆細胞的基因組完全正常——處置：這些區域排除，或至少不單獨採信

# 雷三： CNV 乾淨就宣稱不是癌

## 雷是什麼

看到某群 CNV 圖平平整整，就把它標成 normal 收工。



## 為什麼會踩

直覺上「癌 = 基因組大亂」；但這只是常見，不是必然。


## 踩了會怎樣

近二倍體的血癌、部分兒科腫瘤被漏判成正常細胞，整條下游分析從第一步就錯。

# CNV 是證據之一，不是判決書

模擬資料

CNV 圖乾乾淨淨……所以不是癌？



染色體 1 → 22 (近二倍體細胞實算)

## 近二倍體的惡性腫瘤真實存在

- 多數血癌：靠融合基因與點突變驅動
- 部分兒科腫瘤：基因組出奇乾淨
- 成人癌也有近二倍體的個案

**CNV 只能判「有 CNV → 幾乎必是惡性」；  
反過來「沒 CNV → 正常」不成立**

缺訊號時：回到突變、融合、marker 與臨床

**CNV 是證據之一，不是判決書**

這個推論是單向的：有事件幾乎必是惡性；沒事件不代表正常



### 踩雷區小結

**heatmap 上的每個顏色都是  
「相對你選的基線」的推論。**

基線、窗口、平台三件事交代清楚，你的 CNV 結論才站得住。



# 5+

## 複雜樣本策略室

標準流程走完了——這一集你手上本來就是一顆腫瘤。現在想像它換成另一顆

# 不同腫瘤，不同 CNV 指紋

開圖之前先查表——你才知道 heatmap 上該找什麼、「沒找到」又代表什麼

| 腫瘤                | 教科書事件                                           | 判讀決策                                            |
|-------------------|-------------------------------------------------|-------------------------------------------------|
| GBM               | chr7 整條增加+ chr10 整條缺失                           | 整條染色體級，窗口平滑的最佳場景；跨病人重現性高                        |
| oligodendroglioma | 1p/19q 共缺失                                      | 臂級事件，本集範例——診斷級證據                                |
| 乳癌                | HER2（ERBB2, chr17q12）焦點擴增；luminal 常見 1q+ / 16q- | 焦點事件比 101 基因的窗口窄，會被平均稀釋——臂級交給 inferCNV，焦點擴增另找證據 |
| 肝癌                | 1q +、8q +（8q 帶著 MYC）                            | 臂級增加為主；肝細胞代謝背景吵，事件要跨病人重現才算數                     |

# 近二倍體腫瘤：名單與備案

## 哪些腫瘤 CNV 常乾淨



多數血液腫瘤（AML  
可近乎正常核型）、  
部分兒科腦瘤、少數  
近二倍體實體瘤

## 基因組側備案



點突變（Smart-seq  
讀全長抓得到；10x  
只看 3' 端）、融合  
基因、等位基因失衡  
（Numbat /  
HoneyBADGER）

## 表型側備案




免疫表型與分化阻滯  
——跟正常骨髓／正  
常組織參照圖譜比，  
找「卡在半路的前驅  
細胞」

# 多區域取樣：subclone 的時間與空間

模擬資料

同病人 margin + core (實算)



**跨區域共享**

1p- / 19q-  
= 早期主幹事件

**單區域私有**


core B 的 chr4- / 11+  
= 晚期分支

**用空間替演化定序**

margin 的 unresolved 偏多  
是生物現實，不是失敗

跨區域共享的事件是早期主幹，單一區域私有的是晚期分支； margin 浸潤前線訊號弱， unresolved 偏多是生物現實

# 三角驗證強化版：否決、自檢、換軌



草稿不是終點：三道保險走完，標籤才有資格進論文

(示意流程；分數與門檻的算法見頁 29-31)

草稿判定之後加三道保險：譜系否決、reference 自我檢查、CNV 缺席就換證據軌道

# 本集 checklist



說得出為什麼分群 + marker 判不了惡性



reference 用同一份樣本的免疫 / 基質細胞



cutoff 依平台選：Smart-seq 用 1、10x 用 0.1



heatmap 先看 reference 乾不乾淨，再看事件



判定用 CNV × 分群 × marker 三角驗證



HLA / IG 區域的「事件」不單獨採信

六格全勾，才把 malignant 標籤寫進論文

一句話總結

# 惡性判定看基因組的影子： 排序、開窗、比基線，然後三角驗證。

CNV 給你的是很強的證據，前提是你知道它哪三個地方會騙你。

# 自測 1

為什麼腫瘤資料裡「惡性 vs 正常上皮」不能直接靠分群加 marker 解決？

- A 因為腫瘤資料的分群演算法會失效
- B 因為惡性的定義在基因組，兩者都只看轉錄組
- C 因為上皮細胞沒有可用的 marker
- D 因為惡性細胞數量太少

**答** B。惡性細胞和正常上皮共享譜系 marker，分群只反映表達差異，不反映基因組是否異常。所以需要 CNV 這種「從轉錄組推基因組」的證據。



# 自測 2

**inferCNV 的滑動窗口平均，目的是什麼？**

- A 加快計算速度
- B 把單基因雜訊壓掉，讓染色體級的一致偏移浮現
- C 校正批次效應
- D 移除低品質細胞

**答** B。單基因的表達比值雜訊大約 1 個  $\log_2$  單位，看不出任何事件；窗口內幾十個基因平均之後，雜訊縮到約原本的幾分之一，成段的拷貝數偏移才會現形。

## 自測 3

**某群細胞：CNV 分數低、跨樣本混得很好、marker 是典型免疫細胞。另一群：CNV 有 chr1p/19q 缺失、樣本特異、上皮 marker。你的標籤？**

- A 前者 normal、後者 malignant
- B 兩群都 ambiguous，等定序驗證
- C 前者 malignant、後者 normal
- D 只看 CNV 分數就夠，不必看其他

**答** A。兩群都是三路證據一致的教科書案例：前者三者皆無（normal），後者三者齊備（malignant）。三角驗證的意義在於「一致才下判」，這兩群剛好都一致。

下集預告

# B17：反卷積——用單細胞參考拆解 bulk

到這裡你已經能把一份單細胞資料解剖得很深。下一集反過來：

你有 300 個病人的便宜 bulk 資料和 3 千顆細胞的參考——讓兩邊互相成就。