

B17 B 系列

反卷積： 用單細胞參考拆解 bulk 資料

自己建 ground truth、自己對答案——還原誤差量得出來，方法家族才會選。


約 38 分鐘 | 前置：B10、B12 | 資料：pbmc3k 自建假 bulk

300 個病人 vs 3,000 顆細胞

300 個病人的 bulk RNA-seq



... × 300，附存活與臨床資料



存活分析做得動


誰是誰
(signature)



樣本數與
臨床終點



3,000 顆細胞的 scRNA 參考



型別解析度拉滿，但只有幾位捐贈者

反卷積：讓兩邊互相成就

bulk 有隊列與臨床終點，單細胞有型別解析度——為什麼不讓兩邊互相成就？

本集的起點

**bulk 測到的每一個數字，
都是一鍋混合物的總和。**

反卷積要做的，就是把這鍋湯拆回「每種細胞各佔多少」。而你手上剛好有拆它的鑰匙。

這一集你會學到

- 1 說出反卷積解的是哪條方程，以及它和 B12 pseudobulk 的鏡像關係
- 2 用 pbmc3k 自建 signature 與 20 個已知比例的假 bulk，跑 NNLS 對答案
- 3 說出 CIBERSORTx / MuSiC / Bisque / SPOTlight 的定位與 reference 缺型別的偏差


01

一條方程，兩個方向


$\text{bulk} \approx \text{signature} \times \text{比例}$ 。先把方程看懂，工具全是它的變形

混合方程

bulk 表達向量



signature matrix S



比例向量 p



≈

×

基因 × 1 (測得到)

基因 × 型別 (單細胞給的)

型別 × 1 (要解的未知數)


反卷積 = 已知 bulk 與 S，解出 p

已知 bulk 向量與 signature matrix S，解出比例向量 p——這就是整集要做的事

B12 往回加， B17 往回拆

B12 : pseudobulk (往回加)

每顆細胞的型別標籤已知




已知：細胞 $\times$ 標籤

算出：bulk 向量

B17 : 反卷積 (往回拆)

只有混好的 bulk，標籤不見了




已知：bulk 向量 + S

解出：比例 p

同一條等式： $\text{bulk} \approx S \times p$ 。B12 用它驗證，B17 用它求解

pseudobulk 是把有標籤的細胞加成 bulk；反卷積是把沒標籤的 bulk 拆回比例——同一條等式


signature matrix 怎麼來



挑 marker 不是為了美觀——沒有區辨力的基因，只會把方程變難解

- B10 的註釋標籤 → 每型別平均表達
- marker 篩選：只留有區辨力的基因
- 持家基因整列一樣亮，零資訊，剔除
- 拆得動的解析度由 signature 決定，不是由工具決定

共線性： CD4 T 與 CD8 T 太像



signature 欄與欄的相關

CD4 T	1.00	0.80	-0.05	-0.07	-0.02	0.03
CD8 T	0.80	1.00	-0.16	0.36	-0.15	-0.12
B	-0.05	-0.16	1.00	-0.07	-0.02	0.03
NK	-0.07	0.36	-0.07	1.00	-0.05	-0.00
Mono	-0.02	-0.15	-0.02	-0.05	1.00	0.57
DC	0.03	-0.12	0.03	-0.00	0.57	1.00
	CD4 T	CD8 T	B	NK	Mono	DC

模擬資料

pan-T 共享基因把兩欄的相關拉到 0.8—— 方程變得「病態」，兩型的份可以互換而殘差幾乎不變

兩種輸出，別混著讀

拿到結果先問：這是哪一種？

絕對比例

估計「佔全部細胞的幾 %」

- NNLS / MuSiC 這條路線的目標
- 總和 = 1，可跨型別相比
- 仍受 RNA 含量差異干擾

相對分數

同一型別跨樣本比大小

- CIBERSORT 預設輸出屬於這類
- 樣本之間可排序，型別之間不可直接比
- 論文誤讀重災區

本集核心觀念

反卷積的品質上限在 **signature** ， 不在演算法。

參考不像、缺型別、共線性——這些坑演算法救不回來。所以我們先花力氣把 S 建好。

02

從 pbmc3k 建 signature matrix

承接 B10 的註釋 → 合併大類 → 平均 → 挑 marker

讀入註釋物件，合併成 6 大類

```
library(Seurat)
library(dplyr)
set.seed(1234)

pbm.c <- readRDS("output/pbm.c_b10_annotated.rds")
# 亞群太細拆不動：先合併成 6 大類（理由見下一頁）
merge.map <- c("Naïve CD4 T" = "CD4 T", "Memory CD4 T" = "CD4 T",
              "CD8 T" = "CD8 T", "Effector CD8 T" = "CD8 T",
              "CD14 Mono" = "Mono", "FCGR3A Mono" = "Mono",
              "B" = "B", "NK" = "NK", "DC" = "DC")
pbm.c$ct <- merge.map[as.character(pbm.c$celltype.manual)]
pbm.c <- subset(pbm.c, subset = !is.na(ct)) # Platelet 太少，退場
table(pbm.c$ct)
```

B	CD4 T	CD8 T	DC	Mono	NK
344	1178	311	32	594	165

反卷積的第一個決策不是選工具，是決定「拆到多細」

每型別平均 × marker 篩選 → signature

```
Idents(pbm c) <- "ct"
m k <- FindAllMarkers(pbm c, only.pos = TRUE,
                      min.pct = 0.25, logfc.threshold = 1)
top <- m k %>% group_by(cluster) %>%
  slice_max(avg_log2FC, n = 25) %>% pull(gene) %>% unique()


avg <- AggregateExpression(pbm c, group.by = "ct")$RNA # 加總 counts
sig <- t(t(avg) / colSums(avg)) * 1e4 # 每欄 CPM 化
sig <- sig[intersect(top, rownames(avg)), ]
dim(sig); round(cor(sig)["CD4 T", "CD8 T"], 2)
```

```
[1] 138 6
```

```
[1] 0.8
```

欄與欄的相關要先看：CD4 vs CD8 已經 0.8，這筆「共線性稅」等一下會現形

建好的 signature 長這樣



對角區塊

每型別有自己的亮區
→ 方程可解

共享區塊

pan-T、毒殺模組跨欄發亮
→ CD4/CD8、CD8/NK 難分

持家基因

整列一樣亮 = 零區辨力
→ 建 signature 時剔除

模擬資料

對角亮塊讓方程可解； pan-T 與毒殺模組的跨欄亮塊，就是共線性的來源

這一節做了什麼

6 個型別



B10 的 10 類合併
成拆得動的 6 大類

一個 signature



138 個 marker ×
6 欄，每欄 CPM 尺
度

一個警訊



$\text{cor}(\text{CD4}, \text{CD8}) =$
0.8，共線性已登記
在案

03

自產 ground truth

抽細胞、按已知比例混 20 個假 bulk、比例存檔

已知比例混出 20 個假 bulk


```
types <- colnames(sig)
alpha <- as.numeric(table(pbm.c$ct)[types]) / ncol(pbm.c) * 80
truth <- t(replicate(20, { g <- rgamma(6, alpha); g / sum(g) }))
colnames(truth) <- types # 真值表：對答案用

cnt <- GetAssayData(pbm.c, layer = "counts")
bulk <- sapply(1:20, function(b) {
  cells <- unlist(lapply(types, function(tp)
    sample(colnames(pbm.c)[pbm.c$ct == tp],
      round(500 * truth[b, tp]), replace = TRUE)))
  Matrix::rowSums(cnt[, cells]) # 500 顆加總 = 一個假 bulk
})
bulk <- t(t(bulk) / colSums(bulk)) * 1e4 # 每個 bulk 也 CPM 化
```

Dirichlet 抽比例讓 20 個 bulk 各不相同；比例抽完就存檔——答案在我們手上

20 個假 bulk 的真值

20 個假 bulk 的「真值」比例 (Dirichlet 抽樣，抽完就存檔)



模擬資料

每一列是一個假 bulk 的真實組成。等一下 NNLS 的答案，就跟這張表對

到這裡，你手上有什麼

bulk 矩陣



基因 $\times$ 20，每欄是
一鍋混合物

真值表



20 $\times$ 6 的比例，總
和各 = 1

還沒開始解



接下來假裝不知道答
案，把 p 解出來

04

NNLS：十行內的核心解法

透明、可講、夠準——先懂它，再談進階工具

NNLS 在做什麼

普通最小平方 (OLS)


讓 $\| \text{bulk} - S \times p \|$ 最小

但 p 可以是負的——「-8% 的 NK」沒有意義

非負最小平方 (NNLS)

同一個目標，加一條約束： $p \geq 0$

解完再正規化成總和 = 1，就是比例



跟普通最小平方同一個目標，多一條「比例不能為負」的約束；解完正規化成總和 = 1

核心解法：一個 bulk

```
# install.packages("nnls")
library(nnls)

A <- sig          # 基因 × 6 型別
b <- bulk[rownames(sig), 1] # 第 1 個假 bulk，取同一組基因

fit <- nnls(A, b)      # 非負最小平方：核心就這一行
prop <- fit$x / sum(fit$x) # 正規化成總和 = 1
round(setNames(prop, types), 3)
```

```
CD4 T CD8 T   B   NK Mono   DC
0.388 0.196 0.219 0.030 0.154 0.012
```

這個 bulk 的真值是 0.389 / 0.198 / 0.226 / 0.023 / 0.158 / 0.006——先感受一下距離

迴圈解完 20 個 bulk

```
est <- t(apply(bulk[row.names(sig), ], 2, function(b) {  
  x <- nnls(A, b)$x  
  x / sum(x)  
}))  
colnames(est) <- types  
head(round(est, 3), 3)
```


```
      CD4 T CD8 T      B      NK Mono      DC  
[1,] 0.388 0.196 0.219 0.030 0.154 0.012  
[2,] 0.554 0.053 0.070 0.072 0.230 0.022  
[3,] 0.509 0.077 0.106 0.053 0.246 0.008
```

20 個 bulk、每個十毫秒等級——反卷積本體從來不是計算量問題

MuSiC 多做了什麼：加權


基因 A：跨個體很穩

同一個 marker × 6 位捐贈者



基因 B：跨個體亂跳

同一個 marker × 6 位捐贈者



MuSiC：不是把 marker 一刀切，而是給每個基因連續的權重——

跨個體越穩定、資訊量越大的基因，在解方程時說話越大聲

模擬資料

跨個體穩定的基因權重高、亂跳的權重低—— NNLS 的骨架不變，話語權重新分配

05

對答案

估計 vs 真值：整體、然後逐型別

整體成績單

```
library(tidyrr)
df <- bind_rows(
  as.data.frame(truth) |> mutate(bulk = 1:20, what = "truth"),
  as.data.frame(est) |> mutate(bulk = 1:20, what = "est")) |>
  pivot_longer(all_of(types), names_to = "ct") |>
  pivot_wider(names_from = what, values_from = value)

cor(df$truth, df$est)          # 整體相關
sqrt(mean((df$truth - df$est)^2)) # RMSE：平均差幾個百分點
```


```
[1] 0.992
```

```
[1] 0.020
```

$r = 0.992$ 、 $RMSE = 0.02$ ——平均每型別差兩個百分點。但整體分數會騙人，往下看

估計 vs 真值：120 個點

20 個假 bulk × 6 個型別 = 120 個點




模擬資料

大群貼著對角線；左下角的小群（NK、DC）開始離線——放大看下一張

每型別誤差：豐富準、稀有飄

每型別的還原誤差（20 個假 bulk，NNLS 實跑）



模擬資料

CD4 / Mono / B 在幾個百分點內； NK、 DC 相對誤差 28%-87% ； CD8 不稀有也飄——共線性的稅

寫進論文的方法段

**「反卷積精度以已知比例之模擬混合驗證：
整體 $r = 0.99$ ，稀有型別（ $<5\%$ ）誤差顯著較
高。」**

一句話讓審稿人知道：你量過自己的誤差，而且知道弱點在哪。

同一條方程的三個戰場



TCGA 隊列的免疫浸潤

上萬份腫瘤 bulk 都能拆出
免疫組成，接上存活與治療反應
(CIBERSORT 的成名場景)



空間轉錄組的 spot

Visium 一個 spot 是 1-10 顆細胞
的迷你 bulk——同一條方程
(SPOTlight 等工具)



跨平台的現實

bulk 與單細胞來自不同技術，
CIBERSORTx 的 batch 校正
就是在修這道量綱落差

一條方程，三個戰場——差別只在 signature 從哪來、雜訊怎麼校正

TCGA 免疫浸潤、空間 spot 反卷積、跨平台校正——你剛剛親手解過的方程，撐起這三個場景

方法家族速查

工具	關鍵思想	什麼時候選它
NNLS	非負最小平方，十行內、全透明	教學、快速 sanity check、自建流程
CIBERSORTx	固定 signature + batch 校正 + 高解析模式	跨平台 bulk 隊列（如 TCGA）
MuSiC	跨個體穩定度加權的 NNLS 家族	手上有多位捐贈者的 scRNA 參考
Bisque	同隊列配對 bulk + scRNA 互相校正	同一批人同時測了兩種資料
SPOTlight	NMF + signature 拆空間 spot	Visium 等 spot 解析度的空間資料

06

踩雷區

三個雷，第一個當場實跑給你看

雷一： reference 缺型別

雷是什麼

樣本裡真實存在的型別（例如 NK）不在 signature 的欄位裡。




為什麼會踩

方程被迫把 100% 的訊號分給「現有的欄」——缺席者的份無處可去。

踩了會怎樣

NK 的比例被塞給最像的 CD8 T：實跑中 CD8 從 12% 被灌成 22%，而且沒有任何報錯。

實跑：把 NK 從參考拿掉



模擬資料

同一批 20 個 bulk、同一個解法，只少一欄——NK 的份幾乎整批轉進 CD8。近親頂替，無聲無息

雷二：跨平台直接套

雷是什麼

拿 10x (UMI、3' 端) 建的 signature，直接去拆全長協定或 microarray 的 bulk。



為什麼會踩


UMI 每個分子數一次；全長協定的讀段沿轉錄本打散，長基因天生拿更多 reads——量綱不同。

踩了會怎樣


長基因多的型別被系統性高估，而且每個樣本偏同一個方向，樣本數再大也救不了。

兩套量綱，同一個基因

10x (UMI, 3' 端計數)



全長協定 / 多數 bulk



同一個基因、兩套量綱。拿 10x signature 直接拆全長 bulk，長基因多的型別會被系統性高估

模擬資料

這就是 CIBERSORTx batch 校正存在的理由；至少要用同平台資料驗證過再上

雷三：比例差異當細胞數差異

雷是什麼

「病人 A 的 CD8 比例比病人 B 高」直接寫成「A 的 CD8 細胞比較多」。



為什麼會踩

反卷積輸出是成分資料：總和鎖死在 1。一個型別擴增，其他所有型別的比例被動下降。



踩了會怎樣

被動下降被誤讀成「B 細胞耗竭」這類結論；需要絕對量就得引入外部錨點，比較請在 CLR 這類轉換後做。

只有 CD8 變了，全部型別「看起來」都變了

絕對數：只有 CD8 變了

比例：所有型別「看起來」都變了



比例的總和被鎖死在 1：一個型別擴增，其他型別的比例被動下降——這不是它們的細胞數變少

左：絕對數只有 CD8 擴增。右：比例上所有型別都動了。反卷積給你的是右邊

踩雷區小結

**反卷積永遠會給你一組比例。
它不會告訴你 **reference** 錯了。**

缺型別、跨平台、成分性——三個雷共享同一個解法：用已知答案的假 bulk 先驗一次。


06+

複雜樣本策略室

標準流程走完了——現在想像餵進方程的不是自己混的假 bulk，是一顆腫瘤的真 bulk


腫瘤 bulk 的第一個輸出：純度

腫瘤 bulk 的組成：惡性欄就是純度



每根柱 = 一位病人 (按惡性比例排序)

交叉驗證：跟公開純度估計對答案



DNA 拷貝數估的純度 (ABSOLUTE 式)

腫瘤反卷積的 ground truth 沒得自己混——但 TCGA 附公開的 DNA 純度估計：先對過惡性欄，再談其他欄

模擬資料

參考加上惡性欄之後，那一欄的比例就是腫瘤純度——TCGA 有公開的 DNA 純度估計，先對過這一欄再信其他欄

惡性 signature 的病人特異性

同一張參考表裡，兩種欄的性質完全不同

TME 型別

跨病人像同一種東西

- 巨噬、T、寡樹突：跨病人混合（B9 的四塊大陸）
- signature 可跨病人共用、可借公開參考
- 多病人參考讓 MuSiC 有「跨個體穩不穩」可加權

惡性細胞

一人一座島，CNV 主導

- 拿病人 A 的惡性 signature 拆病人 B = 參考不像
- 對策：全部惡性合併成一欄 Malignant——粗，但抓共同訊號
- BayesPrism 進一步允許惡性表現偏離參考

比例接進 Cox 之前：四道統計關卡

關卡	TCGA-GBM 實跑數字	決策
檔案 ≠ 病人	391 個檔案 → 372 份原發 → 去重 284 位	只留原發、每人一份——否則死亡事件被重複計算
追蹤缺漏	54 位存活者有 53 位缺追蹤時間；229 位可分析、227 位死亡	只報組間比較，不報絕對中位存活
陽性對照	年齡 HR 1.03/ 歲， $p = 1.8e-06$	已知效應有出來，你的 null 才是可以報的 null
解析度	巨噬合併欄 HR 1.10， $p = 0.46$ ——null	文獻連到預後的是特定 TAM 狀態；拆細參考重跑再下結論

本集 checklist



說得出反卷積解的是哪條方程、未知數是誰



signature 只留有區辨力的 marker，共線性檢查過



用已知比例的假 bulk 對過答案，誤差心裡有數



知道稀有型別的估計要打折扣再解讀



reference 是否涵蓋樣本裡的主要型別，先問過



結論用「比例」措辭，沒偷換成「細胞數」

六格全勾，你的反卷積結果才有資格進論文

一句話總結

**先用已知比例的假 bulk 對過答案，
再去拆你沒有答案的真 bulk。**

誤差不是用猜的，是自己量出來的。

自測 1

混合方程 $\text{bulk} \approx S \times p$ 裡，反卷積要解的「未知數」是哪一項？

- A bulk 表達向量
- B signature matrix S
- C 比例向量 p
- D 基因的長度

答 C。bulk 是測到的、 S 是單細胞參考給的，唯一的未知數是各型別的比例 p 。B12 的 pseudobulk 是知道標籤往回加，反卷積是拿著 S 往回拆——同一條等式的兩個方向。

自測 2

NNLS 比普通最小平方多了一條什麼約束？為什麼需要它？

- A 係數總和必須等於 1
- B 係數不得為負——因為「- 8% 的 NK」沒有意義
- C 基因數必須大於型別數
- D 殘差必須服從常態分布

答 B。 $p \geq 0$ 是唯一新增的約束：比例天生非負。總和 = 1 不是 NNLS 保證的，是解完之後手動正規化出來的——兩件事別混。基因多於型別是可解性的前提，不是 NNLS 特有。

自測 3

你要拿 PBMC 參考去拆腫瘤組織的 bulk。最大的系統性風險是什麼？

- A 計算時間太長
- B bulk 定序深度不夠
- C 參考缺了腫瘤細胞與基質——它們的訊號會被塞給最像的免疫型別
- D NNLS 對腫瘤資料會報錯

答 C。腫瘤 bulk 裡佔大宗的惡性細胞與基質在 PBMC 參考裡沒有欄位，方程只好把它們的訊號分給現有型別——本集實跑：缺 NK 時 CD8 從 12% 被灌成 22%，而腫瘤場景缺的可是佔一半以上的型別。工具照樣跑完、不報任何錯。

下集預告

B18：生態系與收官

十八集走到這裡，你已經能從 FASTQ 一路打到反卷積。但單細胞的世界比 R 和 Seurat 大得多——蛋白、染色質、空間、Python 生態。最後一集，把地圖攤開，告訴你下一步往哪走。