

B18 B 系列

生態系與收官： 多組學、空間、Python 世界 與下一步


一集之內把 scRNA 之外的鄰居技術、R/Python 生態與 19 集地圖收攏。

約 35 分鐘 | 前置：B1-B17 | 資料：既有物件（pbmc3k / ifnb）

回到第一張 UMAP

模擬資料

B1 • 你的第一張 UMAP



當時：15 行程式碼，每一行都是照抄的

現在：每一行的背後，你都走過一整集

Read10X / CreateSeuratObject	B5
subset (QC 過濾)	B5
NormalizeData	B6
FindVariableFeatures / ScaleData	B6
RunPCA	B7
FindNeighbors / FindClusters	B8
RunUMAP / DimPlot	B9
註釋、整合、DE、下游……	B10+

這一集回答：地圖的邊界之外，是什麼？

B1 的 15 行程式碼——現在你知道每一行背後是一整集

本集的問題

地圖你已經走完了。 地圖的邊界之外，是什麼？

RNA 只是細胞的一個切面。這一集把其他切面、另一個語言世界、以及你的下一步攤開。

這一集你會學到


- 1 說出蛋白、染色質、空間、克隆型各補上 RNA 的哪個盲點，分析上多了哪一步
- 2 掌握 R 與 Python 生態的分工現實，h5ad 互轉能做對、驗收得了
- 3 用 19 集全景圖自我定位，帶走一張進修路線圖

01

RNA 之外：模態地圖

每個盲點，對應一種技術

轉錄組的四個盲點



量到的：RNA 的量 (B1-B17 的全部)

每一種鄰居技術，都是為了補上轉錄組的一個盲點

蛋白、開放染色質、空間位置、克隆型——每個都有一種技術去補

多模態整合的共同思想： WNN

細胞 1：RNA 說得清楚

轉錄組把它跟鄰居分得很開；
表面蛋白 panel 沒有它的 marker

RNA 權重  0.78

ADT 權重  0.22

兩個權重加起來 = 1，逐顆細胞各自決定

細胞 2：蛋白說得清楚

naive 與 memory T 的 RNA 幾乎一樣；
CD45RA/CD45RO 蛋白一刀分開

RNA 權重  0.25

ADT 權重  0.75

兩個權重加起來 = 1，逐顆細胞各自決定

WNN 的核心：不是全資料集一組權重，是每顆細胞自己的權重

每顆細胞有自己的模態權重——誰的資訊多，就聽誰的

本集核心觀念

模態不是越多越好， 是每個模態回答不同的問題。

先問「我的問題缺哪個切面」，再決定要不要加模態。加了，就用 WNN 這類方法讓它們各司其職。

02

CITE-seq 下游與 WNN

承接 B4 的 ADT，兩個 assay 一起分析

兩個 assay，各自 normalize

```
# 承接 B4：CITE-seq 讀進來是一個 list，兩個矩陣
inputs <- Read10X("data/citeseq/filtered_feature_bc_matrix/")
names(inputs)
#> [1] "Gene Expression" "Antibody Capture"

cite <- CreateSeuratObject(counts = inputs[["Gene Expression"]])
cite[["ADT"]] <- CreateAssayObject(
  counts = inputs[["Antibody Capture"]])

cite <- NormalizeData(cite) # RNA：照 B6 的做法
cite <- NormalizeData(cite, assay = "ADT",
  normalization.method = "CLR", margin = 2)
```

ADT 用 CLR、margin = 2（對細胞算）—— B4 講過為什麼抗體不用 LogNormalize

FindMultiModalNeighbors : WNN 關鍵碼


```
# 兩個模態各自降維
DefaultAssay(cite) <- "RNA"
cite <- cite |> FindVariableFeatures() |> ScaleData() |> RunPCA()
DefaultAssay(cite) <- "ADT"
cite <- cite |> ScaleData() |>
  RunPCA(reduction.name = "apca")

# WNN : 兩組 KNN → 每顆細胞的模態權重 → 加權鄰居圖
cite <- FindMultiModalNeighbors(cite,
  reduction.list = list("pca", "apca"),
  dims.list = list(1:30, 1:18))
cite <- RunUMAP(cite, nn.name = "weighted.nn")
cite <- FindClusters(cite, graph.name = "wsnn")
```


跑完後 meta.data 多一欄 RNA.weight——每顆細胞的 RNA 權重，值得畫出來看

WNN 在做什麼：模擬展示


只用 RNA：A 與 B 黏成一團



只用 ADT：C 混進 A



WNN 加權合成：三型分開



演算法算出的 RNA 權重（各型平均）：
naive T (A) 0.31 memory T (B) 0.24 B 細胞 (C) 0.49

兩個 T 亞群把權重讓給 ADT；B 細胞把權重拉回 RNA——權重是演算法逐顆算出來的

模擬資料

RNA 分不開的，ADT 分；ADT 分不開的，RNA 分——權重逐顆細胞計算

這一節做了什麼

兩個 assay



RNA 與 ADT 住在
同一個物件裡，各自
normalize

兩組 KNN



各模態在自己的 PC
空間找鄰居

一張加權圖



每顆細胞的權重合成
weighted.nn，下
游照常分群、畫
UMAP


03

scATAC 與 multiome

一頁看懂 peak 矩陣，一頁看懂橋接


peak 矩陣跟 RNA 矩陣差在哪

RNA：基因 × 細胞



約 2 萬列；數值 0-幾百

ATAC：peak × 細胞



十幾萬列；幾乎只有 0/1

同一套 Seurat 流程可以跑，但 LSI 取代 PCA（細節見 Signac 文件）

RNA 的 feature：基因名

CD8A · MS4A1 · NKG7 ...

ATAC 的 feature：基因組區間

chr2-87011729-87012986 ...



橋接：gene activity

把基因體附近的 peak 訊號加總，
變成「假的基因表現」跟 RNA 對話

十幾萬個 feature、幾乎 0/1、feature 是座標區間——所以 LSI 取代 PCA

multiome 給你什麼

同一顆細胞兩份 答案



RNA 與 ATAC 來自
同一顆細胞，不需要
對齊猜測

因果的方向感



先開染色質、後表現
RNA—— 調控邏輯有了先後

工具： Signac



Seurat 團隊的
ATAC 套件，物件與
語法都是你熟的那套


04

空間轉錄組

位置回來了， B17 的方程也回來了


spot 平台與單細胞級平台

spot 平台 (如 Visium)



一個 spot $\approx$ 1-10 顆細胞的混合

單細胞級平台 (如 Xenium)



解析度
換覆蓋度

逐顆細胞、但基因 panel 有限

位置保住了，代價各不同：spot 犧牲解析度、成像平台犧牲基因數

示意圖

spot 犧牲解析度、成像平台犧牲基因數——沒有免費的位置

spot 反卷積： B17 在空間的角色



單細胞參考當字典，把每個 spot 拆回型別組成——SPOTlight、RCTD、cell2location 都是這件事

bulk 換成 spot，signature $\times$ proportions 那條方程原封不動

這一節的收束

空間資料的分析主力， 還是你這 19 集學的那一套。

QC、normalization、分群、註釋、反卷積——換了座標，沒換方法。

05

R 與 Python：兩個世界

對照表、物件結構、h5ad 互轉實作


Seurat ↔ scanpy 對照表

步驟	R • Seurat	Python • scanpy
讀入 10x	<code>Read10X + CreateSeuratObject</code>	<code>sc.read_10x_mtx</code>
QC 指標	<code>PercentageFeatureSet</code>	<code>sc.pp.calculate_qc_metrics</code>
normalization	<code>NormalizeData</code>	<code>sc.pp.normalize_total + sc.pp.log1p</code>
HVG	<code>FindVariableFeatures</code>	<code>sc.pp.highly_variable_genes</code>
scaling	<code>ScaleData</code>	<code>sc.pp.scale</code>
PCA	<code>RunPCA</code>	<code>sc.tl.pca</code>
鄰居圖	<code>FindNeighbors</code>	<code>sc.pp.neighbors</code>
分群	<code>FindClusters</code>	<code>sc.tl.leiden</code>
UMAP	<code>RunUMAP</code>	<code>sc.tl.umap</code>
marker	<code>FindAllMarkers</code>	<code>sc.tl.rank_genes_groups</code>

同一條流程、同一套概念——B5 到 B10 學的東西，換個名字全部通用

B5-B10 的每一步在 scanpy 都有同名職位——概念一個都不用重學

Seurat 物件對 AnnData



關鍵差異：Seurat 的矩陣是「基因 × 細胞」，AnnData 的 X 是「細胞 × 基因」——方向相反

assay ↔ X/layers、meta.data ↔ obs、reductions ↔ obsm——注意矩陣方向相反

SaveH5Seurat → Convert

```
# remotes::install_github("mojaveazure/seurat-disk")
library(SeuratDisk)

pbmc <- readRDS("output/pbmc_b10_annotated.rds") # B10 的成品
SaveH5Seurat(pbmc, filename = "output/pbmc_b10.h5Seurat")
Convert("output/pbmc_b10.h5Seurat", dest = "h5ad")
# 產出 output/pbmc_b10.h5ad
```

兩步：先存 h5Seurat，再轉 h5ad。預設 X = data 層、raw = counts

Python 端開箱驗收

```
in port scanpy as sc
adata = sc.read_h5ad("output/pbm c_b10.h5ad")
adata
```

```
AnnData object with n_obs x n_vars = 2638 x 13714
  obs: 'orig.ident', 'nCount_RNA', 'nFeature_RNA',
      'percent.mt', 'seurat_clusters', 'celltype'
  obsm : 'X_pca', 'X_umap'
```

第一眼看三個地方：n_obs 在前（細胞數）、obs 欄位齊不齊、obsm 有沒有座標

互轉的鐵則

**轉檔不是結束，
是驗收的開始。**

shape、obs、layers 三關都過，才把檔案交給下游。踩雷區馬上示範三種沒驗收的下場。

06

公開資源與資料復用

把別人的資料，變成你的對照組

三個一定要認識的資源

GEO / SRA



論文資料的正本存放處；矩陣拿 GEO、FASTQ 拿 SRA

cellxgene census



標準化的 h5ad 大倉庫，依組織與細胞型別直接查

Azimuth references



B10 用過的參考圖譜家族——註釋外包給領域專家

資料復用的心法

你的資料不必孤軍奮戰： 同組織的公開資料就是現成的對照組。

方法你全都會了——讀進來、對齊註釋、整合比較，就是 B10 加 B11 的組合技。

07

踩雷區： h5ad 互轉三個坑

每個坑都實際跑給你看

坑一：稀疏矩陣方向

雷是什麼

Seurat 是基因 $\times$ 細胞，AnnData 的 X 是細胞 $\times$ 基因。
手動搬矩陣或拿錯 slot 時，兩者就對調了。



為什麼會踩

工具正常時會自動轉置，於是你從來沒想過方向這件事——直到有一天你自己動手拼物件。


踩了會怎樣

下游把基因當細胞算：QC 指標全錯、PCA 在基因上跑，錯得離譜卻不報錯。

方向一眼驗：先印 shape

13,714 × 2,638

R / Seurat : 基因 × 細胞



細胞


轉置



細胞

2,638 × 13,714

Python / AnnData : 細胞 × 基因



基因

一行驗收

轉完先印 shape :
細胞數應該在前。
數字對調了沒？
沒檢查就是在賭

工具正常時方向會自動處理；出事的是「手動搬矩陣」與「拿錯 slot」的時候

轉完第一行程式碼永遠是印 shape——細胞數應該在前

坑二： meta 欄位型別

雷是什麼

R 的 factor 過去之後，可能變成純字串、甚至數字代碼；層級順序整個掉了。



為什麼會踩

R 的 factor 與 pandas 的 category 概念相近但實作不同，轉換層不保證一一對應。

踩了會怎樣

cluster 「10」排在「2」前面、對照組不再是第一個層級——圖例亂掉，模型的基準組悄悄換人。

坑二的檢查碼：轉檔前後對型別

```
# R 端：轉出前，逐欄記下 meta 的型別
sapply(pbm c@ meta.data, class)

# Python 端：轉入後，逐欄對照
# adata.obs.dtypes
# factor 應成為 category；掉成 object（字串）就自己補：
# adata.obs["celltype"] = (
#     adata.obs["celltype"].astype("category"))
```

orig.ident	nCount_RNA	nFeature_RNA	percent.m.t
"factor"	"numeric"	"integer"	"numeric"
seurat_clusters	celltype		
"factor"	"character"		

兩張型別清單並排對——不一致的欄位當場補救，不要拖到分析中段才發現

坑三：圖層遺失

雷是什麼

scale.data 預設不轉、KNN 圖不轉、多的 assay（ADT）只能另外處理——但轉檔全程零警告。



為什麼會踩

兩邊的物件結構本來就不同構，轉換層只搬「對得上」的部分，搬不動的默默留下。

踩了會怎樣

Python 端拿 X 當 scale.data 用、拿不存在的圖直接分群——結果不對，而你以為資料是完整的。

過得去的與掉下去的

SaveH5Seurat → Convert("h5ad")：過得去的與掉下去的

會過去（驗收後可用）

- ✓ **data layer → X**
預設帶走 normalized data
- ✓ **counts → raw**
原始 counts 存進 raw
- ✓ **meta.data → obs**
細胞附註表
- ✓ **pca / umap → obsm**
降維座標

會掉（到 Python 要補）

- ✗ **scale.data**
預設不帶——Python 端要重算
- ✗ **graphs (KNN 圖)**
不會轉；sc.pp.neighbors 重建
- ✗ **多 assay (ADT 等)**
只轉一個 assay，其餘另存
- ✗ **factor 的層級順序**
可能變成純字串

鐵則：轉完不是結束，是驗收的開始——shape、obs 欄位、layers 三關都過才算轉好

右邊那一欄不是災難，是待辦：到 Python 端逐項重建

h5ad 互轉驗收單

h5ad 互轉驗收單：六格全勾，才算轉好



shape 印出來：細胞 × 基因，數字沒對調



X 是 normalized data 還是 counts，自己說得出



obs 欄位數與型別都對過（factor 有沒有變字串）



X_pca / X_umap 都在 obsm 裡



scale.data 與 KNN 圖知道要在 Python 端重建



多 assay 的資料（ADT）另外處理了

六格全勾，檔案才算交接完成——這張存下來

踩雷區小結

**跨生態系的每一次交接，
都要當成一次資料搬家來驗收。**

shape 對不對、型別在不在、圖層齊不齊。三行檢查碼，省你三天 debug。

7+

複雜樣本策略室

最後一間——標準流程走完了，現在想像你手上不是 PBMC，是一顆腫瘤


工具會換，決策框架長壽

十七間策略室收成五個決策點——換到 scanpy、換到空間平台，問題一個不少

決策點	一句話決策規則	拆過的地方
統計單位是誰	病人，不是細胞—— pseudobulk 起手	B12
整合修到哪	TME 對齊；惡性細胞 per-patient 各自分析	B11
惡性怎麼判	CNV 三角驗證，不靠 marker	B16
比較怎麼設計	配對設計、每型別各自比、批次在設計期就防	B4 · B12
下游走哪條路	先檢查前提再選工具——線與網都是推論	B13–B17

下一站： B19—— 不同腫瘤，不同戰法

B19 · 不同腫瘤，不同戰法——六種場景預告



六種場景各一套戰法；建議觀看順序 B17 → B19 → B18——策略這條線，B19 見


08

全系列收官

19 集，一張地圖

B 系列 19 集全景圖

B 系列 19 集全景圖：從 FASTQ 到生態系



建議順序 B17 → B19 → B18

你現在站在 ★ 的位置——整張地圖你都走過一遍了

上游 → 核心 → 應用 → 進階下游——你現在站在星號的位置

前半場：從 FASTQ 到細胞地圖

上游 B1-B4



FASTQ、
reference、
count、多樣本多模
態——資料的出生地

核心 B5-B10



QC → normalize →
PCA → 分群 →
UMAP → 註釋，一
條龍

應用 B11- B12



整合對齊多樣本，
pseudobulk 把 DE
做對

下半場：拿到清單之後

B13-B14




富集把清單變生物學，
CellChat 推細胞的
對話

B15-B16



軌跡拉出時間軸，
inferCNV 在腫瘤裡
抓惡性細胞

B17-B18



反卷積反哺 bulk 大
隊列，最後把生態系
攤開

三條進修路線

數學向

你常問：「這個演算法
到底在算什麼？」



C 系列：把 B 系列的
每個黑盒子打開推導



PCA 的 SVD、圖分群的
模組度、UMAP 的目標函數

工程向

你常想：「怎麼讓分析
自動跑、能重現？」



pipeline 化：targets /
Nextflow、容器化環境



Quarto 分析報告：
程式碼與結論寫在一起

生物向

你常問：「我這個組織
該看哪些細胞型別？」



領域文獻精讀：你的
器官／疾病的單細胞圖譜



cellxgene census 上
找同組織資料當對照

三條路不互斥——多數人是三條各走一點；重要的是「下一步」不要停

數學向去 C 系列、工程向去 pipeline 與 Quarto、生物向去領域文獻

一句話總結

**你帶走的不是 19 集的指令，
是一整套「先看資料、再下判斷」的紀律。**

指令會過時，紀律不會。工具換成 scanpy、換成空間平台，這套判斷照樣管用。

自測 1

WNN 的「權重」是什麼層級的權重？

- A 整個資料集共用一組
- B 每個 cluster 一組
- C 每顆細胞自己一組
- D 每個基因一組

答 C。WNN 為每顆細胞各算一組模態權重：該細胞哪個模態的鄰居更能預測它的 profile，哪個模態的權重就高。所以 naive 對 memory T 的區分交給 ADT，B 細胞的辨識交給 RNA——同一份資料裡同時發生。

自測 2

Visium 這類 spot 平台的一個 spot，裡面是什麼？

- A 恰好一顆細胞
- B 約 1-10 顆細胞的混合訊號
- C 一個細胞核
- D 一個基因的表現量

答 B。spot 是固定位置的捕捉區，蓋住幾顆細胞就混幾顆——所以 spot 資料本質上是「帶座標的迷你 bulk」，B17 的反卷積方程直接適用： $\text{spot} \approx \text{signature} \times \text{proportions}$ 。

自測 3

h5ad 轉出來了，Python 端的第一行程式碼應該做什麼？

- A 直接跑 `sc.pp.neighbors` 開始分析
- B 印出物件：看 `shape`、`obs` 欄位、`obsm`
- C 先畫一張 UMAP 慶祝
- D 把 `X` 轉置一次以防萬一

答 B。轉檔是驗收的開始：`n_obs` 是不是細胞數、`obs` 欄位與型別齊不齊、`X_pca` / `X_umap` 在不在。三關都過再動手；「以防萬一先轉置」正好是把對的方向弄錯的方法。

系列收官

B 系列，全 19 集完結

謝謝你走完這張地圖。下一站 C 系列：把 B 系列的每個黑盒子打開，從 SVD 到 UMAP 的目標函數，一步一步算給你看。

工具會更新，資料會更大——但「先看分布、再定閾值、寫下理由」永遠是你的起手式。