

B19 B 系列


複雜樣本的分析策略設計： 不同腫瘤、不同戰法

五個決策點，從生物問題反推整條管線——GBM、黑色素瘤、乳癌、肝癌、AML、多區域，六套戰法。

約 40 分鐘 | 前置：B11、B12、B16（建議 B17 之後看） | 建議順序：B17 → B19 → B18

同一條管線，三種資料，三個結論

GBM 四位病人



彩色＝惡性；灰＝TME

「發現四種
全新腫瘤亞型！」


AML 骨髓



紅＝AML 芽細胞；灰＝正常骨髓

「CNV 乾淨、沒有病人島
——找不到惡性細胞」

黑色素瘤 治療前 vs 後



cell-level DE (實跑)

「治療改變了 120 個基因！」
(真效應：0 個)

模擬資料

同一條 PBMC 教學管線，三種資料，三個自信但錯誤的結論

三個結論都很自信，三個都是錯的——而且程式沒有報任何錯

本集的起點

管線沒有錯， 錯的是策略。

每一行程式碼都執行正確。錯在跑之前沒有人問：這份資料是什麼、這個問題需要什麼設計。

這一集你會學到


- 1 用五個決策點，在動手前把一份複雜樣本的分析策略設計出來
- 2 說出 GBM、黑色素瘤、乳癌、肝癌、AML、多區域六種場景的戰法差在哪、為什麼
- 3 看懂策略決策樹，替自己手上的腫瘤資料選出起點

01

策略設計的五個決策點

從生物問題反推管線，而不是從管線出發

五個決策點



五個決策點答完，工具與參數自己就位——順序不能反過來

每個決策點各有一集講技術細節；這一集講的是「怎麼把它們接成一套策略」


五個決策點，五個問句

這五句話就是 R/B19_strategy.R 裡 strategy_checklist() 印出來的內容


決策點	要問的問題	答錯的代價
① 統計單位	這個比較裡，獨立的觀察值是誰？	假重複：幾千個假陽性（ B12 ）
② 整合強度	哪些細胞該對齊、哪些不能硬拉？	把病人的生物學當批次抹掉（ B11 ）
③ 惡性判定	這種腫瘤，哪種證據拿得到？	惡性與正常劃錯界，下游全錯（ B16 ）
④ 比較設計	批次跟生物效應拆得開嗎？	「治療效應」其實是批次效應
⑤ 下游路線	資料撐得起這條下游嗎？	在湊不齊的格子上硬做，做出雜訊

從問題反推，不從管線出發

管線出發（教學範例的慣性）



問題出發（本集的方法論）



同一批工具、同一套函式——差別只在決策發生在跑管線之前，還是之後

- 管線出發：結論被預設參數決定，錯得很有自信
- 問題出發：先答五個決策點，工具與參數自己就位
- 兩條路用的函式一模一樣——差別只在決策的時機

把策略變成程式： `strategy_checklist()`

```
source("R/B19_strategy.R") # 本集附的策略模板  
strategy_checklist()       # 動手前，五個問題過一遍
```

- B19 策略檢查表（動手前逐題作答並記錄） —
 - [1] 統計單位：這個比較裡，獨立的觀察值是誰？
 - [2] 整合強度：哪些細胞該對齊、哪些不能硬拉？
 - [3] 惡性判定：這種腫瘤，哪一種證據拿得到？
 - [4] 比較設計：批次跟生物效應拆得開嗎？配對了嗎？
 - [5] 下游路線：資料撐得起這條下游嗎？先驗最小格。

答案寫進分析筆記，跟 QC 閾值一樣是「有數字、有理由、有紀錄」

本集核心觀念

參數是假設： 有數字、有理由、有紀錄。

B5 對 QC 閾值講過這句話。這一集把它升級成整條管線的策略原則。


02

GBM：實體瘤的原型


病人島、大 CNV、四狀態、core/margin——前面十八集策略的總裝

GBM 的兩個地標

惡性一人一島（按病人上色）



CNV 又大又典型：chr7 增、chr10 缺




超過八成 GBM 病人帶這對事件——惡性判定的錨

模擬資料

惡性一人一島（B11 的負對照）+ chr7 增 chr10 缺（B16 的錨）——策略從這兩個事實長出來


惡性內部怎麼比＋樣本怎麼取

惡性內部：比「狀態分數」，不比分群



Neftel 四狀態：每位病人都有四種，比例不同——分數可跨病人比

取樣設計：core／margin 配對



同病人配對

core vs margin 先吸掉病人差異，
n=4 也有功效

缺氧梯度

核心壞死、MES 樣偏多——
組成差異本身是結果

邊緣的價值

浸潤前緣細胞少、CNV 弱——
MIN_CELLS 先驗收

示意圖

跨病人比「Neftel 狀態分數」不比分群；取樣用 core/margin 同病人配對

GBM 的五決策點答案

這張表是「策略卡」的格式——之後每種腫瘤各有一張

決策點	GBM 的答案
統計單位	病人；狀態比例與分數都以病人為 n
整合強度	TME 對齊註釋；惡性回未整合空間 per-patient
惡性判定	inferCNV 為主（chr7+/10-），三角驗證
比較設計	core vs margin 同病人配對；邊緣先驗細胞數
下游路線	狀態分數、缺氧 / 解離簽名先排除、TME 通訊


03

黑色素瘤：問題不在腫瘤細胞

免疫腫瘤學場景——鏡頭轉向 T 細胞

主角換人：T 細胞與耗竭軸

免疫腫瘤學：鏡頭對準 TME



耗竭是一條軸，不是一個開關

naive / 記憶

效應

耗竭

TCF7 · IL7R · CCR7

PDCD1 · TOX · LAG3

亞群解析度要夠深

T 細胞先取出、重跑 HVG/PCA/分群——大 UMAP 上看不到耗竭亞群

TCR 是王牌

同 clonotype = 同一家族：追蹤克隆擴增與狀態轉換

示意圖

腫瘤細胞照樣做惡性判定，但研究問題住在 TME——策略重心整個翻過來

responder vs non-responder：比較設計

免疫治療研究最常見的比較——兩個地雷都在設計期

災難版

把細胞當 n 、忽略組成

- 兩組各十萬顆細胞， p 值小到離譜
- T 細胞比例差異被讀成「表現差異」
- response 定義沒鎖定，事後挑分組

正確版

病人為 n 、組成與表現分開問

- 每型別各自 pseudobulk，病人當樣本（B12）
- 組成用比例分析、表現用 DE，兩題分開答
- response 標準收案前定義並寫死

黑色素瘤的三張牌

亞群解析度



T 細胞取出來重跑
HVG/PCA/ 分群——
大 UMAP 看不到耗
竭亞群

TCR 資訊



5' 平台加 TCR 定序：
同 clonotype 追蹤
克隆擴增與狀態轉換
（B4 的多模態）

惡性判定較易




黑色素細胞譜系
marker
（MLANA、
PMEL）平時不在皮
膚樣本大量出現，加
CNV 佐證即可

04

乳癌：亞型先於一切

ER/HER2/TNBC 不是註解，是三種不同的病

亞型分流 + HER2 局部擴增




亞型先於一切：亞型不同，等於不同的病


配對正常乳腺組織的價值

正常上皮當 CNV 參考 + 惡性對照——
乳腺切除檢體常拿得到，設計期就要留

大視窗 (101 基因)：HER2 尖峰被抹平



小視窗 (31 基因)：局部擴增現形



1 6 11 17 22

模擬資料

局部擴增是小事件：inferCNV 預設 101 基因視窗會把它抹平——參數要跟著事件大小走

乳癌的三個決策

先分流再分析



亞型混著跑，DE 比的是亞型組成不是生物學——收案時就按亞型分層

小視窗抓 **focal amp**



HER2 這類局部事件把 window_length 降到 31 左右才看得見；代價是雜訊變多

配對正常上皮



正常乳腺當 CNV 參考+對照；上皮腫瘤 EPCAM 陽性幾乎就是腫瘤（Q 系列講過的癌別差異）


05

肝癌：高代謝與病毒

QC 基線整組換、reference 加病毒、認得極化

肝癌的三個特殊決策

肝細胞天生高 mt：整條基線上移



QC 規則同一條 ($\text{median} + 3 \times \text{MAD}$)，數字整組換

mt 基線上移是組織性質不是垂死（B5 策略室的完整版）；HBV 序列進 reference 是 B2 的 mkref 真實用途

reference 決策：把 HBV 序列加進基因組

GRCh38 + HBV

→ 病毒轉錄本可計數，
HBV+ 惡性細胞現形

肝細胞極化 (zonation) 是連續梯度

門脈區
(糖質新生)

中央靜脈區
(解毒/CYP)

正常肝的梯度會被誤讀成「亞群」——先認得它，再談惡性分群

模擬資料

肝癌策略卡

QC 全部重定



mt 中位數可到 15-20% ; 照抄 5% 會把肝細胞砍光——規則共用 (MAD) , 數字重算

reference 決策



HBV/HCV 序列加進基因組再 mkref : 病毒轉錄本可計數, HBV 陽性惡性細胞現形

極化不是亞群



門脈到中央靜脈的連續梯度會被切成假亞群; 纖維化 TME 的 CAF 與免疫是另一條主線


06

AML：策略幾乎全反


血液腫瘤是最難的一類——實體瘤的三個訊號全數失效

惡性長得像正常

實體瘤：惡性「跳出來」



AML：惡性「躲進去」——分化阻滯才是訊號



示意圖

實體瘤的三個慣用訊號（病人島、CNV、marker）在 AML 全數失效

AML 芽細胞卡在分化階層的前驅段，跟正常前驅重疊——「跳出來」的訊號變成「躲進去」


為什麼 CNV 這條路走不通

惡性 vs 正常的 CNV 分數：事件越小，兩坨越分不開（灰＝正常）


GBM 式：兩條整臂

單一小事件


近二倍體（AML 常見）



AUC 0.99



AUC 0.69



AUC 0.56

分數分不開時，換證據：

突變／融合基因
(定義性變異)

免疫表型
(表面抗原組合)

分化阻滯
(對照正常參照系)

CNV 不是通則，是其中一種證據

同一套 inferCNV 式演算法實跑——工具沒變，是訊號不在

模擬資料

同一套演算法實跑三種事件強度：AUC 從 0.99 掉到 0.56——近二倍體時分數就是分不開

實體瘤 vs AML：全反對照表

同一個問題，兩邊答案幾乎相反——這就是「不同腫瘤不同戰法」的極端版

實體瘤（GBM 型）

惡性靠「異常」辨識

- 一人一島是訊號
- CNV 又大又典型，inferCNV 是主證據
- 整合的負對照＝惡性不能混

AML

惡性靠「對照正常」辨識

- 惡性混在正常分化連續體裡，島會消失
- CNV 常乾淨：靠突變、融合、免疫表型
- 正常骨髓參照圖譜是必需品，不是選配

AML 的五決策點答案

跟 GBM 那張並排讀，才看得出「全反」有多徹底

決策點	AML 的答案
統計單位	病人——這一條不反，永遠不反
整合強度	可與正常骨髓參照圖譜共嵌入：偏離處才是病
惡性判定	分化阻滯＋突變 / 融合＋免疫表型； CNV 退居輔助
比較設計	診斷 / 緩解 / 復發縱向配對是主線設計
下游路線	沿分化階層的組成分析、幹性分數；軌跡有意義（有真階層）


07

多區域與縱向設計

同一位病人的多個樣本——規則跟著「病人內」走


subclone 演化怎麼讀

同一顆腫瘤、三個區域



區域間差異 =
空間 × 演化 × 微環境

subclone 家系樹



主幹事件 = 早期

所有區域共有的 CNV，
起始事件的候選

分支事件 = 晚期

單一區域私有，
代表局部演化

病人內可整合

同病人共享主幹家系，可放一起；
病人之間照舊分開

示意圖

主幹 = 早期、分支 = 晚期；同病人各區域可整合，病人之間照舊分開（B16 的 subclone 判讀升級成設計）


縱向設計：批次的災難與解法

災難設計：治療前後 = 兩個批次



「治療效應」= 批次效應，數學上無法拆開

設計期的解法：配對 + 混批



同病人前後配對；凍存湊批、同批處理，或每批都放前有後——批次跟條件才拆得開

治療前後如果剛好是兩個批次，效應在數學上拆不開——這件事只能在設計期解決（B4、B11 的伏筆）

設計期就要做的三件事

凍存湊批



樣本凍存（細胞核流程），湊齊前後配對同批處理——批次跟條件才拆得開

每格先算細胞數



病人 × 部位 × 型別的最小格決定你能問什麼；
MIN_CELLS 在收案前就要估（B12）

配對優先




同病人配對先吸掉病人效應， $n=4$ 也有功效——這是小樣本研究唯一的統計紅利

08

把六套戰法收成一張圖

本集招牌圖：從「你的樣本是什麼」到完整策略

策略決策樹



六張葉卡是起點不是教條——你的腫瘤可能同時踩在兩張卡上，決策點逐一過就不會迷路

印下來貼在螢幕旁邊。六張葉卡是起點不是教條——決策點逐一過，就不會迷路

六場景速查：一句話戰法

每一句都是那一節的濃縮——講得出後半句的理由，這一集就學會了

場景	一句話戰法
GBM 型實體瘤	惡性 per-patient、CNV 判惡性、狀態分數跨病人比
黑色素瘤型	鏡頭對準 TME：T 細胞深挖、TCR 加分、腫瘤退居配角
乳癌型	亞型先分流；小視窗抓局部擴增；配對正常上皮
肝癌型	QC 基線重定；reference 加病毒；認得 zonation
AML	正常骨髓參照；分化阻滯＋突變＋免疫表型判惡性
多區域／縱向	病人內整合、配對檢定、批次在設計期就防

09

踩雷區

三個雷，每一個都有實跑的後果

雷一： PBMC 管線直接套腫瘤

雷是什麼

把教學範例的整條流程原封不動餵進腫瘤、AML、治療前後資料。



為什麼會踩


管線每一步都能跑完、每張圖都很漂亮——沒有任何訊號告訴你策略錯了。

踩了會怎樣

cold open 的三個結論：病人變「新亞型」、AML 變「沒有惡性」、批次變「治療效應」。

三個錯誤結論的解剖

GBM 四位病人



彩色＝惡性；灰＝TME

「發現四種
全新腫瘤亞型！」


AML 骨髓



紅＝AML 芽細胞；灰＝正常骨髓

「CNV 乾淨、沒有病人島
——找不到惡性細胞」

黑色素瘤 治療前 vs 後



cell-level DE (實跑)

「治療改變了 120 個基因！」
(真效應：0 個)

模擬資料

同一條 PBMC 教學管線，三種資料，三個自信但錯誤的結論

回看 cold open：左＝決策點②沒答、中＝決策點③沒答、右＝決策點①④沒答

雷二：跨腫瘤抄參數

雷是什麼

看到 GBM 論文用 $mt < 20\%$ ，把同一個數字抄到自己的 PBMC 或別種腫瘤上。



為什麼會踩


數字看起來像「腫瘤界的慣例」——但那條線的理由住在那份資料的分布裡。

踩了會怎樣


PBMC 上 6-20% 的垂死細胞全數放行，QC 形同虛設；反方向抄（5% 套肝癌）則屠殺好細胞。

同一個數字，兩種命運

GBM：這條 20% 線是算出來的



PBMC：同一個數字變成災難



模擬資料

參數的「理由」不能跨資料搬家——能搬家的是規則（看分布、算 MAD、記理由）

能跨資料搬家的是「規則」（看分布、算 MAD、記理由），不是「數字」

雷三：忽略病人效應

雷是什麼

DE 時把細胞當獨立樣本，病人這個層級完全不進模型。



為什麼會踩


B12 講過的 pseudoreplication——但腫瘤的病人效應天生更大：同病人惡性細胞共享整套 CNV。

踩了會怎樣

模擬實跑：病人效應 0 時假陽性 0 個，效應拉到 0.6 時 300 個 null 基因裡冒出 64 個「顯著」。

病人效應 × 假陽性：實跑曲線

病人效應越大，cell-level 假陽性越失控（300 個 null 基因實跑）



病人隨機效應大小 (log2 SD)

腫瘤的病人效應天生就大 (CNV 整組不同) ——這條紅線在腫瘤永遠在右端

pseudobulk 全程壓在 0——R/B19_strategy.R 第 3 節可以重現這條曲線

模擬資料

踩雷區小結

**複雜樣本不會讓程式報錯，
只會讓結論悄悄變錯。**

三個雷的共同解法都不是新工具，是動手前把五個決策點答完。

五決策點速查卡

策略速查卡：動手前把五格填滿——每格有數字、有理由、有紀錄

要問自己的問題

預設答案（可推翻，但要寫下理由）

① 統計單位

這個比較裡，獨立的觀察值是誰？

預設：病人。細胞當 n = 假重複

② 整合強度

哪些細胞該混、哪些該留在原地？

TME 對齊；惡性 per-patient；病人內多樣本可合

③ 惡性判定

這種腫瘤，哪一種證據拿得到？

CNV 大→inferCNV；乾淨→突變＋表型＋參照系

④ 比較設計

批次跟生物效應拆得開嗎？配對了嗎？

能配對就配對；混批在收樣本前決定

⑤ 下游路線

資料撐得起這條下游嗎？

先驗收 MIN_CELLS/MIN_PAIRS，再選路

每一格：一個問句、一個預設答案。預設可以推翻——但推翻要寫下理由

六場景參數起點: `strategy_presets()`

```
presets <- strategy_presets() # 六場景起點 (範例值)  
names(presets)  
presets$AML$malignancy
```

```
[1] "GBM"      "melanoma" "breast"  
[4] "liver"    "AML"       "multiregion"  
[1] "分化阻滯 + 突變 / 融合 + 免疫表型; CNV 退居輔助 "
```

注意每個 preset 的註解都寫著「範例值，依資料調整」——它是起點，不是答案

一句話總結

**腫瘤不是單數名詞——
先問樣本是什麼，再決定怎麼打。**

工具會過時，五個決策點不會。

自測 1

策略設計的五個決策點裡，哪一條在六種場景中永遠不變？

- A 整合修到哪
- B 統計單位是病人
- C 惡性判定用 CNV
- D 下游一定要做軌跡

答 B。整合策略、惡性證據、下游路線都隨腫瘤改變——連 CNV 都在 AML 失效。唯一跨場景不變的是：獨立的觀察值是病人，細胞當 n 就是假重複。

自測 2

AML 資料裡「惡性一人一島」的訊號常常消失，原因是？

- A AML 細胞太少
- B 定序深度不夠
- C 芽細胞的表現像正常前驅細胞，且 CNV 常乾淨
- D 整合演算法對血液樣本特別強

答 C。病人島的來源是病人特異的大 CNV 拉動整體表現。AML 芽細胞常近二倍體、又卡在正常分化階層的前驅段，表現譜跟正常前驅重疊——島自然消失，判惡性要換證據。

自測 3

你拿到治療前 4 位、治療後 4 位的黑色素瘤資料，前後各在不同日期定序。DE 該注意什麼？

- A 用更大的 logFC 門檻
- B 治療與批次完全混淆，效應無法歸因；只能當探索並如實寫明
- C 改用 SCTransform 就能校正
- D 把兩批分開各自做 DE 再取交集

答 B。條件＝批次時，任何統計方法都拆不開兩者——這不是校正問題，是設計問題。正確解法在收樣本之前：配對、凍存湊批、混批處理。事後只能誠實降級為假說產生。

下集預告

B18：生態系與收官

十九集的地圖到這裡只剩最後一塊：這條管線之外還有什麼——多組學、空間、Python 世界。工具每年都在換，什麼東西值得帶走？收官見。