

BS2 B 系列・補充


平台大比較： 10x 之外的世界

液滴、微孔、平盤、條碼組合——四大家族一次看懂，還有平台怎麼決定你的 QC 與分析。

約 35 分鐘 | 前置：B2-B5 | B 系列補充第 2 集

同一管血、兩種平台，QC 圖完全不一樣

同一管血、同一天、兩台機器——QC 報告回來了



哪一台壞掉了？——先別急著回答

模擬資料（分布位置為量級示意）

兩張 QC 圖差了約百倍——哪一台壞掉了？

本集的起點

兩台都沒壞。 平台不同，「正常」就長得不同。

一邊數的是 UMI、一邊數的是 reads——連單位都不一樣。看不懂平台，就看不懂 QC。

這一集你會學到

- 1 用「怎麼隔離、有沒有 UMI、讀哪一段」三個問題，認出任何一個單細胞平台的家族
- 2 說出各平台的細胞數量級、深度取向、偏誤，與題庫裡對應的代表資料集
- 3 解釋平台怎麼改變 QC 期望值、正規化選擇與下游分析，並依研究問題選平台

01


原理分家：四大家族

所有平台都在回答同一個問題：怎麼把一顆細胞跟它的條碼關在一起

技術家族樹

單細胞定序技術的四大家族

分家的關鍵只有一個問題：怎麼把「一顆細胞」跟「它的條碼」關在一起



示意圖（規模為量級，取自題庫代表資料集）

液滴、微孔、平盤全長、條碼組合——差別在「隔離的方式」

液滴式：一顆液滴＝一間隔離室



液滴式的核心：一顆液滴＝一間隔離室

細胞流、珠子流、油流在微流道交會——每顆液滴就是一個獨立的反應器

細胞

條碼珠

油



GEM：油包水液滴
細胞＋一顆珠子



珠子上的每一條引子



接頭 cell barcode · 16 bp UMI · 12 bp poly-dT

同一顆珠子：上萬條引子共用同一個 barcode、
各帶不同的 UMI (v3 化學：16+12=R1 的 28 bp)

→ barcode 答「哪顆細胞」
→ UMI 答「哪個分子」

示意圖


B2 拆過的 R1 二十八個鹼基（16 barcode + 12 UMI），物理上就住在珠子的引子上

讀哪一段：全長 vs 3' 端點

讀哪一段：全長 vs 3' 端點

同一條轉錄本，兩種平台看到的部分完全不同

平盤全長 (Smart-seq2)



覆蓋鋪滿整條：
isoform、編碼區突變、
TCR/BCR 全長都看得到

液滴 3' 端點計數 (10x 3')



只讀 3' 端一小段：
分子用 UMI 數得準，
但序列資訊大多看不到

全長=資訊多、每顆細胞貴；端點=定量準、便宜、可大量


示意圖

Smart-seq 鋪滿整條轉錄本； 10x 3' 只讀端點——這一刀決定你日後能做什麼分析

UMI 去重：把 reads 摺回分子

UMI 去重：把 reads 摺回分子

PCR 會偏心地複製，reads 數不可信；UMI 讓你數的是分子



示意圖

有 UMI：counts 是分子數。無 UMI（Smart-seq2）：counts 是 reads 數——兩者不在同一個物理尺度上

有 UMI，counts 是分子數；無 UMI（Smart-seq2），counts 是 reads 數——物理尺度不同

另外兩家：微孔與條碼組合

微孔：Seq-Well



細胞靠重力沉進微孔陣列，免精密幫浦——設備輕、可攜

條碼組合：sci-RNA-seq3



先給條碼、再合併處理，多輪組合相乘——規模上看百萬顆

平盤條碼：MARS-seq / CEL-seq2



孔盤分選 + 每孔條碼 + 合併建庫；有 UMI、讀 3' 端

四大家族總表

規模與深度都是量級——精確數字看各平台的官方頁

家族	隔離方式	UMI	讀哪段	每輪規模
液滴式（10x、Drop-seq、inDrops）	油包水液滴＋條碼珠	有	3' 端	數千–數萬顆
微孔（Seq-Well）	重力沉降進微孔	有	3' 端	數千–數萬顆
平盤全長（Smart-seq2/3）	分選進孔盤，一孔一顆	SS2 無	全長	數十–數千顆
條碼組合（sci-RNA-seq3 等）	先條碼、再合併，多輪相乘	有	3' 端	數十萬–百萬顆

本集核心口訣

**認平台，問三件事：
怎麼隔離、有沒有 UMI、讀哪一段。**

這三個答案，決定了資料的長相、QC 的期望值、跟下游能做什麼。

02

逐平台側寫

每個平台配一個題庫資料集——側寫不是規格表，是預告你的資料長什麼樣

10x Chromium：預設答案

生態系最厚



Cell Ranger 到
Seurat 一條龍；
B1-B5 整段都是它

量級：數千-數 萬顆



基礎 01 的 5k
PBMC (約 5,000
顆) 就是標準的一輪

代價



只看 3' 端、每顆細胞測得淺；doublet 與 ambient RNA 是液滴原罪 (基礎 10)

Smart-seq2：小而深的顯微鏡

全長、深測



每細胞 reads 上看
數十萬級；低表達基
因、isoform、編碼
突變都看得到

量級：數百-數 千顆



進階 02 GBM 3,589
顆、進階 03 黑色素
瘤 4,645 顆——腫
瘤經典多半是它

無 UMI



counts 是 reads、
受基因長度影響；正
規化與 QC 都要換
腦袋（段 3）

Drop-seq vs inDrop：學界的兩位前輩

2015 年同期問世的兩套液滴系統，10x 的商業化原型

Drop-seq

拋棄式、便宜、可自建

- 代表：基礎 08 小鼠視網膜 44,808 顆
- 珠子捕捉率靠運氣，細胞利用率低
- 經典圖譜時代的主力機

inDrop

水凝膠珠、可控包覆

- 代表：基礎 02 Baron 胰島 ~8,569 顆
- 捕捉率較高，適合稀少樣本
- 每細胞深度偏淺，QC 期望值要下修

MARS-seq vs CEL-seq2：平盤加條碼

孔盤分選的精準＋條碼合併的效率——介於平盤與液滴之間的家族

MARS-seq

384 孔盤＋分選

- 代表：基礎 04 造血前驅 ~2,730 顆
- 進階 19 骨髓瘤 51,840 顆——盤數堆上去規模也能大
- 免疫學重鎮的招牌流程

CEL-seq2 / SORT-seq

IVT 線性放大＋條碼合併

- 代表：基礎 09 Muraro 胰島（4 位捐贈者）
- SORT-seq = 自動化的 CEL-seq2
- 矩陣裡常帶著沒過 QC 的空孔——載入先看 `dim()`

Seq-Well：帶著走的單細胞

免幫浦微孔



設備輕、成本低，床邊與野外做得起來

量級同液滴



進階 05 AML
~38,410 顆、進階
16 攝護腺（S3
版） 21,743 顆

資料長相像



10x

UMI + 3' 端；基礎
06 的 COVID 隊列
就是 10x 型矩陣

sci-RNA-seq3：百萬顆的世界

組合條碼相乘



多輪條碼組合，不需要一顆一室——規模指數成長

代表：兩張發育圖譜



進階 56 MOCA 官方清洗後 1,331,984 顆；進階 57 人類胎兒圖譜約 400 萬顆

代價：每顆很淺




靠細胞數換統計力；單顆細胞的判讀要更保守

題庫實景：細胞數 × 深度

題庫裡的真實資料集：細胞數 × 深度量級

橫軸＝官方細胞數（log 尺度）；縱軸＝每細胞深度的量級（示意），往上越深



細胞數是官方數字、深度是量級——右下角規律：越廣的技術，每顆細胞越淺

平台側寫速查表

代表資料集全部出自實作練習題——想親手摸哪個平台，照題號去

平台	家族	UMI	代表資料集（題號）	官方細胞數
10x Chromium 3'	液滴	有	5k PBMC（基礎 01）	~5,000
Smart-seq2	平盤全長	無	GBM 核心 / 邊緣（進階 02）	3,589
Drop-seq	液滴	有	小鼠視網膜（基礎 08）	44,808
inDrop	液滴	有	Baron 胰島（基礎 02）	~8,569
MARS-seq	平盤條碼	有	造血前驅（基礎 04）	~2,730
CEL-seq2 / SORT-seq	平盤條碼	有	Muraro 胰島（基礎 09）	4 位捐贈者
Seq-Well	微孔	有	van Galen AML（進階 05）	~38,410
sci-RNA-seq3	條碼組合	有	MOCA 小鼠胚胎（進階 56）	1,331,984

側寫的用法

看到資料先認平台—— 側寫告訴你該期待什麼。

nCount 該是什麼量級、哪些型別容易缺席、哪些分析做得動——側寫先講好，QC 就不會誤判。

03


平台決定 QC 與分析邏輯

同一套函式、不同的期望值——閾值的理由住在平台裡

nCount 的量級差異

nCount 的量級：七種技術不住在同一條數線上

液滴與微孔數的是 UMI；Smart-seq2 數的是 reads——先問單位，再談大小




cold open 的答案：Smart-seq2 數的是 reads，天生比 UMI 大一到兩個量級

無 UMI 的正規化：長度進場

無 UMI 的隱形變數：基因長度

兩個基因、各 3 個分子——有 UMI 一樣多；數 reads 就差好幾倍



處方：UMI 資料照常 CP10K+log1p；無 UMI 資料要做長度校正（TPM 一族），跨基因比較才公平

示意圖（reads 數為示意比例）

- UMI 資料：長短基因各數各的分子——CP10K + log1p 就位（B6）
- read 資料：長基因天生累積更多 reads，跨基因比較要長度校正（TPM 一族）
- 這就是 Smart-seq 經典資料常給 TPM 矩陣的原因（進階 04 就是 TPM）

全長 vs 端點：下游的分水嶺

讀哪一段不是技術細節，是你日後能問什麼問題

全長（Smart-seq）

序列資訊多

- isoform 與可變剪接看得到
- 編碼區點突變抓得到——B16 說過 10x 只看 3' 端先天吃虧
- TCR/BCR 全長序列可重建

端點計數（10x 3'）

定量準、量大

- UMI 去重把 PCR 偏誤吃掉
- 要配對 TCR/BCR 得換 10x 5' 加 V(D)J（進階 38、45）
- 序列層面的問題大多回答不了

同一個工具、兩個平台：inferCNV 的 cutoff

```
cnv <- infercnv::run(cnv,  
  cutoff = 1,      # Smart-seq：每細胞計數深，用 1  
  out_dir = "output/bs2_infercnv",  
  denoise = TRUE)
```

```
# 換成 10x 資料，同一行要改：  
# cutoff = 0.1      # 差十倍——理由不在工具，  
#                  # 在平台的每細胞深度（B16）
```

B16 的原話：同一條線用錯平台，不是砍掉太多基因、就是留下一堆雜訊基因

拿到資料先過的平台檢查表

五個問題，每個都改變你接下來的動作

檢查	為什麼	動作
counts 的單位是 UMI 還是 reads ？	量級差一到兩個級；不確認就誤判 QC	查平台；分布佐證
nCount 期望量級是多少？	每個平台的「正常」不同	先看分布再定閾值（B5）
正規化要不要管長度？	無 UMI 的 read counts 有長度偏誤	UMI：CP10K；無 UMI：TPM 類
工具參數有沒有平台開關？	如 inferCNV cutoff 1 vs 0.1	讀文件，別抄別人的數字
這個平台的原罪是什麼？	液滴：doublet / ambient；平盤：孔效應與空孔	針對性 QC（基礎 10、基礎 09）

段 3 鐵則

**QC 閾值不能跨平台搬家——
能搬家的是規則，不是數字。**

B5 的「先看分布、再定閾值、寫下理由」，到了新平台一個字都不用改。

04

實測：同一管血、七種技術

pbmcsca——生物學鎖死，剩下的差異全是技術

載入 pbmcscsca


```
install.packages("SeuratData",  
                  repos = "https://seurat.nygenom e.org")  
library(SeuratData)  
InstallData("pbm csca")    # Ding 2020 ; GSE132044  
pbm csca <- LoadData("pbm csca")  
pbm csca                    # 31,021 cells  
  
colnam es(pbm csca[[ ]])    # 欄名親眼確認，別抄教學
```

同一管 PBMC 用七種技術各做一遍：10x v2/v3、Smart-seq2、Seq-Well、inDrops、Drop-seq、CEL-seq2

七種技術：每顆細胞測到幾個基因

同一管血、七種技術：每顆細胞測到幾個基因？

生物學鎖死了，剩下的差異幾乎全是技術——這就是 pbmcscs 的設計




模擬資料（實跑抽樣；量級示意，非 pbmcscs 實測值）

排序是重點：深測技術看得到更多基因——正規化救不了「根本沒測到」


未整合 vs 整合後

先不整合，直視技術效應；整合後再看它救回什麼

同一批模擬細胞跑兩次降維：左按技術聚、右按型別對齊



未整合：按「技術」上色，各自成大陸



模擬資料 (PCA+knn 嵌入實跑兩次)

整合後：按「型別」上色，跨技術對齊

不整合：細胞按技術聚（B11 的技術效應）。整合後：同型別跨技術對齊

某型別在某技術下缺席——三種假說

偵測不到



靈敏度或細胞大小偏好：這個技術對它天生失明

流程丟掉了



分選、裂解、沉降——細胞在上機前就死在路上

抽樣不夠




細胞數太少，稀有群純粹沒抽到——加細胞數就回來

深度換廣度

深度換廣度：兩種顯微鏡，看見兩種東西

左：深測才看得到低表達基因（Poisson 偵測率實算）。右：廣測才數得到稀有族群（期望數實算）



1% 的稀有族群，抓得到幾顆？

深而小：5,000 顆



期望 50 顆

廣而淺：50,000 顆



期望 500 顆

50 顆分不出群；500 顆可以——
稀有群是用細胞數買到的

模擬資料（兩側皆實算）

進階 09 的教訓：5,063 顆 Smart-seq2 的 T 細胞，看見了幾萬顆 10x 看不見的低表達调控子

深而小 vs 廣而淺：怎麼選

兩種顯微鏡看見兩種東西——研究問題決定拿哪一支

深而小

平盤全長路線

- 低表達轉錄因子、受體看得見
- isoform、突變、全長受體序列
- 稀有族群容易整群漏抓

廣而淺

液滴／組合條碼路線

- 稀有群靠細胞數撈得到
- 組成比例、圖譜級問題的正解
- 單顆細胞的訊號毛，判讀要保守

本集主旨

平台是假設的一部分： 它決定你看得見什麼、看不見什麼。

「參數是假設」的上一層——連產生資料的機器，都是分析假設的一部分。

平台選擇決策表

平台選擇決策表：從研究問題出發

正著走選平台；拿到別人的資料就反著走——先認平台，再設 QC 期望值



示意圖

正著走選平台；拿到公開資料反著走——先認平台，再設期望值

這一集的四句話

講得出右欄的理由，這一集就帶走了

段落	一句話
① 原理分家	認平台問三件事：隔離、 UMI 、讀哪段
② 逐平台側寫	側寫預告資料長相；每個平台題庫都有真資料
③ QC 邏輯	閾值不搬家；單位、量級、長度、參數逐一過
④ pbmcscsca 實測	技術效應大於你想像；深度換廣度是真取捨

自測 1

同一管血，10x 報 nCount 中位數幾千，Smart-seq2 報幾十萬。
第一步該做什麼？

- A 懷疑 Smart-seq2 的機器故障
- B 先確認兩邊 counts 的單位：UMI vs reads
- C 把 Smart-seq2 下採樣到跟 10x 一樣
- D 直接合併兩份資料跑分群

答 B。Smart-seq2 無 UMI，counts 是 reads，天生比 UMI 大到兩個量級——這是物理性質不是故障。單位沒確認前，任何 QC 判斷都是瞎猜。

自測 2

為什麼無 **UMI** 的資料跨基因比較前要做長度校正（**TPM** 類）？

- A 因為它的定序品質比較差
- B 因為長基因累積更多 reads，read counts 混入長度效應
- C 因為 TPM 是比較新的方法
- D 不需要：log-normalize 就能校正長度

答 B。全長讀取下，同樣 3 個分子，長基因切出的片段就是比短基因多——reads 差異裡混著長度。UMI 數分子所以免疫；無 UMI 要把長度除掉。log-normalize 修的是深度，不是長度。

自測 3

你要研究 T 細胞裡低表達的轉錄因子與其突變狀態，經費只夠幾千顆細胞。
選哪個方向？

- A 10x 3'：生態系最完整
- B sci-RNA-seq3：細胞數最多
- C 平盤全長（Smart-seq 系）＋分選
- D Seq-Well：設備最便宜

答 C。兩個需求都指向全長深測：低表達基因要深度才看得見、突變要讀到編碼區。細胞數少不是缺點——這正是深度換廣度的正面案例，進階 09 的 5,063 顆 T 細胞就是這樣做的。

下集預告

BS3：工具地圖

平台選完了，工具怎麼選？一千八百多個工具、每年還在長——
下一集給你一張地圖跟一套四步選工具法。想先動手的，題庫基礎 11 就是本集的實作版。