

BS4 B 系列補充


細胞標注資源導覽： 從 marker 到圖譜

四類資源、一張決策樹、三個實戰劇本——標注不缺工具，缺的是知道去哪拿、拿哪個、記什麼。

約 35 分鐘 | 前置：B10、B16 | B 系列補充第 4 集

同一群細胞，三個名字

你的 7 號群 (CD3E+ / CD8A+)



藍 = 待標注的那一群

工具一：SingleR + HPCA

「NK 細胞」

工具二：映射式 (圖譜參考)

「CD8 效應 T」

工具三：marker 打分字典

「NKT 樣細胞」

哪個對？

三個都是
假設，
不是答案

同一群細胞、三個資源、三個名字——差別不在工具，在它們各自背後的參考

三個資源都很自信——差別不在工具，在它們各自背後的參考

模擬資料

本集的起點

三個名字， 三個假設。

B10 的鐵則沒有變：自動標注是假設，不是答案。這一集講的是——假設要從哪些資源產生、怎麼驗證、怎麼記錄。

這一集你會學到

- 1 把細胞標注的資源世界收成四類： marker 字典、工具＋參考集、參考圖譜、腫瘤專用——每類知道首選和雷區
- 2 沿選庫決策樹走一遍，替 PBMC、腫瘤、小鼠三種資料各選出一套資源組合
- 3 帶走維護現況快照與「工具、參考集、版本、日期」四件事的紀錄紀律

01

標注的三條鐵則

資源導覽開始前，先把 B10 與 B16 的規矩擺上桌

三條鐵則

自動標注是假設



任何工具吐出的標籤
都要用 marker 圖
回頭驗證（DotPlot
／ FeaturePlot），
並記下四件事
（B10）

惡性判定靠 CNV



腫瘤樣本先走 CNV
推斷＋跨病人分群行
為，再談細胞型別；
marker 只能標微環
境（B16）


參考集的本質決 定極限




bulk 純化族群：大
類穩、連續狀態弱；
圖譜映射只認得參考
裡有的型別——疾病
狀態會被塞進健康標
籤

鐵則三的證據： bulk 參考 vs 單細胞參考

bulk 參考（兩個純化平均）：硬切成兩類



單細胞參考（沿軸取樣）：連續狀態保得住



模擬資料（相關性比對實跑）

celldex 那批 bulk 參考：大類穩、連續狀態與罕見型別弱——這不是缺陷，是「純化族群」這個本質的極限

同一條連續分化軸： bulk 參考硬切兩類、單細胞參考保得住連續——模擬資料、相關性比對實跑

本集核心觀念

參考集的本質， 決定它的極限。

選資源的第一個問題永遠不是「哪個最新」，而是「它的參考是怎麼來的、裡面有沒有我的型別」。

02

四類資源，一張地圖

先看全景，再逐類進場——第一站：marker 字典

標注資源四象限

示意圖



四類資源各管一件事——日常標注永遠是「自動第一意見+手動 marker 驗證」的組合

日常標注永遠是組合技：自動第一意見+手動 marker 驗證

四類資源總表

類別	代表資源	什麼時候用
I marker 字典	CellMarker、PanglaoDB	手動驗證 cluster 身分、查文獻出處
II 工具+參考集	SingleR+celldex、CellTypist、Azimuth、scType	自動第一意見（cluster 或逐細胞）
III 參考圖譜	CELLxGENE、Tabula Sapiens、HLCA、Allen Brain	幫任何組織找參考、抓子集自建 reference
IV 腫瘤專用	inferCNV、CopyKAT、scATOMIC、3CA、TISCH2、UCell/AUCell	先判惡性、再標狀態；marker 只標微環境

marker 字典雙雄

一個查出處，一個求輕量——用途不同，不是二選一

CellMarker

文獻級 marker 字典

- 2.0 論文實見：26,915 markers、2,578 型別、656 組織
- 83,361 筆條目出自 24,591 篇文獻；人 52,987、鼠 32,285
- 每筆 marker 都能回溯到原始文獻——寫報告的第一站
- 主站已升 3.0；免費免登入

PanglaoDB

一張 TSV 的輕量表

- 8,286 筆關聯、178 型別、29 組織——一個檔案全下載
- 課堂示範、AddModuleScore 快速打分的首選
- marker 表停更於 2020-03-27
- 正式研究不能單獨依賴它——要搭新資料庫

雷一： marker 字典的版本陷阱

雷是什麼

引用 CellMarker 規模數字時不標版本，或把 PanglaoDB 當成「現況」在正式研究單獨使用。



為什麼會踩

CellMarker 主站已升 3.0、2.0 下載頁已 404，3.0 的下載格式以官方頁為準；PanglaoDB 停在 2020——2020 後確立的型別與命名它都沒有。

踩了會怎樣

審稿人開官方頁對不上你引的數字；或你的「新型別」在字典裡查無此人、被錯標成舊命名。

03

自動標注：工具＋參考集

四個工具、一張 celldex 選擇表、一個映射的極限


自動標注工具四件套

方法細節在 B10——這裡只管「什麼情況拿哪個」

工具	路線	原理一句話	起手情境
SingleR + celldex	R	與 bulk 純化參考比相關性	R 流程的第一意見
CellTypist	Python	logistic regression 預訓練模型，共 77 個	Scanpy 流程；免疫用 Immune_All_Low 起手
Azimuth	網頁／R	映射到高品質參考圖譜＋信心分數	組織在官方 15 個參考清單內
scType	R	免參考資料集、cluster 級 marker 打分	快速第二意見、與 SingleR 交叉比對

celldex 參考集怎麼選

celldex 的本質：全是 bulk 微陣列／RNA-seq「純化族群」——大類穩、連續狀態與罕見型別弱



來源：celldex (Bioconductor)；標籤一律回 marker 驗證

七個參考集各有主場——PBMC 用 MonacoImmune 是 vignette 明言的建議

celldex 選擇表 (速查版)

你的資料	參考集	一句話理由
PBMC	MonacoImmuneData	vignette 明言最貼近典型 PBMC
人類多組織第一輪	HumanPrimaryCellAtlasData	涵蓋廣 (微陣列時代圖譜)
大類要粗但穩	BlueprintEncodeData	標籤較粗、錯得少
CD4+ T 亞群	DICE	CD4 亞群解析度高
骨髓／造血前驅	NovershternHematopoieticData	myeloid ／前驅解析度最高
小鼠免疫	ImmGenData	亞型極細 (ImmGen 計畫)
小鼠泛用	MouseRNAseqData	腦、血、心等多組織

另外三位： CellTypist 、 scType 、 與第二意見鐵律

CellTypist (Python 首選)



77 個預訓練模型、
每個約 1 MB ；免疫
最強，也涵蓋肺（含
HLCA ）、腸、腦等；
可用自己的資料訓自
訂模型

scType （快速 第二意見）



免參考、cluster 級
全自動打分；
source() GitHub
腳本使用，最後
release 2022——
當草標與交叉比對，
不當最終答案

第二意見鐵律



重要結論至少兩個獨
立來源：一個比對式
（ SingleR ／
CellTypist ）＋一個
映射或字典式；吵架
的群交給 marker
裁決


R 起手式: SingleR 接上 cellidex

```
library(SingleR); library(cellidex)
ref <- MonacoImmuneData()          # PBM C 首選參考集
pred <- SingleR(
  test  = GetAssayData(obj, layer = "data"),
  ref   = ref,
  labels = ref$labelmain,
  clusters = obj$seurat_clusters) # 第一輪用 cluster 模式
table(pred$labels)
```


完整走讀 (含 delta 檢查與 Azimuth) 在 B10 第 24-31 頁——這裡只確認起手式長什麼樣

映射式標注：原理與極限

原理：投影到參考地圖，鄰居投票



極限：參考裡沒有的型別，會被硬塞



模擬資料

映射式標注 (Azimuth/HLCA 這一路)：清單內組織最省事，但它只認得參考裡有的型別 (進階30 的核心教訓)

Azimuth 官方 15 個參考 (PBMC 161,764 cells、I1/I2/I3 三層標籤) ——但參考裡沒有的型別會被硬塞

雷二：把映射結果當普查

雷是什麼

疾病樣本丟給 Azimuth / HLCA 映射，輸出的健康標籤照單全收——連信心分數都懶得看。



為什麼會踩

映射只認得參考裡有的型別，而且沒有「我不認得」這個選項：疾病特有狀態一定會被塞進最近的健康標籤，分數還看似合理。

踩了會怎樣

纖維化、腫瘤旁、發炎特有的細胞狀態從結果裡憑空消失——這是進階 30 整題在練的教訓。

04

參考圖譜：找參考的地方

工具清單外的組織，答案在圖譜站

四個圖譜入口

CELLxGENE

找參考的第一站

首頁實見 33M+ unique cells、436 datasets、2.7K+ 型別；Census 快照另見 44M+ 人類細胞；下載 h5ad（rds 棄用中）

Tabula Sapiens

人類泛器官

1.1M+ cells、28 器官、24 位捐贈者；v1 是 Science 2022 正式發表、v2 仍是 preprint——引用標明版本

HLCA

肺的圖譜級參考

核心 584,444 cells / 107 人 / 14 datasets（Sikkema 2023）；Azimuth Lung v2 同源；h5ad 約 5.6 GB

Allen Brain

腦專用

全小鼠腦／全人腦轉錄體圖譜；AWS S3 公開、免帳號，h5ad + 官方 Python 工具；泛器官圖譜解析度不足時來這

圖譜變參考：三步

1 ① 找 collection

CELLxGENE 按組織搜，挑注解層級合用、規模合理的 dataset——不是越大越好，是標籤要對口

2 ② 下 h5ad、轉格式

rds / Seurat 下載在棄用中；R 使用者用 zellkonverter 轉檔——基礎 20 練的就是這件事

3 ③ 抓子集自建 reference

取同組織子集當參考，接 SingleR 或 Seurat TransferData ——方法回 B10 / B11，這裡只管素材從哪來

05

腫瘤專用資源

先判惡性、再標狀態——順序不能反

腫瘤標注三件套：現況

腫瘤標注三件套：現況（2026-09 查證）

示意圖

inferCNV

CNV 推斷經典（B16 主角）

官方已宣告停止支援；
Bioconductor 3.21 仍可安裝

正式研究：加測替代品

CopyKAT

自動分 tumor/normal

README 明文：小兒腫瘤與
血液腫瘤（CNA 少）會失效

解法：給已知正常細胞當錨

scATOMIC

pan-cancer 階層式標注

訓練 19 癌種、外部驗證 13 種
(median F1 = 0.99)

清單外癌種：來源判定不適用

鐵則不變：惡性判定靠 CNV+跨病人分群行為，不靠 marker (B16)

inferCNV README 點名的替代品：inferCNA/CopyKAT/Numbat (Numbat 要 allele 資訊，成本較高)

AML 這類近二倍體腫瘤：

CNV 這條路常常走不通，
證據要換 (B19 的 AML 戰法)

三件套各有失效區——工具現況是 2026-09 查證的快照，用前開官方頁再確認

三件套逐一盤點

工具	定位	現況與限制（2026-09）
inferCNV	CNV 推斷經典（B16 主角）	官方 README 宣告停止支援、點名 inferCNA/CopyKAT/Numbat；Bioconductor 3.21 仍收 v1.24.0——教學照用，正式研究加測替代品
CopyKAT	貝氏法自動分 tumor/normal + 亞克隆	README 明文：小兒腫瘤與血液腫瘤（CNA 少）會失效；解法是提供已知正常細胞或用 T cells 當錨點
scATOMIC	pan-cancer 階層式標注 + 惡性判定	v2.0.3 維護中；訓練 19 癌種、外部驗證 13 種（median F1 = 0.99）；清單外癌種的來源判定不適用

狀態註解與查詢站

3CA

腫瘤狀態程式總站

124 datasets、40+ 癌種、5.54M cells、149 個 meta-programs；41 個惡性 MP（含 Neftel GBM 四狀態）在 Gavish 2023 的 Table S2 一份 XLSX 全拿

TISCH2

腫瘤免疫查詢站

190 datasets、6,297,320 cells、約 50 癌種；malignancy / major / minor 三層注解；查 marker 表現超快，但不提供 batch download

UCell / AUCell

打分雙件套

rank-based（UCell）與 AUC-based（AUCell）的 signature 打分——配 3CA meta-programs 或 MSigDB C8 用；打分只給相對富集

替代品

Numbat / inferCNA

inferCNV README 點名的交叉驗證選項；Numbat 是 haplotype-aware，需要 allele 資訊（BAM），作業成本較高

雷三：打分數當惡性判定

雷是什麼

用 UCell / AUCell 給細胞打了個「腫瘤 signature」高分，就把它標成惡性細胞。



為什麼會踩

打分只給「相對富集」——增殖、壓力、代謝 signature 在正常細胞一樣能高分；惡性的證據是 CNV 加跨病人分群行為，不是任何一張 signature。

踩了會怎樣

增殖中的正常前驅被標成癌細胞、下游的「腫瘤異質性」全在分析正常細胞——B16 的鐵則被繞過的代價。

06


決策樹實走與三劇本

把四類資源接成一條可以走的路

選庫決策樹

選庫決策樹：從你的資料出發（細胞標注參考庫・總覽說明）

示意圖



四個問句走到底，最後一律 marker 驗證——印下來貼在參考庫旁邊

決策樹的五個站

1 ① 物種

人或小鼠往下走；其他物種 → Cell Taxonomy（34 物種）、EBI SCEA（21 物種），多半還要自建 marker 清單

2 ② 腫瘤

含腫瘤 → 三件套先判惡性；惡性細胞交給 3CA meta-programs，微環境當正常組織繼續走

3 ③ 組織

在 Azimuth 15 參考內 → 先跑一輪當第一意見；腦 → Allen Brain；其他 → CELLxGENE 找圖譜自建

4 ④ 生態系

R → SingleR + celldex（挑對參考集）+ scType 第二意見；Python → CellTypist（先查 77 模型清單）


5 ⑤ 一律

手動 marker 驗證：CellMarker 查出處 + HPA 蛋白質佐證 + UCSC Cell Browser 看同類研究怎麼標；記四件事

三個實戰劇本

三個實戰劇本

示意圖



三個劇本共同的結尾：一律回 marker 驗證，一律記下工具、參考集、版本、日期

三條路殊途同歸：一律回 marker 驗證、一律記四件事

劇本一： PBMC 第一次標注

第一意見： **Azimuth**



網頁版免安裝，
PBMC 參考
161,764 cells、
l1/l2/l3 三層標籤——
一粗標半小時內拿到

第二意見： **SingleR**



cellDex 選
MonacoImmuneDa
ta； cluster 模式
跑一輪，跟
Azimuth 的標籤對
表

裁決： **CellMarker**



不一致的群回
canonical marker
裁決（B10 的法官
戲），記四件事——
對應題庫基礎 01 /
10 / 12

劇本二：腫瘤樣本

先判惡性



inferCNV 起手、
CopyKAT /
scATOMIC 交叉；
證據是 CNV + 跨病
人分群行為（B16）

微環境照常走



免疫、基質細胞當正
常組織：Azimuth
/ SingleR +
marker 驗證——跟
劇本一同一套

惡性標狀態



3CA meta-
programs + UCell
打分標狀態；
marker 不判惡性—
—對應題庫進階 01
/ 03 / 05 / 37

劇本三：小鼠資料

免疫為主



SingleR +
ImmGenData：亞
型極細；要追單一基
因在哪個族群表現，
回 ImmGen 官網查

泛用組織



MouseRNAseqDat
a 起手；缺參考再補
Tabula Muris（20
器官、FACS +
droplet 兩套）

字典也有鼠



CellMarker 收
32,285 筆小鼠條目
—— marker 驗證不
因換物種而豁免；對
應題庫基礎 07 / 08
/ 15 / 16 / 19

三劇本的共同結尾

**路線可以換，
驗證與紀錄不能省。**

PBMC、腫瘤、小鼠走的是三條路——終點都是 marker 圖加四件事筆記。

07

維護快照與紀錄紀律

資源會變老——你的紀錄不能跟著老

維護現況快照（2026-09）

維護現況快照（細胞標注參考庫，2026-09）

inferCNV	停止支援	README 明文宣告；點名 inferCNA／CopyKAT／Numbat；Bioconductor 3.21 仍收 v1.24.0 可安裝
CellMarker	主站升 3.0	2.0 的下載頁已 404；規模數字引用時標明出自 2.0 論文（NAR 2023）
PanglaoDB	實質停更	marker 表停在 2020-03-27——教學輕量好用，正式研究要搭新資料庫
CELLxGENE	rds 棄用中	rds／Seurat 下載在棄用中，長期以 h5ad／Census 為主——R 使用者要會 h5ad 轉檔
舊網址	已轉址	portal.brain-map.org → brain-map.org；TISCH 用 tisch.compbio.cn；DISCO 換 a-star 網域

查證日 2026-09-07。資源規模與網址會變——引用前花 30 秒開官方頁確認版本，並在報告記下取用日期

五條現況全部出自參考庫 2026-09-07 的逐一查證——這頁本身也會過期，用前重查

四件事紀錄卡

紀錄紀律：四件事卡

示意圖

分析筆記・標注紀錄（示意）

工具

SingleR (cluster 模式)

參考集

celldex : MonacoImmuneData

版本

sessionInfo() 全文貼進筆記

日期

取用日 2026-09-07

參考庫會更新

CellMarker 升 3.0、celldex 換版——
你的紀錄是唯一能重現當時結果的東西

標籤是假設

審稿人問「這個標籤怎麼來的」，四件事就是你的答案

換人接手要能重跑

沒記版本的標注，半年後連你自己都重現不了（B18 的交接驗收）

四件事：工具、參考集、版本、日期——每一次標注都寫進筆記，跟 QC 閾值同一個紀律

工具、參考集、版本、日期——跟 QC 閾值同一個紀律：有數字、有理由、有紀錄

紀錄紀律三個動作

1 ① 開官方頁 30 秒

引用任何規模數字或版本前，先開官方頁確認現況——本集的快照只保證 2026-09-07 那一天

2 ② 筆記記四件事

工具、參考集、版本、日期；版本用 `sessionInfo()` 全文貼進筆記，不要憑記憶

3 ③ 報告寫取用日期

規模數字標明出處版本（CellMarker 的數字標 2.0 論文）；資料下載日寫進方法段

回顧：一張表帶走這一集

你要做的事	首選	要記住的一句話
手動驗證 marker	CellMarker （+ HPA 佐證）	PanglaoDB 已停更，只當輕量輔助
R 自動第一意見	SingleR + celldex 選對參考集	bulk 純化本質：大類穩、連續弱
Python 自動第一意見	CellTypist （Immune_All_Low 起手）	77 個模型，先查清單再上
清單內組織映射	Azimuth 15 參考	參考裡沒有的型別會被硬塞
腫瘤樣本	三件套 → 3CA + UCell	惡性判定靠 CNV ，打分不算數

下一步

細胞標注參考庫



精選 16 + 延伸 20
+ xlsx 速查表——
本集每個數字的出處；
跨物種、蛋白質佐證
等延伸情境都在延伸
庫

題庫對應題



PBMC 標注：基礎
01 / 10 / 12 ； 圖
譜映射極限：進階
30 ； 腫瘤三件套：
進階 01 / 03 / 05
/ 37 ； 小鼠：基礎
07 / 08 等

方法複習



標注怎麼跑回 B10
（ SingleR /
Azimuth 走讀）、
惡性判定怎麼跑回
B16 （inferCNV 全
流程）——本集不重
教方法

一句話總結

工具會換、圖譜會長大—— 驗證的習慣不會過期。

四類資源、一棵決策樹、四件事紀錄：這三樣帶走，資源再怎麼換代你都接得住。

自測 1

拿到一份腫瘤樣本，第一個該打開的資源類別是？

A marker 字典：先查腫瘤 marker

B 工具＋參考集：先跑 SingleR

C 參考圖譜：先找同癌種圖譜

D 腫瘤專用：先做惡性判定

答 D。順序不能反：先用 inferCNV / CopyKAT / scATOMIC 配合跨病人分群行為判惡性，微環境才回一般流程、惡性細胞才談狀態。marker 不判惡性——這是 B16 的鐵則。

自測 2

SingleR + cellDex 在連續分化的造血資料上，把過渡細胞硬分進兩端型別。根本原因是？

- A SingleR 的演算法寫錯了
- B 參考是 bulk 純化族群的平均，沒有中間狀態
- C 資料的定序深度不夠
- D 分群的 resolution 設太低

答 B。cellDex 那批參考的本質是 bulk 純化族群：參考裡只有 A 和 B 的平均輪廓，任何過渡細胞都只能被指派到比較像的一端。參考集的本質決定它的極限——換單細胞參考或圖譜映射才保得住連續。

自測 3

半年後審稿人要你重現標注結果，最能救你的是哪一項？

- A 記得當時用的是哪台電腦
- B 筆記裡的四件事：工具、參考集、版本、日期
- C 重跑一次最新版工具
- D 引用參考庫的網址

答 B。參考庫會更新——CellMarker 升 3.0、celldex 換版、Azimuth 參考改版。重跑最新版得到的可能是另一組標籤；只有「工具、參考集、版本、日期」四件事能把你帶回當時的結果。

下集預告

BS5：富集分析資源導覽

同一份 DE 清單，兩個網站給出完全不同的 top pathway——誰在說謊？（都沒有。）
基因集資料庫、KEGG 的授權地雷、決策樹再走一遍。下集見。