


BS5 B 系列補充

富集分析資源導覽： 從基因清單到生物學

四條鐵則、一張資料庫地圖、一張工具鏈地圖、一棵決策樹——把「跑得動」升級成「選得對」。

約 35 分鐘 | 前置：B12、B13 | B 系列補充第 5 集

同一份清單，兩個網站，兩個答案



同一份清單、同一天送出——兩個 top 榜幾乎沒有交集。誰在說謊？

示意圖

左邊滿是管家類條目，右邊全是干擾素——同一份清單

本集的起點

沒有人說謊： 兩邊的 **universe** 不同。

網站 A 拿全基因體當背景，網站 B 拿偵測到的基因當背景。工具都對，選擇不同——
這一集講的就是這些選擇。

這一集你會學到

- 1 用四條鐵則，在動手前決定富集分析的方法、背景與版本紀錄
- 2 看懂基因集資料庫地圖與授權紅綠燈——包括 KEGG 的三重授權限制
- 3 沿著決策樹，替「清單、排名、打分、活性」四種輸入選對工具鏈

01


四條鐵則

GSEA 與 ORA 的原理在 B13；這裡講的是選擇的原則

鐵則一：輸入決定方法

你手上是什麼？

示意圖



常見錯配：先切 p 值再丟 GSEA——排名資訊被你自己丟掉了

先問「我手上是什麼」，方法與工具自己就位

清單走 ORA ，排名走 GSEA

B13 的結論搬過來當第一條分岔

ORA

你手上只有一份名單

- 輸入：切好閾值的清單＋背景
- 超幾何檢定；對閾值敏感
- 背景設錯，全盤皆錯（等一下實跑）

GSEA


你手上有完整排名

- 輸入：整份排序，不切閾值
- fgsea / clusterProfiler::GSEA
- 先切 p 值再丟 GSEA = 自己丟掉資訊

鐵則二：統計單位往上游追

同一份多病人資料

示意圖



富集分析不會救回上游的錯——排名是垃圾，榜單就是垃圾


富集結果的可信度＝餵進去的 DE 排名的可信度（B12）

鐵則三： universe 是隱形錯誤

模擬資料（實跑）



清單只可能來自中間那圈



清單是隨機抽的——真富集為零；錯誤背景把「偵測得到」讀成了「富集」

隨機清單、零真富集——錯誤背景照樣做出 38% 的「顯著」

universe 的正確寫法

兩個輸入缺一不可：清單＋背景

```
sig.up <- rownames(pb)[pb$padj < 0.05 & pb$log2FoldChange > 1]
universe <- rownames(pb) # 背景 = 這次實際檢定過的基因
length(sig.up); length(universe)

library(msigdb); library(clusterProfiler)
hm <- msigdb(species = "Homo sapiens", collection = "H")
ora <- enricher(sig.up,
                 universe = universe, # 不設，工具拿全基因組頂上
                 TERM2GENE = hm[, c("gs_name", "gene_symbol")])
```

```
[1] 473
```

```
[1] 11143
```

B13 的 ifnb 例子：清單 473、背景 11,143——兩個數字都要進報告

鐵則四：版本要記錄——三件事

參數三件事的富集版；缺一件，結果不可重現

哪個庫、哪個版本



MSigDB 2026.1 ?
GO release 日期?
資料庫每年都在變，
榜單跟著變

哪個方法



ORA 還是 GSEA ?
打分用哪支？參數用了誰的預設？

哪個背景



universe 是誰、多少個基因——跟 QC 閾值一樣寫進筆記

本集核心觀念

先答四條鐵則， 再挑資料庫與工具。

輸入決定方法、單位往上游追、universe 給對、版本記下來——四題答完，剩下的是查表。

02

基因集資料庫導覽

MSigDB、GO、Reactome、WikiPathways——以及 KEGG 的授權地雷

MSigDB 2026.1：一站式總倉庫

MSigDB v2026.1 —— 35,361 個基因集

H 50 Hallmark 低冗餘，起手式	C1 302 位置 染色體位置	C2 7,670 curated 含 Reactome／WP／ legacy KEGG	C3 3,714 調控目標 TF／miRNA 標的	C4 1,006 computational 計算導出
C5 16,283 ontology GO+HPO	C6 189 oncogenic 致癌訊號	C7 5,219 immunologic 免疫擾動	C8 866 細胞型別 scRNA-seq 導出	C9 62 perturbation 2026 新增

存取：官網下載需免費註冊；R 內用 msigdbr 套件免註冊直接取（多物種、tidy 格式）

數字出自官方頁（2026-09 查證）

35,361 個基因集、十個 collection——你只需要認得其中幾個


常用 collection 速查

2026.1 新增 C9——教材寫「C1-C8」的地方要更新

Collection	規模	什麼時候用
H · Hallmark	50	第一輪永遠從這裡起手：低冗餘、好報告
C2 · curated	7,670	含 Reactome / WikiPathways / legacy KEGG 子集
C5 · ontology	16,283	GO + HPO ； 冗餘高，配去冗餘工具用
C7 · immunologic	5,219	免疫擾動 signature ； 免疫學專案
C8 · cell type	866	scRNA-seq 導出的細胞型別 marker 集
C9 · perturbation	62 （新增）	computational perturbation signatures （2026 新館）

GO：最大，也最冗餘

GO release 2026-08-05：38,092 terms (BP 23,974 / MF 10,041 / CC 4,077)



rrvgo /
REVIGO
→



父子項共享基因：40 條，其實一件事

或乾脆改報 Hallmark（50 集、刻意低冗餘）

示意圖

BP 是 marker list ORA 的標配；結果動輒上百條時，先去冗餘再進報告

Reactome vs WikiPathways：兩個 CC0 的通路庫

機制解讀的首選免費組合——都可商用

Reactome

階層式、專家策展

- V97：人類 2,883 條 pathways
- 資料 CC0，免費免註冊
- 訊號／代謝機制解讀的首選；KEGG 的合法替代品

WikiPathways

社群策展、更新快

- 2,090 條 pathways（2026-08 release）
- CC0；clusterProfiler 直接支援（enrichWP）
- KEGG／Reactome 沒收的新主題常在這

KEGG：用之前先懂授權

KEGG (release 119.0 • 587 個 reference pathway maps)

1 FTP 大量下載

訂閱制——
學術單位也要付費

2 REST API

限學術使用者，
且 ≤ 3 請求/秒

3 商業使用

必須另外購買授權

clusterProfiler 的 enrichKEGG / gseKEGG 執行時連網抓 KEGG——學術可用、商業環境不可

合法替代：Reactome (CC0) / WikiPathways (CC0) / MSigDB C2 的 legacy KEGG 基因集

授權條款出自 KEGG 官方 legal 頁 (2026-09 查證)

本集最重要的一張踩雷卡——尤其是要進業界的人

KEGG 何時用、何時繞路

還是用它的理由



pathway 圖仍是全
場最漂亮
(pathview 上色) ;
學術教學可用

繞路的理由



商用專案、需要離線
批量基因集的流程—
—授權過不了

替代路線



Reactome /
WikiPathways
(CC0) , 或
MSigDB C2 的
legacy KEGG 集

資料庫授權紅綠燈

數字出自官方頁（2026-09 查證）

綠燈：商用也安心

Reactome	CC0（公有領域）・ V97、人類 2,883 pathways
WikiPathways	CC0 ・ 2,090 pathways，社群策展
STRING	CC BY 4.0（標注來源即可商用）・ v12.5
Gene Ontology	免費免註冊 ・ release 2026-08-05

黃燈：可用，但有門檻

MSigDB	官網下載需免費註冊；msigdb 套件免註冊
DISGENET	已商業化：免費層需學術申請，批量下載不再開放

紅燈：商用環境直接繞路

KEGG	三重限制：FTP 訂閱制／API 限學術／商用須購買
viper	非商用授權（decoupleR 內建方法之一）

學術環境幾乎都綠；商用環境先看這張再選庫

踩雷警告

**商用環境裡，
授權是法律問題，不是技術問題。**


enrichKEGG 在公司電腦上一樣跑得動——跑得動不代表跑得合法。

03

工具鏈導覽

檢定、打分、活性推斷——三條路線，各自的主力

三條路線，三種問題



三條路的結論都要回到 cluster/病人層級做統計——統計單位往上游追 (B12)

示意圖

先確認你問的是哪一種問題，再挑那條路線的工具

檢定路線的主力三件套

B13 的教學主力，全在 Bioconductor 上

套件	版本	定位
clusterProfiler	v4.20.0	ORA + GSEA 統一介面；吃 GO / WikiPathways / 任意 GMT
fgsea	v1.38.0	preranked GSEA ；快，適合多 contrast 批跑
enrichplot	v1.32.0	dotplot / cnetplot / emapplot / gseaplot2 的產線

打分路線： GSVA vs 逐細胞

同樣是打分，層級不同、工具不同

樣本層級

GSVA (v2.6.6)

- `genexsample` → `genesetxsample` ; 四方法含 `ssgsea`
- `pseudobulk` 的 pathway 分數，接組間統計
- `cell-level` 可跑但受 `dropout` 影響

細胞層級

escape / UCell / AUCell

- `escape` (v2.8.0) 一站式：四種打分同一介面
- `UCell` / `AUCell` : rank-based , 對 `dropout` 較穩
- 打分是描述——結論回 `cluster` / 病人層級

活性推斷三件套

推「活性」不是看「表現」—— TF 的 mRNA 低表現、dropout 嚴重

decoupleR



統一介面跑多種推斷方法； R v2.17.0，官方重心已移 Python 版 decoupler

CollecTRI： TF 字典



1,186 個 TF、43,175 條有向 TF-gene 關係；DoRothEA 的官方接班人

PROGENy： pathway footprint



14 條 pathways；用擾動實驗的 footprint 基因推活性

維護現況快照（2026-09 查證）

工具會過時——這張表本身也會，引用前開官方頁再確認

資源	現況	該做什麼
DoRothEA	官方已建議改用 CollecTRI	只在重現 2023 以前的文獻時用
SCENIC（R 版）	官方棄用	用 pySCENIC；新專案評估 SCENIC+
pySCENIC	最新 release 0.12.1（2022-11），維護緩慢	教材與報告要註明維護現況
viper	非商用授權	商業環境改用 ulm / mlm 等方法

網頁快查三站

貼上清單、三十秒拿到總覽——先偵察，再正式做

工具	規模／版本	強項
Enrichr	225 個 gene-set libraries ； 免登入	跨庫總覽最快；課堂演示首選
g:Profiler	Ensembl 114 、 400+ 物種	非模式物種的救援站； gprofiler2 可進 R 流程
ShinyGO	v0.86 （ Ensembl 115 、 925 物種）	圖表現成、免登入
DAVID	Knowledgebase v2025_2 ； 快照較舊	只在對照老文獻時用

網頁工具的三個極限

無法設 universe



背景由網站決定——
冷開場的災難就是這
樣來的

版本不可控



網站哪天更新了庫，
你的結果就再也重現
不出來

正式結果回 R



clusterProfiler +
msigdbR + 記版本——
論文用這條路

一句話收下

網頁快查是偵察， 不是報告。


偵察給你方向感；進論文的每一個數字，都要走可重現、可記版本的那條路。

04

決策樹實走

一棵樹、五個分支、兩個實戰劇本

決策樹：從你手上的東西出發



資料庫怎麼選？

- 第一輪永遠：MSigDB Hallmark (50) + GO BP
- 訊號／代謝機制 → Reactome (CC0) > KEGG (授權三重限制)
- 主題新、社群策展 → WikiPathways (CC0)
- 商用環境 → 避開 KEGG；用 Reactome / WikiPathways / STRING (CC BY)

完整決策樹見：參考庫/富集分析參考庫/總覽說明.md

本集招牌圖——完整版在富集分析參考庫的總覽說明裡

五個分支，一句話走完

你手上是	走哪條	記得
顯著清單	網頁快查探索； enricher + msigdb 正式做	設 universe （鐵則三）
完整排名	fgsea ； 基因集首選 Hallmark	排名來自 pseudobulk （鐵則二）
要逐細胞打分	escape 一站式，或 UCell ／ AUCell 單用	打分是描述，統計回上層
要推活性	decoupleR + CollecTRI （TF ） ／ PROGENy （ pathway ）	別直接讀 TF 表現量
多個清單要一次比	Metascape multi-list	單清單就用不著它

劇本一： ifnb 刺激反應

B13 的資料、本集的選庫邏輯——基礎 03 同款

- 1 ① 偵察** DE 清單貼進 Enrichr 快看方向——預期看到干擾素主題
- 2 ② 定路線** 有 pseudobulk 完整排名 → GSEA 路線（鐵則一）
- 3 ③ 選庫** 第一輪 Hallmark 50 ；要機制細節再加 Reactome
- 4 ④ 實跑** fgsea + msigdb ; 已知答案驗證： IFN response 必須是榜首
- 5 ⑤ 記錄** MSigDB 版本、方法、排名來源——寫進筆記（鐵則四）

劇本一的最小骨架

與 B13 同一份資料，答案也同一個

```
ranks <- setNames(res$stat, rownames(res)) # pseudobulk 排名
hallmark <- split(hm$gene_symbols, hm$gs_name) # msigdb 抓的 H 館

library(fgsea)
set.seed(1234)
gsea <- fgsea(pathways = hallmark, stats = ranks,
              minSize = 15, maxSize = 500, eps = 0)
head(gsea[order(gsea$padj),
            c("pathway", "NES", "padj")], 2)
```

	pathway	NES	padj
1	HALLMARK_INTERFERON_ALPHA_RESPONSE	2.88	4.1e-23
2	HALLMARK_INTERFERON_GAMMA_RESPONSE	2.79	4.1e-23

IFN- β 刺激的資料，IFN response 就該是榜首——已知答案，對上了

劇本二：腫瘤狀態打分

B16 / B19 的場景——進階 03、06、12 同款

- 1 ① 定路線**
問題是「每顆惡性細胞處在什麼狀態」→ 打分路線
- 2 ② 選基因集**
Hallmark 定大方向；腫瘤狀態接 3CA meta-programs（細胞標注參考庫）
- 3 ③ 選工具**
escape 一站式（可同時比四種打分），或 UCell 單用
- 4 ④ 先排除干擾**
解離壓力與缺氧 signature 先過關，才允許進結論（B13 策略室）
- 5 ⑤ 收斂**
分數是描述——組間結論回病人層級統計（鐵則二）

劇本二的三個地雷

循環論證



拿這份資料的
marker 當基因集回
打同一份資料——結
論早藏在輸入裡
(B13 雷二)

壓力訊號當生物學



解離壓力／缺氧分數
高的細胞群，先問取
樣再談狀態

拿分數直接檢定



幾千顆細胞的分數丟
t 檢定＝假重複還魂
——單位是病人

什麼時候跳出精選、用延伸庫

延伸庫 13 個資源，各有一句「適用條件」——這裡挑五個

你的情況	用
多個 cluster 的 marker lists 要一次比較	Metascape
要網頁版 GSEA （不只 ORA ）或代謝體富集	WebGestalt
要 PPI 網絡+跨庫富集一次拿	STRING（CC BY，商用可）
GO 結果冗餘爆炸	rrvgo / REVIGO
全 Python 流程	GSEAPy + decoupler-py

這一集的地圖，一頁收完

段落	一句話
四條鐵則	輸入決定方法；單位往上游追； universe 給對；版本記下來
資料庫	Hallmark + GO BP 起手；機制找 Reactome ；商用避 KEGG
工具鏈	檢定 clusterProfiler ／ fgsea ； 打分 escape ／ UCell ； 活性 decoupleR
決策樹	從「你手上是什麼」出發，五個分支各有歸宿

下一步

參考庫



富集分析參考庫三個
檔：總覽（決策樹）、
精選 16、延伸 13
—— 本集所有數字的
出處

題庫對應



基礎 03（第一次富
集）、基礎 06 / 進
階 24
（ pseudobulk→GS
EA ）、進階 03 /
06 / 12（打分）

活性推斷實戰



進階 04 / 31
（ CollecTRI TF 活
性）、進階 24 / 50
（ PROGENy
pathway 活性）

一句話總結

**清單不是終點：
選對庫、選對路線，
它才變成生物學。**

而「選對」的每一步——方法、背景、版本——都寫得進筆記、查得回出處。

補充系列到此

BS 系列完結：五張地圖都在你手上

資料、平台、工具、標注、富集——五集補充講的都是同一件事：資源會過時，選擇的原則不會。
參考庫與題庫在那裡等你，隨時回來查。