

B 系列 B 系列

B 系列 · 實作篇

總結卡與重點卡

十九集動手做完之後，值得單獨記住的那些東西。
可以單張截圖、可以整份印出來貼在螢幕旁。

B1-B19 濃縮 | 36 張 | 數字全部來自實測

B 系列地圖：一張看懂十九集

四段三個交棒點：上游交 count 矩陣、核心交註釋好的物件、應用交 DE 結果——每次交棒都是一個 RDS 檔

上游 B1-B4



FASTQ → count 矩陣

B1 環境建置+第一張 UMAP | B2 mkref 與 FASTQ 解剖 | B3 count 與 web_summary 判讀 | B4 aggr / multi / Feature Barcode

核心 B5-B10



矩陣 → 有名字的細胞地圖

B5 QC 用分布定閾值 | B6 normalization 與 HVG | B7 PCA | B8 分群 | B9 UMAP | B10 註釋——PBMC 3k 一路貫穿

應用 B11-B12



多樣本 → 可信的差異

B11 整合與批次診斷 | B12 pseudobulk + DESeq2 ——全系列統計上最重要的一課；ifnb 撐起這條支線

進階下游 B13-B19



拿到清單之後的「然後呢」

B13 富集 | B14 通訊 | B15 軌跡 | B16 inferCNV | B17 反卷積 | B19 腫瘤策略 | B18 生態系收官

01

上游四集 · Cell Ranger

B1-B4 : count 還沒開跑，結果已經被決定了一半

B1 · 環境建置與第一張 UMAP

一句話定位：今天裝好環境，今天就跑出第一張 UMAP——環境是實驗設備的一部分



版本要驗

R 4.3 以上 + Seurat v5，packageVersion 要親眼看到 5.x；renv 鎖住整套版本，結果才能重現



路徑要相對

RStudio Project + 相對路徑；全系列腳本裡永遠沒有 setwd、沒有絕對路徑



15 行跑完全程

Read10X 到 DimPlot：過濾後 2,638 顆、9 群。數字對就算重現——UMAP 鏡像翻轉是同一張圖



踩雷一句話

不管版本直接裝最新（v4 教學碼在 v5 的 Layers 架構下爆炸）；setwd 寫死絕對路徑，換台電腦第一行就死

B2 · 參考基因組與 FASTQ：mkref 與 mkfastq

一句話定位：FASTQ 回答「誰、什麼、哪個樣本」，reference 決定「哪些基因數得到」



三個檔案

R1 = barcode + UMI（誰）、R2 = cDNA（什麼，唯一拿去比對的）、I1 = sample index（哪個樣本）



reference = 兩件事

FASTA 管比對、GTF 管計數，版本必須一致。同一批 FASTQ，兩個 reference 測到的基因數差 2,300 個（20,300 vs 22,600）



加轉基因的儀式

GFP 要同時加進 FASTA 與 GTF；建完 reference，一行 grep 在 GTF 裡搜到基因名，才准開 count



踩雷一句話

大聲的雷（版本混搭、R1 當 cDNA）當場爆；安靜的雷最貴——GTF 忘了加 GFP，計數永遠是精確的零，全程無警告

B3 · cellranger count 與 web_summary 判讀

一句話定位：count 產出的不是答案，是報告；放行與否，由讀報告的你決定



四關放行

警告訊息、細胞數（對上機記錄）、knee plot 形狀（高原—陡崖—平台）、mapping 分解表。四關全過才進下游



健康範圍

Valid Barcodes > 97%、Mapped to Genome 八九成；細胞樣本 exonic 約 55%、intronic 約 28%——intronic 反轉衝上五成＝細胞質流失（snRNA-seq 例外）



saturation 是經濟指標

32% 飽和時 reads 翻倍只多 43% UMI，再翻倍只多 19%——問「median genes 夠不夠回答問題」，不是「幾 % 及不及格」



踩雷一句話

把 web_summary 的數字當孤立分數看——沒有對照物的數字不叫判讀，叫看心情

B4 · 多樣本與多模態： aggr、 multi、 Feature Barcode

一句話定位： count 管一個樣本， multi 管一個實驗；合併，預設留給下游

三種「多」

多 lane 交給 count 自動處理；多樣本先各跑 count、合併預設走 R 端；CMO / VDJ 走 multi，ADT / HTO 用 count + Feature Barcode 也行

aggr 的代價

depth normalization 會把好樣本抽淺到跟最爛的一樣——多數情況關掉，深度差異留給下游統計處理

hashing 三種輸出

demultiplex 給 singlet / doublet / negative；negative 不要一律丟——有些族群 HTO 本來就染不上

踩雷一句話

GEX 與抗體的 FASTQ 配對填反，兩邊比對率同時暴跌——看到「兩邊一起爛」，先回頭檢查 libraries CSV

02

核心與應用 · Seurat

B5-B10 核心流程做出細胞地圖， B11-B12 讓多樣本的差異可信

B5 · 讀入資料與 QC

一句話定位：先看分布，再定閾值；定了閾值，記下理由——答案隨資料變，流程不變



實測數字

13,714 個基因 × 2,700 顆細胞，過濾後剩 2,638 顆——濾掉 62 顆、約 2.3%。每一步濾掉多少，都要留下紀錄



兩派定線法

固定閾值（這份資料是 nFeature 200-2,500、mt < 5%——別搬去別的組織）與 median ± 3×MAD，互相檢查；過濾前先存 pbmc_raw.rds



doublet 處理

每多回收一千顆，doublet 率約 +0.8%；DoubletFinder 標記不移除，標籤進 metadata，分群後再清算



踩雷一句話

mt 一律砍 5%（心肌會全滅）；先過濾再看分布（順序反了）；QC 一輪定案（殘渣群要到分群後才現形）

B6 · Normalization、HVG、Scaling

一句話定位：三步解三個問題—— normalization 解深度、HVG 解雜訊、scaling 解量級；選哪條路線不重要，有理由並走完才重要

→ 兩條路線

LogNormalize (CP10K + log1p) → vst 選 2,000 個
HVG → ScaleData (z-score + clip) ; 或 SCTransform 一行三步合一

實測對決

兩路線 HVG 重疊 1,245 / 2,000 (六成出頭) ; 主要族群結構與經典 marker 的結論，兩邊完全一致

✓ 保命檢查

跑完 PCA，算一下 PC1 與 nCount 的相關——一行程式碼、三秒鐘，擋掉最貴的災難

踩雷一句話

跳過 normalization，PC1 變成定序深度軸；SCT 之後再 log 一次，雙重壓縮讓 marker 灰成一片

B7 · PCA 與維度選擇

一句話定位：三種方法框出一個區間，往多的一側定案，理由記下來——然後停止焦慮



三法定 nPC

ElbowPlot 拐點落在 7-12、量化 cutoff 指到 PC13、穩定度掃描確認在平原上——本系列定案 1:10



寬容但不對稱

nPC 10 與 30 幾乎同一張圖；nPC = 5 時兩個 T 亞群直接融合消失——亞群訊號常住在 PC7 這種中段弱 PC



方法段直接抄

「取前十個 PC。ElbowPlot 拐點落在七到十二；相鄰變異差小於千分之一的位置在 PC 十三。」



踩雷一句話

nPC 太少是唯一致命錯——亞群無聲消失、沒有報錯；PC1 若是深度／核糖體（實測相關 0.98），回 B6 修 normalization

B8 · 分群： resolution 掃描與 clustree

一句話定位：分群給的是假說； clustree 找穩定層， marker 定生死，理由寫下來

掃描實測

resolution 0.2→1.4：群數 6、8、10、11、13、15、16——同一份資料，群數翻了快三倍。群數是問出來的，不是資料告訴你的

定案邏輯

穩定帶 0.4-0.8；0.6 的十群每刀有 marker 撐，0.8 多的那刀前十名全是 RPL / RPS、pct 兩邊 99%——是狀態深淺，不是型別。定案 0.6

定案前驗屍

每群的 QC 中位數與 doublet 比例都要查；血小板群 nFeature 天生低——單一指標永遠不能定罪，要跟 marker 一起看

踩雷一句話

調 resolution 調到想要的群數（循環論證）；跨 run 只認交叉表、不認編號；殘渣群也有 marker 清單——「自成一群」不是生物學

B9 · UMAP / t-SNE：參數、隨機性、可重現性

一句話定位：分析在 PC 空間，圖在 UMAP；seed 釘死，參數寫下來



seed 三層級

set.seed(1234)、RunUMAP 的 seed.use、單執行緒+記版本——三層都處理，論文圖才能重現



兩個旋鈕

n.neighbors 5 / 30 / 100 控局部對全域；min.dist 0.01 / 0.3 / 0.8 控群內鬆緊——壓小 min.dist，任何資料都「分得很開」



距離實測翻臉

換個 seed：群 4- 群 1 距離 7.1→14.1、群 4- 群 5 是 16.7→7.6；15 組群間距離的排序相關 $\rho = -0.04$ ——跟丟銅板差不多



踩雷一句話

UMAP 上只有一件事可信：這一群的成員是誰。距離、面積、形狀、留白，全是佈景——座標永遠不進統計

B10 · 細胞註釋： FindAllMarkers、SingleR、Azimuth

一句話定位：手動建假說，自動來驗證；吵架的時候，證據等級說了算—— canonical marker > 參考集相似度 > 富集猜測



讀表的順序

先 avg_log2FC 看效果量，再 pct.1 對 pct.2 看排他性，最後 p_val_adj 把關——不是按 p 值排



好 marker 的長相

CD79A： pct 0.94 對 0.04； NKG7： 0.99 對 0.13、log2FC 4.05。反例 B2M： 1.00 對 0.99——全世界都表現，p 值再小也不是 marker



三方交叉驗證

手動面板（CD3E、MS4A1、CD14...）+ SingleR + Azimuth；不一致的群逐一裁決，最終標籤入 metadata、原編號保留



踩雷一句話

p 最小 ≠ 最好 marker；自動標籤直接當結論（參考集沒有的型別會被硬塞最近的名字）；subcluster 還用大類 marker——CD3E 分不出四個 T 亞群

B11 · 多樣本整合與批次效應診斷

一句話定位：先看未整合的基線，再整合；整合後，用金絲雀驗收



三種方法一個介面

IntegrateLayers 換方法只換一個參數：RPCA 保守、Harmony 快（theta 預設 2，混過頭先調小它）、CCA 強但最易過度校正；樣本不足百顆要調小 k.weight



驗收三查

split.by 看同群是否同位置；每群條件比例（健康落在 46-55 開）；已知 marker 跨條件亮同一個位置



金絲雀測試

一個「早該存在」的條件特異族群，整合後應仍自成一群。鳥死了＝校過頭，這次整合作廢。全圖完全混勻不是滿分，是警報



踩雷一句話

沒留未整合基線就無從判斷整合改變了什麼；所有樣本無條件整合會拉散稀有族群；integrated 值拿去做 DE——鐵則：幾何用整合，統計回 RNA

B12 · 差異表達：FindMarkers 的陷阱與 pseudobulk + DESeq2

一句話定位：把細胞加總回樣本，把統計交還給樣本

× 天真做法的實測

FindMarkers 跑 stim vs ctrl：3,187 個顯著基因、p 值頂到 $1e-320$ ——但全實驗只有 16 個人。細胞共享 donor 與批次，有效 n 是 8 對 8



正確做法

AggregateExpression（樣本 × 型別加總 RNA counts）→ DESeq2 → lfcShrink：上調 1,024 + 下調 906 $\approx$ 1,930 個。模擬資料更乾脆：naive 303 對 pseudobulk 106



三個守門員

RNA counts（資料層對）、真實的 n（樣本數誠實）、效應量與表現量（榜單基因逐一畫每樣本點圖——baseMean 2.1 撐出的 $\log_2FC$ 3.9 別當主角）



踩雷一句話

integrated 值做 DE（DESeq2 直接報 negative values 錯，這報錯是恩賜）；n=2 對 2 硬跑還宣稱結論；火山圖只看 p 不看 FC 與表現量

03

進階下游七集 · B-IV (B13-B19)

B13 清單變結論、 B14 誰在對誰說話、 B15 狀態的時間軸、 B16 誰是惡性、 B17 反哺 bulk、 B19 不同腫瘤不同戰法、 B18 攤開地圖——工具永遠會給答案，你的工作是判斷答案存不存在

B13 · DE 之後：功能富集與基因集分析

一句話定位：GSEA 問方向、ORA 問名單、模組分數問位置——三層答案要互相對得上

兩條路線

GSEA 吃全部基因的排序（統計量排序，不切顯著閾值）；ORA 吃清單＋背景。清單短，正是改用 GSEA 的訊號——把 B12 的 1,930 個基因變成一句生物學結論

已知答案驗證

fgsea + Hallmark 跑 ifnb CD14 單核球：榜首 INTERFERON_ALPHA_RESPONSE NES 2.88、第二名 IFN- γ 2.79——答案寫在實驗設計裡；榜首不是它，先查流程不是資料

報主題，不報條目

GO 父子項重複計數，「前 20 條」常常只有三個發現；simplify 去冗餘＋按主題收斂（這份資料就三個主題：干擾素抗病毒、抗原呈遞、趨化因子），同主題 NES 方向要一致

踩雷一句話

背景基因集錯置最毒：universe 用全基因組而非偵測到的基因，實測七個測試條目全數「顯著」、多出的四條（核糖體、轉譯…）全是假訊號；拿自家 marker 清單問富集＝循環論證

B14 · 細胞通訊：配體-受體與 CellChat

一句話定位：CellChat 把表達量變成「值得驗證的通訊假設」——產生假設很強，當證據不夠

→ 流程一條鏈

createCellChat → identifyOverExpressed →
computeCommunProb (triMean 約需 25% 細胞表達) →
aggregateNet ; CTRL 與 STIM 各自建物件、參數一致，
mergeCellChat 之後才比較

☘ 粒度 8 vs 14 翻盤

同一份資料：8 群時結論是「單核球對 NK 送 CXCL10」；
14 群時活化 T 獨立成群（只佔 T 細胞 5%），最強軸換成
「單核球對活化 T」——重要結論換一個粒度重跑

⚖ p 值與機率成對報

permutation p 只說「比隨機高」——nboot 100 時解析度就是 1/100，一大排觸底、沒有排序能力；強弱看通訊機率。
min.cells 10 是底線，小群的分數是骰子

⚠ 踩雷一句話

三個假設一個都沒驗證——RNA ≠ 蛋白 ≠ 分泌 ≠ 真的接觸到；
通訊是推論不是觀察，結論的動詞永遠是「提示」

B15 · 軌跡分析與擬時序

一句話定位：軌跡回答「怎麼走過去」；「有沒有在走」要你先答——工具永遠會給你一條線

✓ 資格審查三題

過程連續？中間態被取到？ root 有生物學依據？ PBMC 的離散型別硬拉，照樣畫出漂亮的「分化路徑」——分支點落在型別交界＝人工產物

✗ root 反轉實測

換一個 root 重跑 Slingshot：新舊 pseudotime 的等級相關 - 0.998，整條順序倒轉、成熟 marker 的 smoother 由升轉降——方向錯了，全程沒有任何警告

🗺 算在 PCA，看在 UMAP

對真實時間的等級相關：PCA 空間 0.99、UMAP 座標 0.98——差距小是這份模擬資料的運氣，UMAP 還把主幹隨機撕成孤島，局部順序被重排、pseudotime 品質交給了 seed

⚠ 踩雷一句話

pseudotime 是曲線上的弧長——是順序，不是時鐘；在 UMAP 座標上算還宣稱定量，等於把 B9 的「距離不可信」全部忘掉

B16 · 腫瘤場景： inferCNV 與惡性細胞判定

一句話定位：惡性判定看基因組的影子——排序、開窗、比基線，然後三角驗證



原理一條鏈

依基因組座標排序 → 滑動窗口平均壓掉單基因雜訊 → 相對 reference 的染色體級偏移； oligodendroglioma 內建範例的 chr1p/19q 缺失，是教科書級的訊號



reference 選錯歸零

拿疑似惡性的群當基線實跑：它自己的缺失整排歸零變全白，真正的正常細胞反而在 1p/19q 冒出假「增加」——方向整個反轉，而且錯圖看起來毫無破綻



三個假訊號來源

基線錯置； HLA / IG 基因簇共調控被平滑成假擴增（模擬的純二倍體細胞照樣在 chr6 長出紅山）；近二倍體腫瘤 CNV 乾淨——推論是單向的：有事件幾乎必惡性，沒事件推不出正常



踩雷一句話

CNV 是證據之一，不是判決書——判定用 CNV × 分群 × marker 三角驗證；reference 只放有把握的免疫與基質，出圖第一眼先看 reference 那幾列乾不乾淨

B17 · 反卷積：用單細胞參考拆解 bulk

一句話定位：先用已知比例的假 bulk 對過答案，再去拆你沒有答案的真 bulk



同一條等式兩個方向

bulk $\approx$ signature $\times$ 比例：B12 往回加、B17 往回拆。pbmc3k 註釋建 138 基因 $\times$ 6 型別的 signature（CD4 對 CD8 欄相關 0.8 登記在案），自混 20 個已知比例假 bulk，NNLS 對答案



整體分數會騙人

整體 $r = 0.992$ 、RMSE 0.02——被 CD4、Mono 這些大型別撐起來；逐型別拆開看，低於 5% 的稀有型別誤差顯著較高。豐富型別準、稀有型別飄



缺型別 = 近親頂替

把 NK 從參考拿掉：CD8 估計從 12% 跳到 22%（真值 13%）——NK 的份整批塞給共享毒殺模組的近親，而且不知道真值時毫無破綻。拆之前先問：主要型別，參考都有欄嗎



踩雷一句話

比例是成分資料：只有 CD8 擴增四倍，其他型別的佔比「看起來」全在掉——措辭永遠用佔比、跨樣本先 CLR；跨平台直接套是系統性偏差，樣本再多也救不了

B18 · 生態系與收官：多組學、空間、Python

一句話定位：你帶走的不是十九集的指令，是「先看資料、再下判斷」的紀律



模態地圖與 WNN

CITE-seq / scATAC / 空間 / TCR-BCR 各補轉錄組的一個盲點；WNN 的權重是每顆細胞自己一組——T 亞群的區分交給 ADT、B 細胞的辨識交給 RNA，同時發生



spot = 帶座標的迷你 bulk

Visium 一個 spot 混約 1-10 顆細胞——B17 的反卷積方程直接適用；地圖上的路線，彼此接力



h5ad 三個坑

過得去：X、raw、obs、obsn；會掉：scale.data、KNN 圖、多 assay、factor 層級。轉完第一行先印 shape——「以防萬一先轉置」正好把對的方向弄錯



踩雷一句話

跨生態系交接當成搬家驗收——搬家公司不會告訴你哪個箱子掉了：shape、欄位型別、圖層三行檢查碼，省你三天 debug

B19 · 複雜樣本的分析策略設計：不同腫瘤、不同戰法

一句話定位：腫瘤不是單數名詞——先問樣本是什麼，再決定怎麼打（建議觀看順序 B17→B19→B18）

◎ 五個決策點

統計單位是誰、整合修到哪、惡性怎麼判、比較怎麼設計、下游走哪條路——從生物問題反推管線，答完五題再寫程式碼

▣ 六場景戰法

GBM 是實體瘤原型（病人分群 + chr7+/10- + Neftel 四狀態）；黑色素瘤主角是 T 細胞；乳癌亞型先於一切；肝癌 mt 基線整體上移；AML 全反；多區域縱向靠設計期防混淆

× AML 全反

惡性長得像正常、CNV 常乾淨——一人一島消失、inferCNV 失效；改用分化阻滯 + 突變 + 免疫表型，正常骨髓參照圖譜是必需品。唯一不反：病人是統計單位

⚠ 踩雷一句話

跨腫瘤抄參數——GBM 的 mt < 20% 搬到 PBMC 反而放進垃圾；預設可推翻，推翻要寫理由，跟 QC 閾值一模一樣

⑤+ 複雜樣本策略室： v3 每集加開的一段

B1-B18 每集在踩雷區之後都有策略室：「標準流程走完了——現在想像你手上不是 PBMC，是一顆腫瘤。」五個決策點的速查如下，總其成的是 B19

策略室



策略 = 決策

pbmc / ifnb 走讀完全保留；
策略室只講決策差異

決策點 1



統計單位是誰

獨立觀察值是病人，不是細胞
(B12、B19)

決策點 2



整合修到哪

TME 對齊、惡性不硬拉
(B11、B19)

決策點 3



惡性怎麼判

CNV × 分群 × marker；近二
倍體換證據 (B16、B19)

決策點 4



比較怎麼設計

配對與湊批在收樣本前
(B4、B12)

決策點 5



下游走哪條路

細胞數交叉表先驗收 (B13-
B17、B19)

數字卡一：上游與 QC 的實測數字

三個「差很多」的現場——材料、判讀、過濾（B2、B3、B5）



2,300

同一批 FASTQ、兩個 reference，測到的基因數差距（20,300 vs 22,600）



+43% → +19%

飽和度 32% 時，reads 每翻倍一次多看到的 UMI——成本線性長，資訊對數長



2,700 → 2,638

PBMC 3k 過濾前後的細胞數：濾掉 62 顆、約 2.3%，每一步都有紀錄

數字卡二：下游的三個警世數字

群數是問出來的、UMAP 距離是佈景、cell-level p 值是幻覺（B8、B9、B12）



6 → 16 群

resolution 0.2 到 1.4，同一份資料的群數——定案靠 clustree 穩定層 + marker，不靠感覺



$\rho = -0.04$

兩個 seed 下，UMAP 15 組群間距離的排序相關——群間距離跟丟銅板差不多



303 vs 106

同一份模擬資料的顯著基因數：細胞層級 vs pseudobulk（真實 ifnb 是 3,187 對約 1,930）

全流程速查：函式鏈

十九集的程式碼，濃縮成一張——每一行後面都有一整集在撐腰

```
## 上游 (B2-B4) : FASTQ + reference -> count 矩陣
cellranger mkref /m kfastq          # B2 材料
cellranger count (多樣本 multi)     # B3-B4 web_summary 判讀後放行

## 下游主線 (B5-B10, PBMC 3k)
Read10X() |> CreateSeuratObject()    # B5 13,714 基因 x 2,700 顆
PercentageFeatureSet(); subset()    # B5 看分布定線 -> 2,638 顆
DoubletFinder                       # B5 標記不移除
NormalizeData(); FindVariableFeatures(); ScaleData() # B6 或 SCTransform()
RunPCA()                             # B7 nPC 定 1:10
FindNeighbors(); FindClusters()      # B8 掃 0.2-1.4, 定案 0.6 = 10 群
RunUMAP(seed.use 固定)              # B9 只畫圖, 不進統計
FindAllMarkers(); SingleR; Azimuth  # B10 三方交叉驗證

## 多樣本支線 (B11-B12, ifnb)
split() -> IntegrateLayers() -> JoinLayers() # B11 幾何用整合
AggregateExpression() -> DESeq2 -> lfcShrink() # B12 統計回 RNA

## 進階下游 (B13-B19) : 清單之後的「然後呢」
-> fgsea / CellChat / slingshot / infercnv / nnls # B13-B17 各一集
strategy_checklist(); strategy_presets          # B19 五決策點與六場景, B18 攤開生態系
```

每集結尾 saveRDS、下集開場 readRDS——接下來兩張卡是完整的檔案接力表

RDS 檔案接力（一）：主線 B5-B10

每一份 output/*.rds 都是一個可以「回頭」的存檔點—— B5 的教訓：沒存 raw ，回頭的成本是重跑 Cell Ranger

檔案	誰產生	誰讀走
pbmc_raw.rds / pbmc_b05_qc.rds	B5 過濾前存底／ QC 完成	B6, B7, B8
pbmc_b06_lognorm.rds (+ b06_sct.rds)	B6 normalization 完成（ SCT 對照）	B7
pbmc_b07_pca.rds	B7 PCA、 nPC 定案	B8
pbmc_b08_clustered.rds	B8 定案 0.6、 10 群	B9, B10
pbmc_b09_umap.rds / pbmc_b10_annotated.rds	B9 UMAP ／ B10 最終標籤入 metadata	後續分析＋ B17 的 signature

RDS 檔案接力（二）：支線與 B-IV

B12 的 DE 結果交棒給 B13；B-IV 各集自建存檔，讀走的人是你的論文

檔案	誰產生	誰讀走
ifnb_b11_integrated.rds	B11 整合完、金絲雀驗收過	B12, B14
ifnb_b12_de_results.rds	B12 pseudobulk DE 結果與 audit	B13
ifnb_b13_gsea.rds	B13 fgsea / ORA / 模組分數	你的論文
ifnb_b14_cellchat.rds	B14 CTRL + STIM 合併通訊物件	你的論文
sim_b15_trajectory.rds	B15 模擬分化資料與 pseudotime	你的論文
b16_infercnv_obj.rds	B16 inferCNV 物件與惡性標籤	你的論文
b17_deconv_results.rds	B17 反卷積估計與 ground truth	你的論文

全系列最貴的一顆雷：把細胞當生物重複

雷是什麼

FindMarkers 直接跑 stim vs ctrl，把 3 萬顆細胞當 3 萬個獨立觀察值——實際上只有 16 個人的檢體。



為什麼會踩

檢定力隨 n 暴漲，而同一個 donor 的細胞彼此相關；donor 之間的生物變異被誤讀成條件效應，連零效應的基因都能拿到天文級 p 值。

踩了會怎樣

p 值頂到 $1e-320$ 、顯著名單膨脹幾成到一個數量級（303 vs 106；3,187 vs 約 1,930）。解法一行：AggregateExpression 把細胞加總回樣本，再交給 DESeq2。

貫穿全系列的鐵則（一）

每一條都在至少兩集裡付過學費

鐵則 1



先看分布，再定 閾值

閾值是資料的性質，不是常數；
記下理由。（B5）

鐵則 2



seed 釘死，版 本上鎖

`set.seed(1234) + renv + 相
對路徑 = 可重現。`（B1、
B9）

鐵則 3



QC 是循環，不 是關卡

殘渣群分群後才現形；回頭修線
重跑。（B5、B8）

鐵則 4



分析在 PC，圖 在 UMAP

分群、距離、DE 不用 UMAP
座標；圖只是展示。（B8、
B9）

鐵則 5



幾何用整合，統 計回 RNA

整合是借來的對齊；DE 一律
回 RNA counts。（B11、
B12）

鐵則 6



細胞不是生物重 複

獨立單位是樣本；pseudobulk
讓 n 誠實。（B12、A1）

貫穿全系列的鐵則（二）

鐵則 7

猶豫的時候，nPC 往多的取



多取的代價是一點雜訊、幾秒計算；少取的代價，可能是一個你永遠不知道存在過的細胞亞群。（B7）

鐵則 8

大聲的錯誤是恩賜



安靜的錯誤（GTF 少一條、深度沒 normalize、殘渣成群）要靠寫成固定動作的檢查去抓——grep、cor、每群 QC 表。（B2-B8）

鐵則 9

分群給的是假說



群數可以訂做、編號會洗牌、垃圾也有 marker 清單；穩定性 + marker + QC + doublet 四關全過，才升級成發現。（B8）

鐵則 10

分數不是名字



p 值、相似度、prediction score 都是證據不是答案；marker 的解析度要配得上群的解析度，蓋章的人永遠是你。（B10）

貫穿全系列的鐵則（三）： B-IV 與策略室加簽的三條

進階下游與策略室共同的紀律：會踩剎車，比會踩油門值錢

鐵則 11



通訊與軌跡是推論，不是觀察

工具永遠給得出一張網、一條線；換粒度、換 root 重跑還在的結論才是結論，動詞永遠用「提示」。

（ B14 、 B15 ）

鐵則 12



reference 決定一切

inferCNV 的基線、反卷積的

signature：選錯不

報錯。跑之前先問

reference 憑什麼，

跑完先驗 reference

那幾列。（ B16 、

B17 ）

鐵則 13



參數是假設：有數字、有理由、有紀錄

預設值是別人資料的答案，跨腫瘤照抄一樣危險。每個閾值寫下數字與理由；推翻預設也要寫理由。

（ B5 、 B19 、策略室）

B 系列 · 一句話

從 FASTQ 到基因清單，再到清單之後的 「然後呢」—— 十九集，這條路你已經完整走過一遍。

指令會過時，但「先看分布、再定閾值、寫下理由」的判斷不會。工具換掉，你還在。

接下來

C 系列 · 看懂數學（8 集）

三條進修路線：數學、工程、生物

數學向 → C 系列：PCA 的 SVD、分群的模組度、UMAP 的目標函數，一步步算給你看。

工程向 → pipeline 化（targets / Nextflow）與 Quarto 可重現報告；生物向 → 你的組織與疾病的圖譜文獻 + cellxgene census。上次卡關卡在哪，就先補哪。